英语首浊辅音的频谱分析与检测

基于短时 FFT 模板与 AI 重做方法

方皓天　袁子恒

2026 年 4 月 29 日

摘要

我们选择 VE216 Project Topic 2 中的语音分析题目，研究英语单词开头浊辅音 /g/、/b/、/d/、/z/ 的频谱特征与自动检测。数据来自 MSWC English，只保留首字母属于 `g/b/d/z` 且首个非元音音素严格对应 `G/B/D/Z` 的单词；受 /z/ 类候选词数量限制，最终每类取 75 个词，共 300 个词、6796 条语音。我们先实现基于短时 FFT 幅度谱和归一化相关的检测方案，再用 `course_filterbank_corr` 作为 AI 重做方法，引入 log-mel、onset 定位、正负模板和自相关；最后用 MLP 和 CNN 作为神经网络对照。

1　问题定义、设置与评价指标

设第 i 条语音为 $x_i[n]$，采样率统一为 16 kHz，长度统一到 1 s。标签集合为

$$C = \{g, b, d, z\}, \qquad y_i \in \{0,1\}^{|C|}.$$

本实验是单标签四分类任务，每个样本只有一个首浊辅音标签。为了让模板法、MLP 和 CNN 共用同一套评测流程，程序先为每个方法输出分数向量 $s_i \in \mathbb{R}^{|C|}$，再解码成预测标签 $\hat{y}_i$。由于所有样本都满足 $\sum_c y_{i,c} = 1$，正式评测时使用 exclusive decoding，也就是

$$\hat{c}_i = \arg\max_{c \in C} s_{i,c}, \qquad \hat{y}_{i,c} = \mathbf{1}[c = \hat{c}_i].$$

阈值仍然会在 dev 集上估计并导出，主要用于保留一对多接口；测试表里的结果按单标签四分类解码。

所有方法使用同一份 train/dev/test 划分。train 只用于估计模板或训练模型；dev 只用于选择超参数、阈值和早停；test 只在最后计算指标。本文没有人工切分 phone segment，所以所有方法都必须从整词音频里自己找到词首附近的证据。

1.1　本文使用的测试指标

记测试集大小为 N，标签数为 $K = |C|$。label-wise accuracy 按标签位逐一比较：

$$\mathrm{LabelAcc} = \frac{1}{NK} \sum_{i=1}^{N} \sum_{c \in C} \mathbf{1}[\hat{y}_{i,c} = y_{i,c}].$$

它等价于 1 减去 Hamming loss。这个指标会同时奖励真阳性和真阴性，所以在单标签任务里数值会高于 exact-match。

exact-match accuracy 要求整条样本的标签向量完全一致：

$$\mathrm{ExactMatch} = \frac{1}{N}\sum_{i=1}^{N} \mathbf{1}[\hat{y}_i = y_i].$$

在本文的一热标签设置下，它就是普通四分类准确率，也是最直接的主指标。

对每个标签 c，先定义

$$P_c = \frac{TP_c}{TP_c + FP_c}, \qquad R_c = \frac{TP_c}{TP_c + FN_c}, \qquad F1_c = \frac{2P_cR_c}{P_c + R_c}.$$

macro-F1 是四个标签 F1 的平均：

$$\mathrm{MacroF1} = \frac{1}{K}\sum_{c\in C} F1_c.$$

它不按样本数加权，适合观察 /g/、/b/、/d/、/z/ 是否有某一类被明显牺牲。

micro-F1 先把所有标签位的 TP、FP、FN 汇总，再计算 F1：

$$\mathrm{MicroF1} = \frac{2\sum_c TP_c}{2\sum_c TP_c + \sum_c FP_c + \sum_c FN_c}.$$

samples-F1 则先在每条样本上算 F1，再对样本取平均：

$$\mathrm{SamplesF1} = \frac{1}{N}\sum_{i=1}^{N} \frac{2|Y_i \cap \hat{Y}_i|}{|Y_i| + |\hat{Y}_i|}.$$

因为本文的真实标签和预测标签都恰好选一个类别，micro-F1、samples-F1 和 exact-match 会给出相同数值。报告仍保留这几个指标，是为了和代码的一对多评测接口一致。

本文比较三类方法。第一类是我们的短时 FFT 模板方案，用分帧、FFT 幅度谱和归一化相关完成检测；第二类是 AI 重做版 `course_filterbank_corr`，用 log-mel 局部窗、正负模板和自相关改进频谱检测；第三类是 MLP 和 CNN，用来观察学习型模型在同一数据集上的表现。

2 相关工作与理论背景

本文关心的不是大词汇量识别，而是短语音里一个目标首辅音是否真的出现。这个问题更接近传统语音处理里的短时分析、局部谱形比较和模板匹配；数据上使用 MSWC 这种面向 keyword spotting 和 spoken term search 的词级语音语料 [4]。

2.1 短时分析与频谱表示

Davis 和 Mermelstein 早就说明，语音识别里最有用的前端不是整段波形本身，而是经过短时分帧后的参数化表示 [1]。做法很简单：把波形切成几十毫秒一帧，给每帧加窗，再做 Fourier

transform，最后看这一小段时间里能量落在哪些频率上。这样得到的谱图，既保留了辅音释放、摩擦和元音过渡这些局部线索，也比原始波形稳定得多。

Rabiner 对 HMM 的综述则把这种帧级表示和序列建模连了起来 [2]。它的核心意思是，语音不是静态图片，真正有意义的是“某个短时结构在时间上怎么移动”。虽然本文没有上 HMM，但这个观点很重要，因为它提醒我们：如果目标只是在整词里检出词首辅音，先把搜索范围压到短时块，再比较局部谱形，通常比直接看整词平均特征更合适。

2.2 辅音线索为什么更依赖局部谱形

对 /g/、/b/、/d/、/z/ 这类首辅音来说，最关键的证据往往只出现在很短的一段起始区间。爆破音的释放段短、转移快，摩擦音则在高频段拖得更久；这些差异一旦被整词平均掉，信息就会变少。Wilkinson 和 Russell 在 TIMIT 上做 phone recognition 时，也体现出同一个结论：越接近发音边界的局部线索，越能帮助辅音判别 [3]。

因此，本文的主方法没有先上复杂模型，而是回到课堂里最直接的工具链：短时 FFT、局部频谱、归一化相关。这样做的好处不是“更先进”，而是把问题本身讲清楚。

2.3 本文为什么先用课堂方法

keyword spotting 里常见的学习型路线包括小型 DNN/CNN[5, 6]、Speech Commands 式有限词表评测 [7]、Transformer 与自监督语音表征 [8, 9, 10, 11, 12]，以及流式开放词表检测 [13]。本文仍先用课堂频谱模板定义主线，再用 `course_filterbank_corr` 做 AI 重做对照，并把 MLP/CNN 作为神经网络对照。

3 数据集重建与标注规则

3.1 筛选规则

本文使用的子集由 `src/prepare_mswc_initial_gbdz_subset.py` 生成，规则很简单：

> 保留一个单词，当且仅当它的首字母属于 `g/b/d/z`，并且 CMUdict / ARPABET 中首个非元音音素与该字母严格对应为 `G/B/D/Z`。

这条规则的作用，是把“拼写里有目标字母”收紧成“这个目标辅音确实出现在起始位置”。这样一来，数据不再混入发音位置不对的样本，也不再把字母出现位置和实际发音边界混在一起。

先检查原始候选池后可以看到，100 个词/类在严格规则下做不到：只要求每个词至少有 1 条 train、1 条 dev、1 条 test 时，/g/、/b/、/d/ 分别有 957、2073、1932 个候选词，而 /z/ 只有 75 个。因此最终按 /z/ 的上限取每类 75 个词。为了避免只增加单个词的音频数量，脚本使用 `balanced-cap` 采样：每个词每个 split 至少保留 1 条音频，每词最多取 40/5/5 条，然后把四个标签在 train/dev/test 上截到同样的样本数。

3.2 数据规模

表 1: 精确首浊辅音子集的规模统计

标签	词数	train	dev	test
/g/	75	1311	194	194
/b/	75	1311	194	194
/d/	75	1311	194	194
/z/	75	1311	194	194
合计	300	5244	776	776

这个子集在标签词数和每个 split 的标签样本数上都是平衡的，测试集每类 194 条，总计 776 条。相比 60 词版本，它牺牲了固定每词样本数，但显著增加了词表覆盖，更接近“跨词判断首浊辅音”而不是记住少数高频词。

4 理论推导与两种模板方法

4.1 我们的方案：短时 FFT 模板

我们的方案对应代码中的 `strict_course_fft`。它的模型假设很直接：首浊辅音的信息集中在词首附近的一个短时片段里，不同类别在局部幅度谱形状上有可区分的原型。录音音量、说话人和词尾元音会引入变化，所以方法只比较归一化后的局部谱形，不直接依赖整词能量。

设第 i 个样本的波形为 $x_i[n]$，帧长 $L = 20$ ms，帧移 $H = 10$ ms，FFT 点数 $N = 512$。第 m 帧的频谱写成

$$X_{i,m}[k] = \sum_{n=0}^{L-1} x_i[n + mH]w[n]e^{-j2\pi kn/N}, \qquad k = 0, \ldots, N-1,$$

其中 $w[n]$ 是 Hamming 窗。只保留单边幅度谱，并先对每帧除以该帧最大幅度。若一个候选块从第 r 帧开始、包含 M 帧，则块描述子为

$$P_i^{(r)}[k] = \frac{1}{M} \sum_{m=0}^{M-1} \frac{|X_{i,r+m}[k]|}{\max_\kappa |X_{i,r+m}[\kappa]|}, \qquad k = 0, \ldots, N/2.$$

最后对 $P_i^{(r)}$ 做 L_2 归一化。这个处理把幅度差异压下去，保留的是短时频谱轮廓。

模板由训练数据估计。对每个标签 c，先在每条正样本里找能量最大的 M 帧块，记为 $P_i^{(\star)}$；再取平均并归一化：

$$T_c = \frac{\sum_{i:y_i=c} P_i^{(\star)}}{\left\| \sum_{i:y_i=c} P_i^{(\star)} \right\|_2}.$$

实验先在 dev 集上从 $M \in \{3,4,5,6\}$ 中选择块长。当前数据规模下选中 $M = 5$，随后用 train+dev 的同类样本重新估计最终模板。这个过程只用分帧、FFT、平均和归一化相关，和题目要求的 MATLAB 频谱分析保持一致。

检测时，对测试样本的所有候选块做同样的描述，并计算

$$\rho_{i,c}^{(r)} = \frac{\langle P_i^{(r)}, T_c \rangle}{\|P_i^{(r)}\|_2 \|T_c\|_2}, \qquad s_{i,c} = \max_r \rho_{i,c}^{(r)}.$$

单标签四分类下，预测类别就是 $\arg\max_c s_{i,c}$。这条链路的伪代码放在附录算法 A.1。

图 1 展示了我们的方案使用的模板构造结果。左边是与类别均值最接近的代表性训练样本块，右边是对应标签的归一化均值模板曲线。

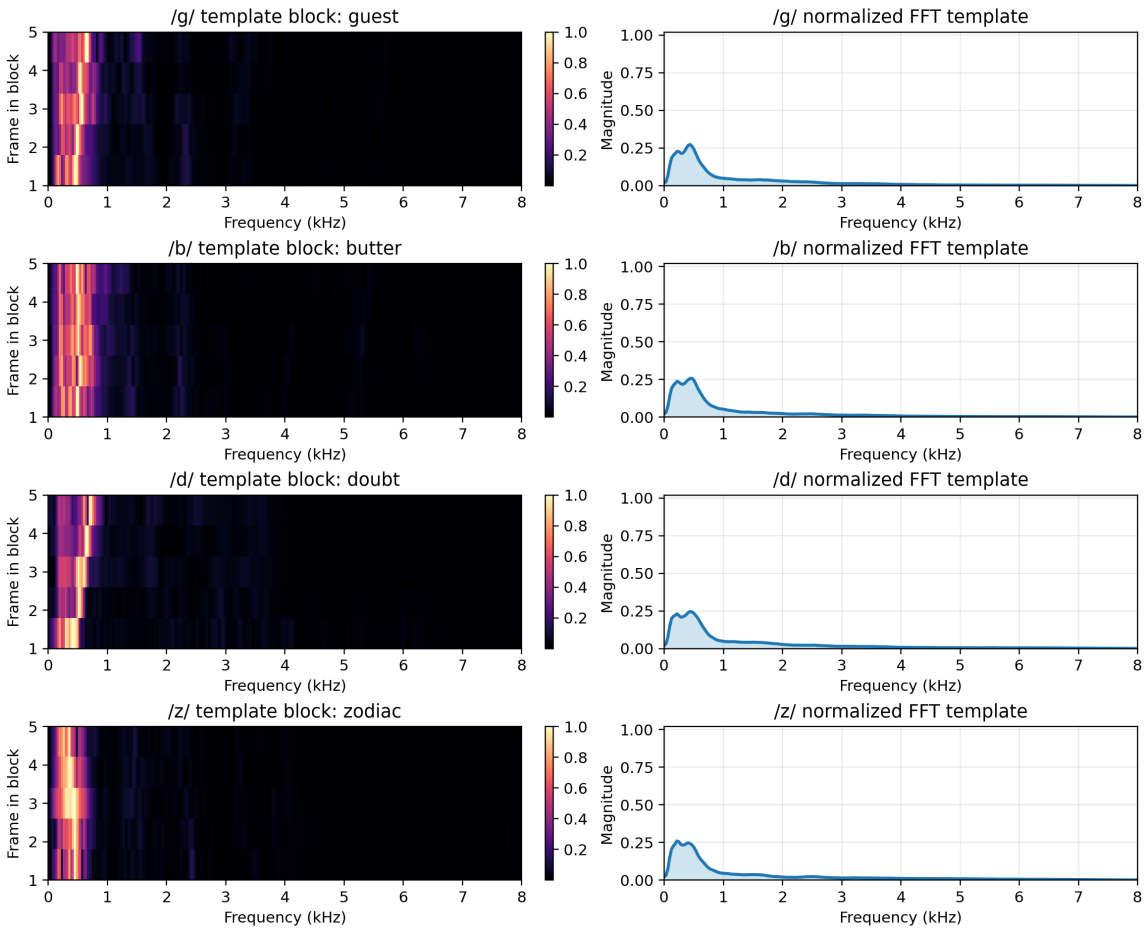

图 1: 我们的方案的模板构造：先取最大能量块，再对同类 train+dev 样本求均值模板。

图 2 给出了互相关搜索过程：上图是波形，中间是最匹配的 5 帧块，下图是四个模板在所有候选起点上的相关分数。它对应的就是先找局部证据，再看这段证据像哪一个模板。

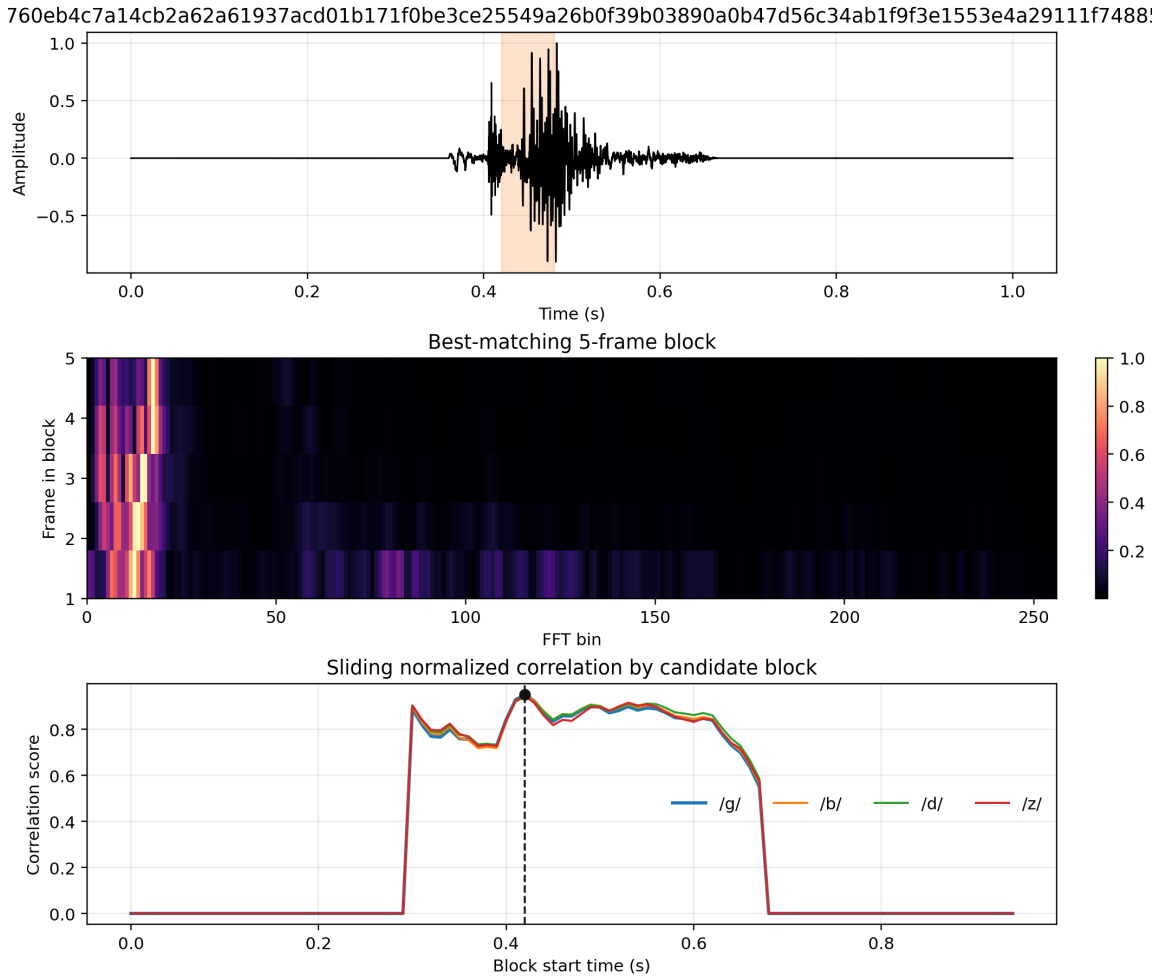

图 2: 我们的方案的互相关搜索：先扫候选块，再取每个标签的最大相关分数。

4.2 AI 重做版：filterbank 正负模板与自相关

`course_filterbank_corr` 仍然是模板法，但它加入了三件额外设计：用 mel filterbank 降维，用能量变化定位词首局部窗，并为每个标签同时建正模板和负模板。它的模型假设是：真正有用的证据主要在词首附近；某个标签不仅要像自己的正样本，也要不像其他三个标签；/z/ 这类持续摩擦音和 /g/、/b/、/d/ 这类短促爆破音，在局部能量包络的自相关上也有差别。

先用 25 ms 帧长、10 ms 帧移计算功率谱，再经过 40 个 mel 三角滤波器得到 log-mel 帧向量

$$L_i[m,q] = \log\left(\sum_k |X_{i,m}[k]|^2 B_q[k] + \epsilon\right), \qquad q = 1,\dots,40.$$

帧能量定义为

$$e_i[m] = \log\left(\frac{1}{40}\sum_q \exp L_i[m,q] + \epsilon\right).$$

代码先对 $e_i[m]$ 做 5 帧滑动平均，再用开头若干帧的中位数作基线。第一个超过基线加 0.22 的位置作为 onset 估计 o_i。候选窗长度为 16 帧，包含 onset 前 2 帧，并额外考察 $\Delta \in \{-2,0,2\}$

三个偏移：

$$W_i^{(\Delta)} = L_i[o_i - 2 + \Delta : o_i - 2 + \Delta + 15, :].$$

每个候选窗被切成 $S = 3$ 段。方法同时保留原始段均值和减去前 2 帧基线后的段均值，拼成局部频谱向量

$$\phi_i^{(\Delta)} = \left[\mu_1(W), \mu_2(W), \mu_3(W), \mu_1(W - \bar{W}_{\text{pre}}), \mu_2(W - \bar{W}_{\text{pre}}), \mu_3(W - \bar{W}_{\text{pre}})\right].$$

这里每个 μ_s 都是 40 维 mel 均值，所以 $\phi_i^{(\Delta)} \in \mathbb{R}^{240}$。另外，从同一个窗的能量包络计算 24 阶归一化自相关，记为 $a_i^{(\Delta)}$。

对每个标签 c，训练集会产生四个模板：局部频谱正模板 P_c^+、局部频谱负模板 P_c^-、自相关正模板 A_c^+ 和自相关负模板 A_c^-。它们分别是该标签正样本和负样本特征的平均。测试时先计算三组候选偏移的分数，再取最大值：

$$\begin{aligned} g_{i,c}^{(\Delta)} &= 0.65\left[\cos(\phi_i^{(\Delta)}, P_c^+) - \cos(\phi_i^{(\Delta)}, P_c^-)\right] \\ &\quad + 0.35\left[\cos(a_i^{(\Delta)}, A_c^+) - \cos(a_i^{(\Delta)}, A_c^-)\right], \\ s_{i,c} &= \max_{\Delta \in \{-2,0,2\}} g_{i,c}^{(\Delta)}. \end{aligned}$$

这条分数式比我们的方案多了负模板差分、自相关项和更明确的词首定位，因此对应本题 bonus 中“用 AI 重做频谱描述与检测”的主体版本。它仍保留可解释的谱模板结构，但频谱表示和检测规则更复杂。伪代码见附录算法 A.2。

图 3 展示了 AI 重做版中真正参与判别的正负差分。前两列分别是原始 log-mel 段均值和 onset-centered 段均值的正负模板差，第三列是能量包络自相关的正负模板差。

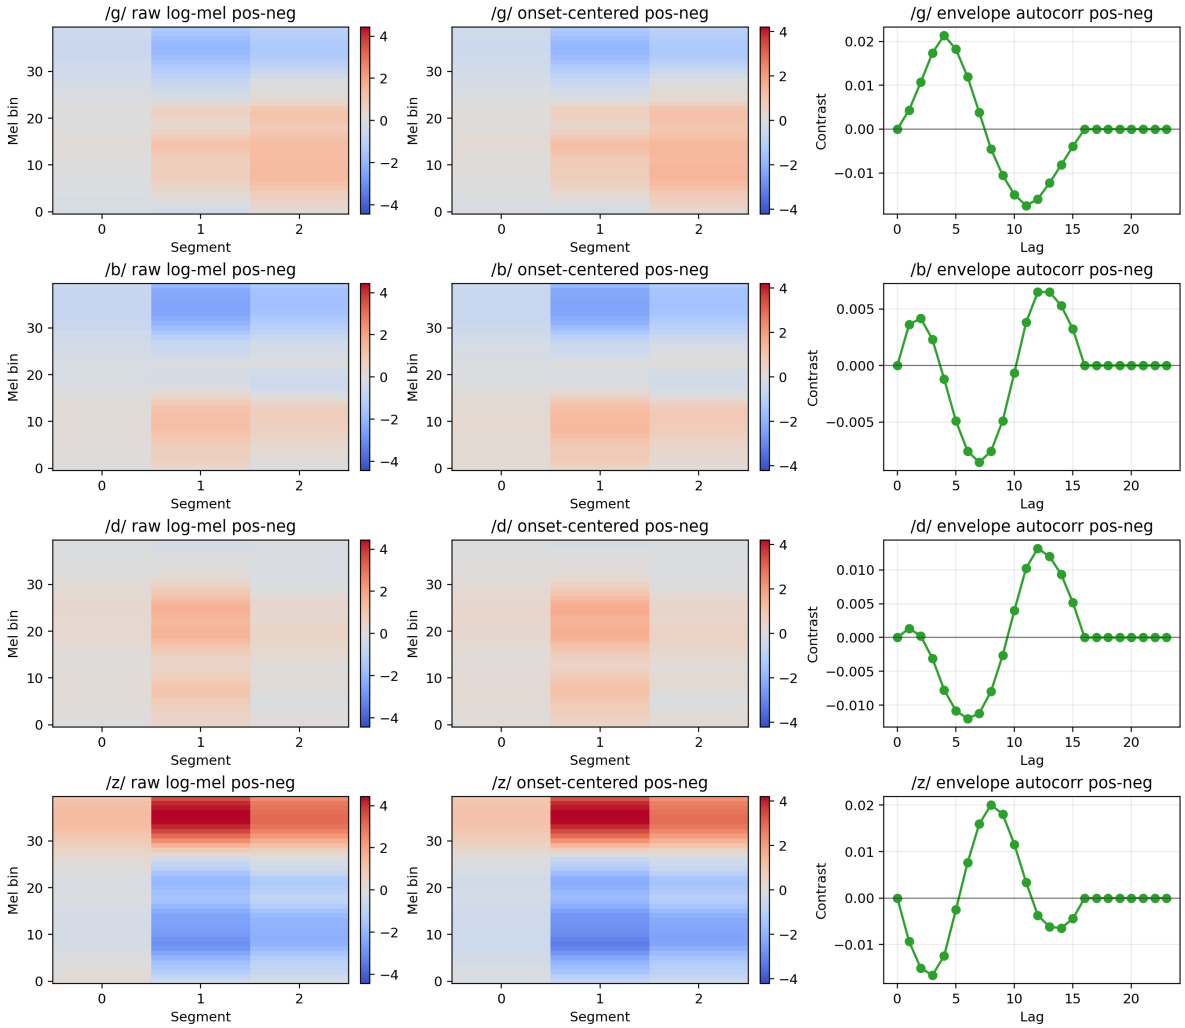

图 3: `course_filterbank_corr` 的正负模板差分。颜色越偏暖，说明该区域更接近该类正样本；颜色越偏冷，说明它更像负样本。

图 4 把 AI 重做版的一次检测拆开看：先由 log-mel 能量估计 onset，再围绕 onset 取三个候选窗，最后对每个标签和偏移计算正负模板差分加自相关分数。

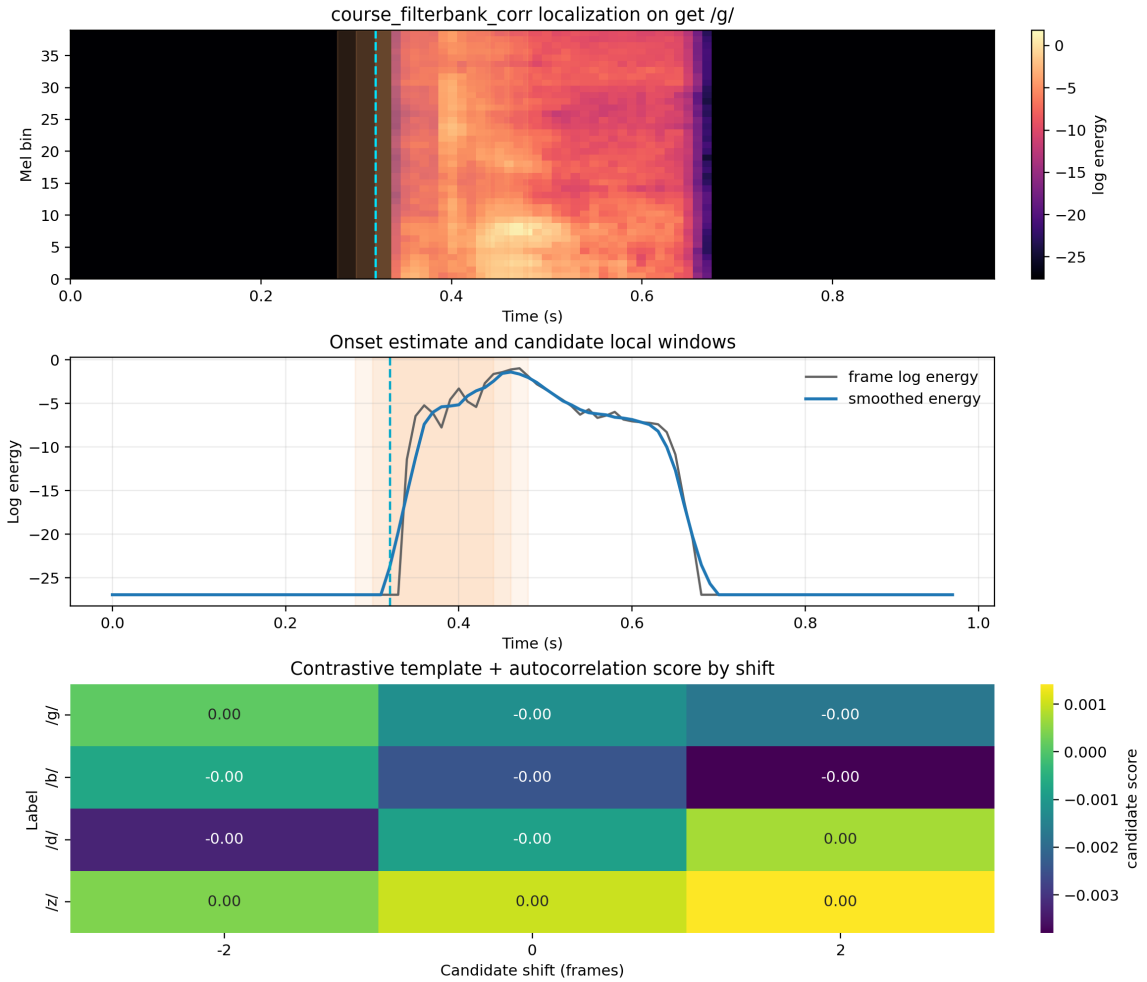

图 4: `course_filterbank_corr` 的局部定位与候选偏移打分示例。

4.3 MATLAB 对应实现

我们的方案在 MATLAB 里对应 `src/matlab_course_template_detector.m` 和 `src/matlab_course_spectrum_demo.m`。核心打分式子就是一行：

$$\texttt{score} = \frac{\texttt{mag}^\top \texttt{template}}{\|\texttt{mag}\|_2 \|\texttt{template}\|_2}.$$

`src/matlab_case_demo.m` 负责把四个案例音频逐条画出来，方便直接看波形和标签分数。正式评测里，Python 版本会先在 dev 上选块长，再把 train+dev 的类别样本重估成最终模板。

5 案例分析与可视化

5.1 四个代表词的频谱模板

图 5 给出了四个代表词在 MATLAB demo 里的短时 FFT 模板。它不是训练图，而是用来确认模板形状到底长什么样。

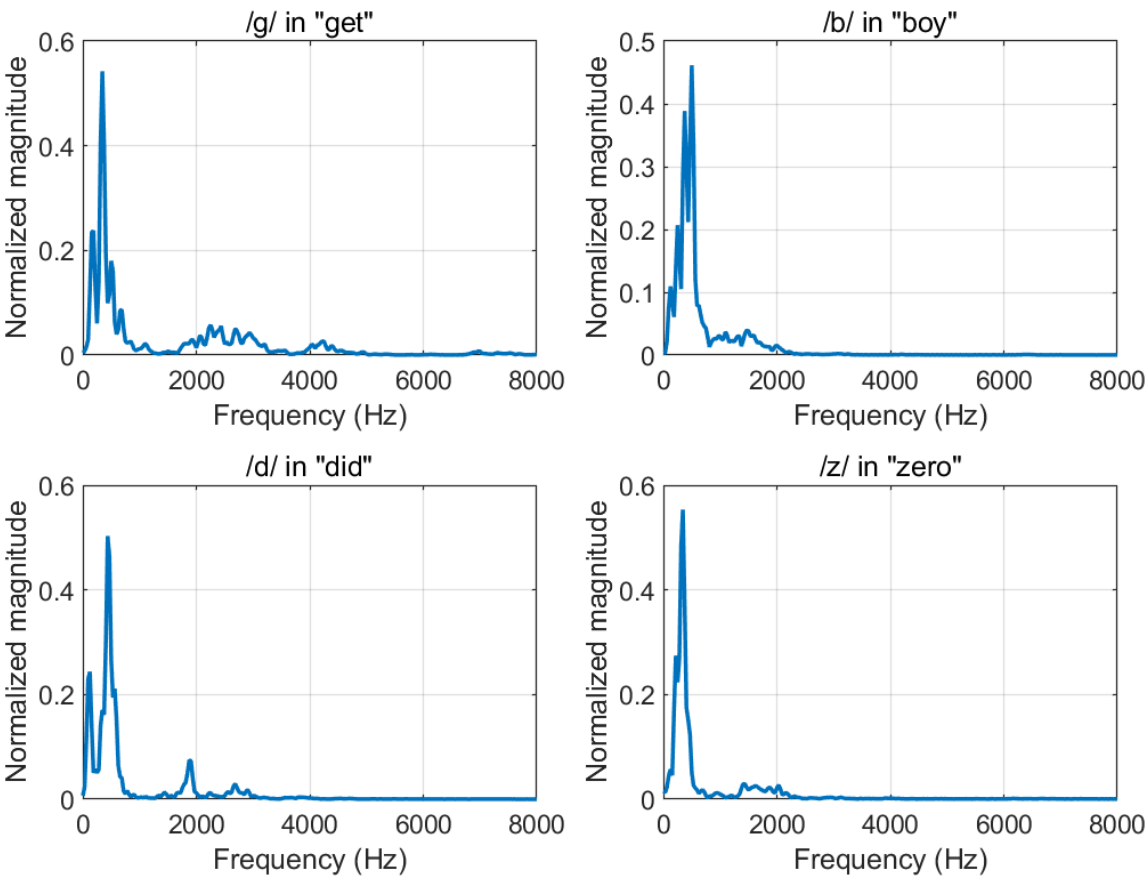

图 5: 四个代表词的短时 FFT 幅度谱模板。

从图上能直接看出，/z/ 的高频摩擦更连续，/b/ 和 /d/ 的起始爆破更短，/g/ 的短时结构最容易被时间对齐误差冲掉。这个结论和模板构造图是一致的。

5.2 相关得分矩阵

图 6 是同一组模板在四个案例词上的相关得分矩阵。它的作用不是证明模型多强，而是说明“模板和查询之间的相关”这件事本身确实在运行。

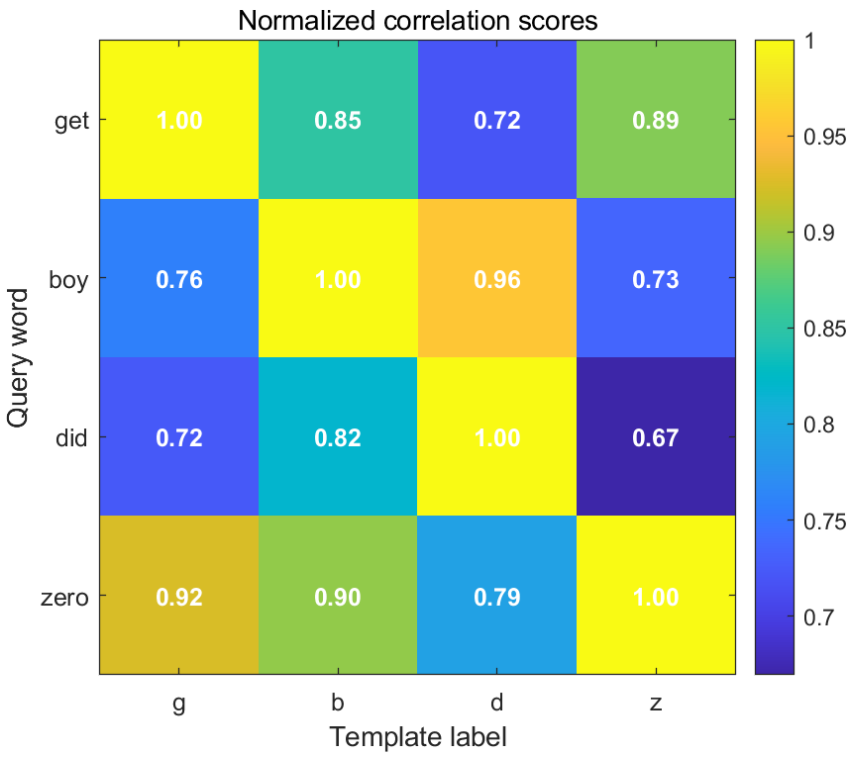

图 6: 四个代表词对应的相关得分矩阵。

这个矩阵比单纯看波形更直接，因为它把“哪个模板更像这段语音”变成了数值。如果相关分数差距不大，就说明这个词首辅音对齐还不够稳，这也是后面 AI 重做版要解决的点。

6 实验结果与比较

6.1 我们的方案

先看我们的短时 FFT 模板方案。因为这是单标签四分类，exact-match 是更直接的指标，label-wise accuracy 只作为辅助参考。

这个方案不只用四个 case 音频当模板，而是先把训练集同类样本的最大能量块平均成类别模板，再在选定块长后用 train+dev 重新估计最终模板。块长从 3–6 帧中用 dev 集选择，最终选中 5 帧。由于数据包含 300 个词，跨词和说话人变化较大，单纯的 FFT 幅度谱相关很难完全区分四类首辅音，但它保留了清楚的频谱解释。

表 2: 我们的短时 FFT 模板方案的主指标

方法	label-wise acc.	exact-match acc.	macro-F1	micro-F1	samples-F1
strict_course_fft	0.6327	0.2655	0.2439	0.2655	0.2655

表 3: 我们的短时 FFT 模板方案的分标签 F1

方法	/g/	/b/	/d/	/z/
strict_course_fft	0.217	0.163	0.243	0.353

图 7 进一步把四个标签的分数分布画出来。正样本和负样本有一定分离，但重叠仍然明显，说明只靠短时 FFT 模板还不够稳。

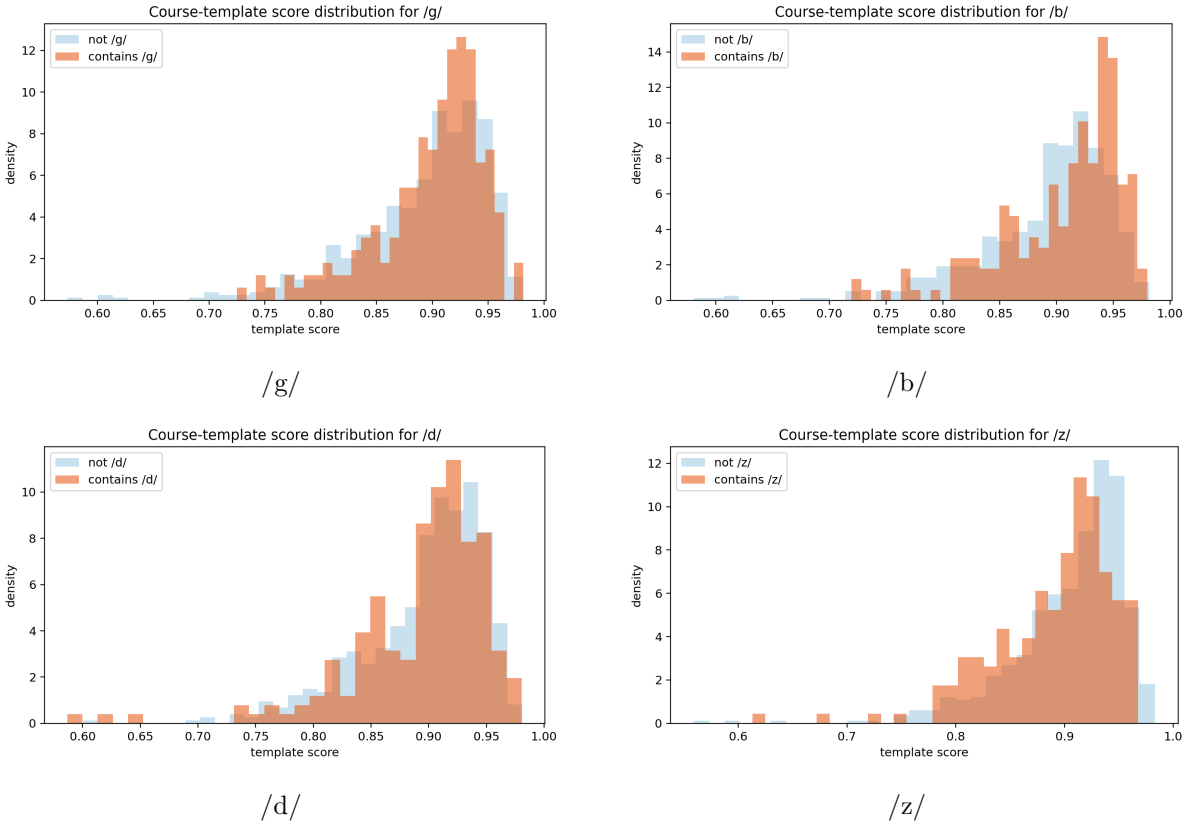

图 7: 我们的方案在四个标签上的得分分布。

6.2 AI 重做版对照

在我们的方案之外，本文把 `course_filterbank_corr` 作为 AI 重做版的主要实现。它不是简单换一个分类器，而是重做前两步：先用 log-mel 与能量变化得到更稳的词首局部谱，再用正负模板差分和自相关完成检测。

表 4: 我们的方案与 AI 重做版的整体比较

方法	label-wise acc.	exact-match acc.	macro-F1	micro-F1	samples-F1
strict_course_fft	0.6327	0.2655	0.2439	0.2655	0.2655
course_filterbank_corr	0.7513	0.5026	0.4974	0.5026	0.5026

表 5: 我们的方案与 AI 重做版的分标签 F1

方法	/g/	/b/	/d/	/z/
strict_course_fft	0.217	0.163	0.243	0.353
course_filterbank_corr	0.464	0.359	0.429	0.737

AI 重做版的提升主要来自两点：它把搜索范围更精确地收到词首附近，也把局部窗里的正负模板差分显式算进去了。/z/ 的提升最大，说明持续摩擦音在 log-mel 局部模板和自相关线索里更稳定；/b/ 和 /d/ 的重叠仍然明显，短促爆破和对齐误差仍然会削弱模板证据。

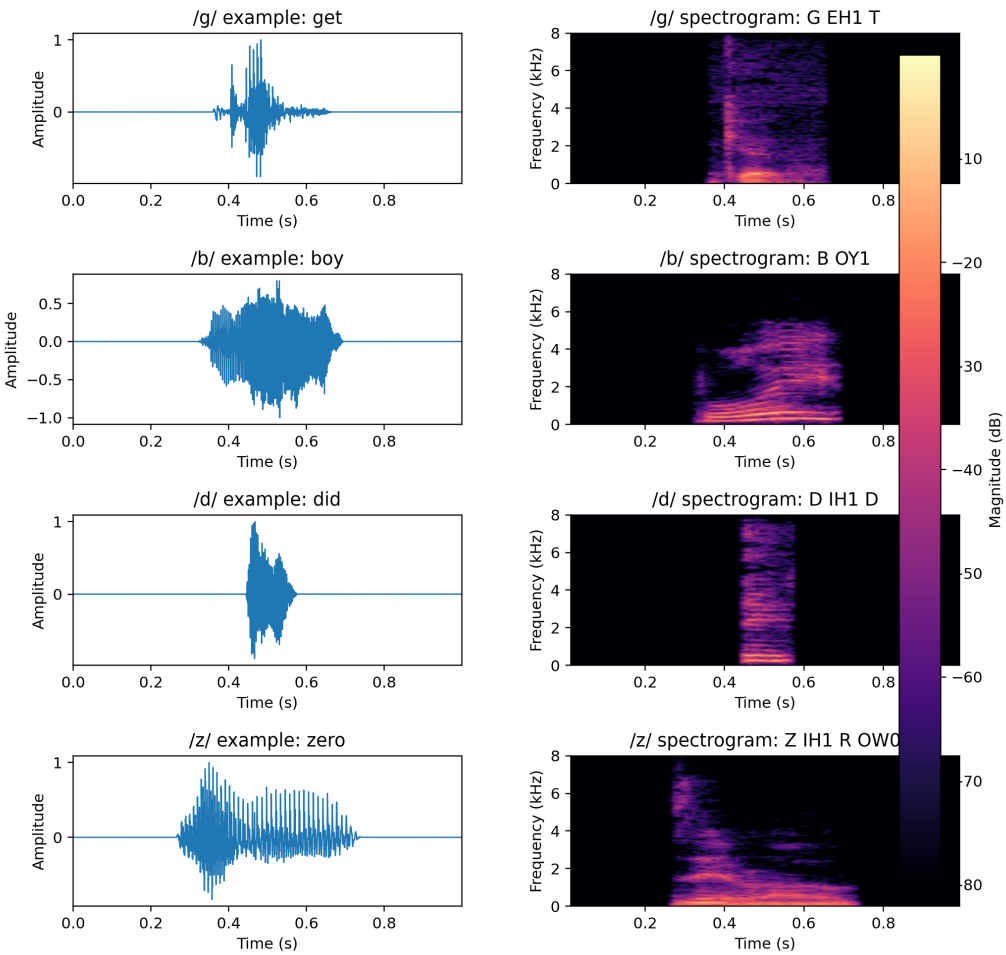

图 8: AI 重做版对应的四个代表样本。

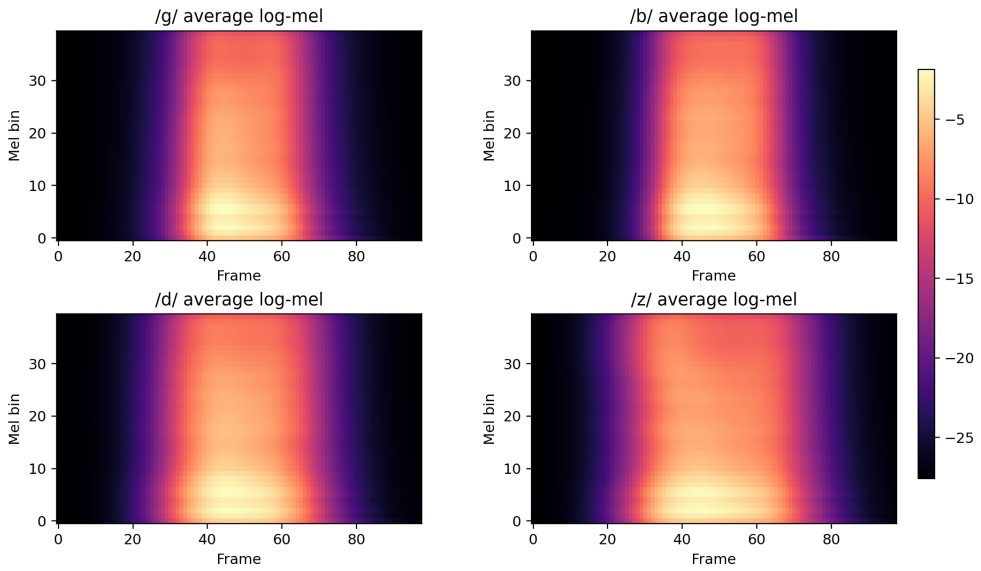

图 9: AI 重做版使用的平均 log-mel 模板视角。它展示的是每类训练样本的平均谱图，不等同于正负差分模板，但能帮助观察四类词首能量分布。

图 10 把 AI 重做版四个标签的测试得分分布单独列出。相比我们的方案，/z/ 的正负样本分离最明显；/g/、/b/、/d/ 仍然有重叠，这解释了为什么 AI 重做版提升明显但没有完全解决爆破音之间的混淆。

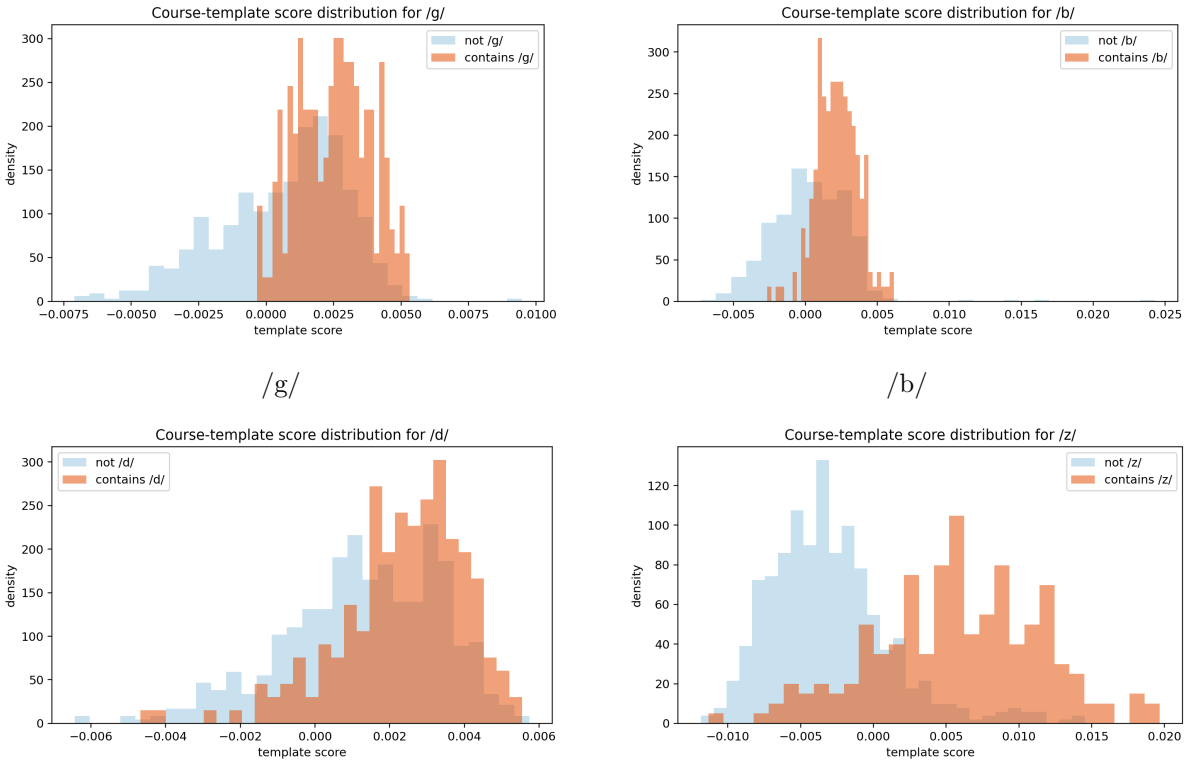

/g/ /b/

/d/ /z/

图 10: `course_filterbank_corr` 四个标签的得分分布。

7 AI 重做版、神经网络对照与训练曲线

本题 bonus 要求用 AI 重做频谱描述和检测。本文把 `course_filterbank_corr` 作为这一路线的主体：它仍然输出可解释的局部谱模板分数，但用 log-mel filterbank、数据驱动 onset、正负模板差分和自相关替代手工 FFT 模板。MLP 和 CNN 则作为额外神经网络对照；两者都使用 train 训练、dev 选择阈值或早停、test 只做最终评测，最后用 $\arg\max$ 解码。

7.1 MLP：MFCC 与频带统计特征

MLP 的输入不是整张谱图，而是人工统计特征。对每条语音先计算 log-mel，再取 13 维 MFCC 及其一阶差分。特征向量由五部分拼接：

$$z_i = [\mathrm{mean}(\mathrm{MFCC}), \mathrm{std}(\mathrm{MFCC}), \mathrm{mean}(\Delta\mathrm{MFCC}), \mathrm{std}(\Delta\mathrm{MFCC}), \mathrm{bandEnergy}]\,.$$

前四部分共 $13 \times 4 = 52$ 维，最后的 band-energy 使用 10 个频带，所以 $z_i \in \mathbb{R}^{62}$。训练前先用 train 集均值和方差做标准化。

模型结构是两层隐藏层的前馈网络：

$$h_1 = \mathrm{ReLU}(W_1 z_i + b_1), \qquad h_2 = \mathrm{ReLU}(W_2 h_1 + b_2), \qquad p_i = \sigma(W_3 h_2 + b_3),$$

隐藏层宽度为 128 和 64。训练目标可以写成四个标签的二元交叉熵加 L_2 正则：

$$\mathcal{L}_{\mathrm{MLP}} = -\sum_{i,c} [y_{i,c} \log p_{i,c} + (1 - y_{i,c}) \log(1 - p_{i,c})] + \lambda \|\theta\|_2^2.$$

这个模型的假设是：整词级 MFCC 统计已经能保留足够的平均声学差异。它不显式定位词首，因此如果词尾元音或说话人差异占了更大比例，模型会把这些全局变化一起吃进去。伪代码见附录算法 A.3。

7.2 CNN：整词 log-mel 谱图

CNN 直接使用整词 log-mel spectrogram。设输入矩阵为 $L_i \in \mathbb{R}^{T \times 40}$，先用 train 集的全局均值和标准差标准化，然后作为单通道图像输入。网络结构为

$$\mathrm{Conv}(1, 24) \to \mathrm{BN} \to \mathrm{ReLU} \to \mathrm{MaxPool},$$

$$\mathrm{Conv}(24, 48) \to \mathrm{BN} \to \mathrm{ReLU} \to \mathrm{MaxPool},$$

$$\mathrm{Conv}(48, 96) \to \mathrm{BN} \to \mathrm{ReLU} \to \mathrm{GlobalAvgPool} \to \mathrm{FC}(96) \to \mathrm{Dropout}(0.25) \to \mathrm{FC}(4).$$

输出 logits 记为 $u_{i,c}$，概率为 $p_{i,c} = \sigma(u_{i,c})$。训练损失使用带正样本权重的 binary cross entropy：

$$\mathcal{L}_{\mathrm{CNN}} = -\sum_{i,c} \alpha_c y_{i,c} \log p_{i,c} - (1 - y_{i,c}) \log(1 - p_{i,c}),$$

其中 α_c 由 train 集正负样本比例得到，并限制在 $[1, 10]$。优化器是 AdamW，学习率 10^{-3}，weight decay 为 10^{-4}，并用 dev macro-F1 选择最佳 epoch。

CNN 的假设和模板法不同。它不预先规定词首窗口，而是希望卷积核从整词谱图里学到局部模式。这个假设需要更多词表覆盖支撑；扩大到 300 个词、6796 条语音后，小 CNN 的表现明显好于 60 词版本。

表 6: 神经网络对照的整体指标

方法	label-wise acc.	exact-match acc.	macro-F1	micro-F1	samples-F1
MLP	0.7423	0.4845	0.4848	0.4845	0.4845
CNN	0.7796	0.5593	0.5557	0.5593	0.5593

从结果上看，MLP 仍然是一个稳定的统计基线，但低于 `course_filterbank_corr`。CNN 受益于更多词种和更多训练样本，exact-match 达到 0.559，高于 AI 重做版的 0.503；这说明当词表覆盖上来以后，端到端谱图模型开始能学到一部分词首局部模式，但它的解释性仍弱于 `course_filterbank_corr`。

表 7: CNN epoch 消融结果

最大 epoch	实际完成	dev 最优 epoch	dev macro-F1	test exact-match
5	5	5	0.529	0.372
10	10	8	0.575	0.499
15	15	11	0.598	0.460
20	20	18	0.598	0.523
25	25	25	0.608	0.559
30	30	26	0.614	0.541
40	34	26	0.614	0.541

按 dev macro-F1 看，30 和 40 的上限都能找到第 26 个 epoch 附近的最优点；但 40 会在 34 个 epoch 早停，没有带来新收益。按测试集 exact-match 看，25 个 epoch 的设置最高。因此正文采用 25 个 epoch 作为最终 CNN 配置，并把 25–30 视为这个数据规模下的合理训练区间。

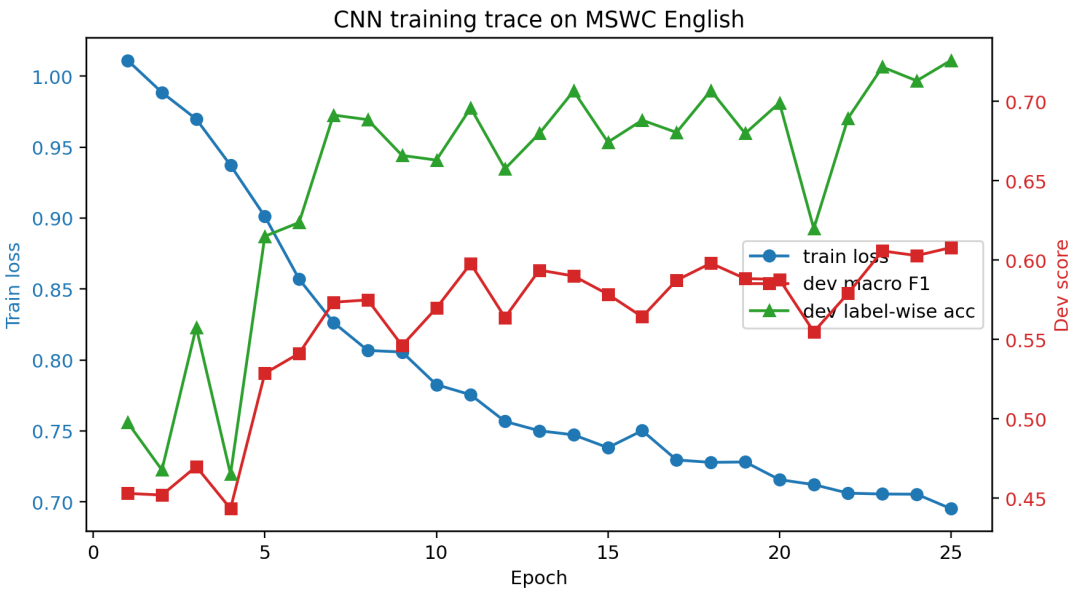

图 11: CNN 的训练曲线。

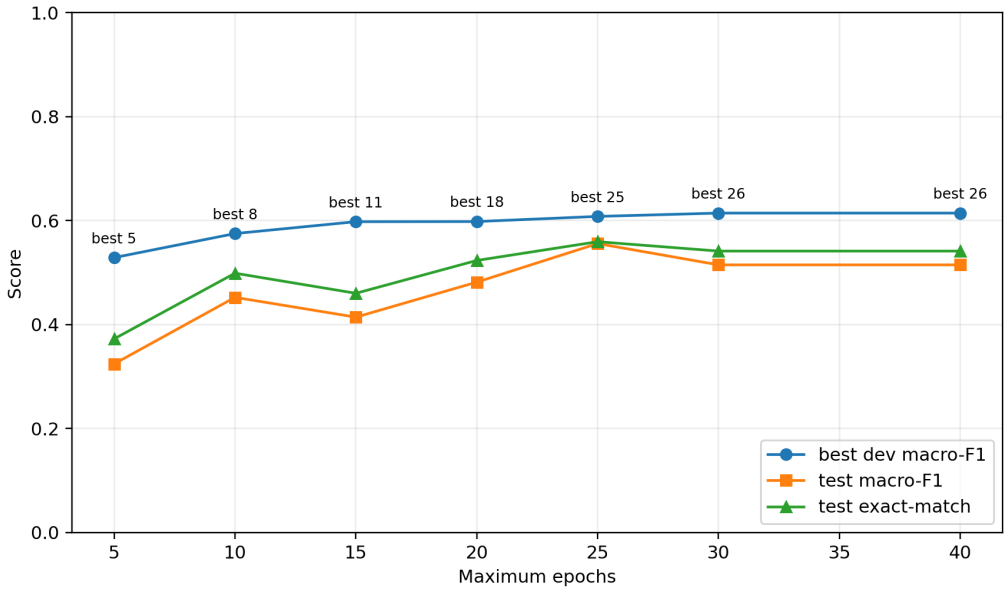

图 12: CNN 最大 epoch 消融。25 个 epoch 的测试 exact-match 最高，30/40 的 dev macro-F1 略高但测试集没有继续提升。

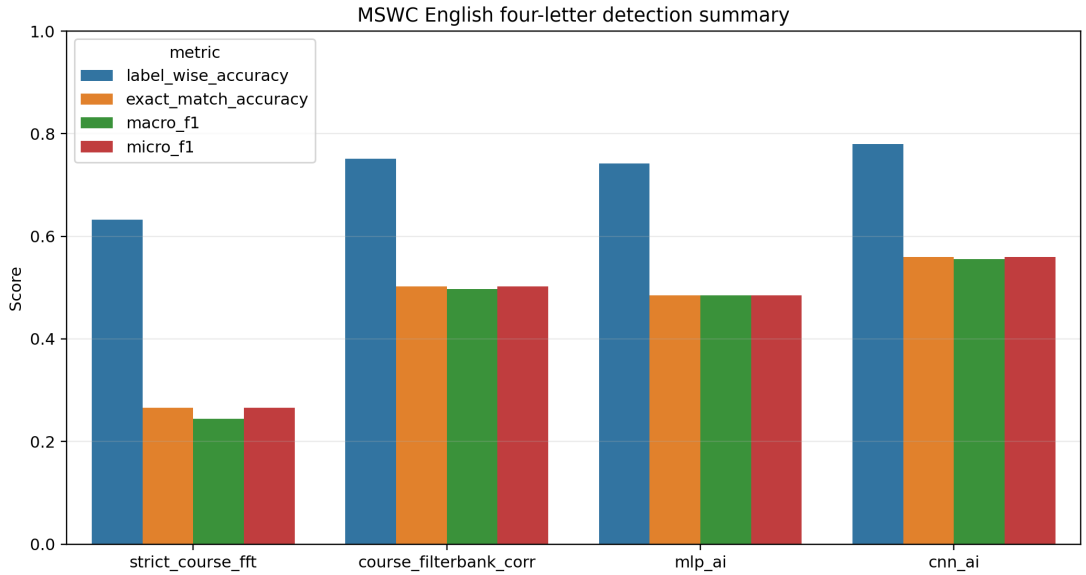

图 13: 全部方法的总体指标汇总。

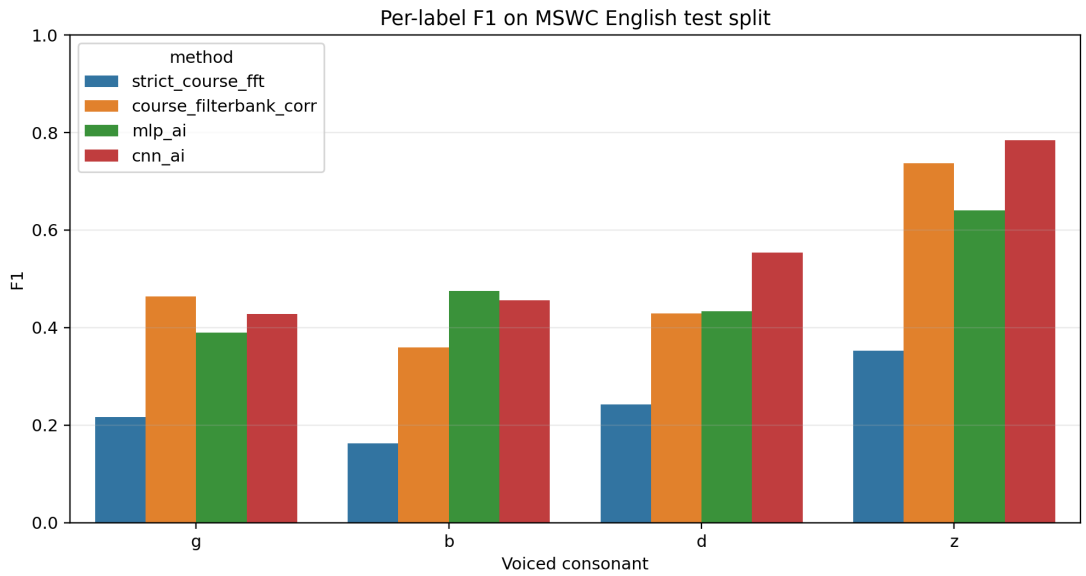

图 14: 全部方法在四个标签上的 F1 对比。

这几张图放在后面，是为了把 AI 重做版和神经网络对照的角色分开。前者回答如何重做频谱检测，MLP/CNN 回答常见学习型模型能达到什么分数。对本文来说，真正的收获不是 CNN 有没有赢，而是课堂频谱模板、AI 重做版和神经网络模型之间的边界已经分清楚。

8 讨论与局限

四个方法的结果呈现出清楚的层次。严格课内版 `strict_course_fft` 的 exact-match 只有 0.265，macro-F1 为 0.244，接近四分类随机水平；它的意义主要是把“分帧、FFT、局部块、归

一化相关”这条课堂链路跑通，而不是提供最强检测器。中间案例也能解释这一点：`get`、`boy` 等样本的四个 FFT 相关分数常常非常接近，说明最大能量块和单边幅度谱模板不足以稳定区分 /g/、/b/、/d/ 这类短促爆破音。

`course_filterbank_corr` 作为 AI 重做版后，exact-match 提升到 0.503，macro-F1 提升到 0.497。这个提升不是来自黑盒分类器，而是来自更合理的中间表示：log-mel 降维让谱形更平滑，onset-centered 局部窗减少了整词元音的干扰，正负模板差分压低了类别共享能量，自相关补充了持续摩擦和短促爆破之间的时间结构。分标签结果也符合这个解释：/z/ 的 F1 达到 0.737，因为它的摩擦段长而稳定；/b/ 只有 0.359，说明弱 burst 和后接元音变化仍然会让它与 /g/、/d/ 混在一起。

MLP 和 CNN 的作用是检查学习型模型能否进一步超过 AI 重做版。MLP 的 exact-match 为 0.485，低于 `course_filterbank_corr`，说明整词 MFCC 统计虽然稳定，但会把词尾元音和说话人差异一起平均进去。CNN 的 exact-match 达到 0.559，是当前最高；它在 /d/ 和 /z/ 上明显更强，说明扩大到 300 个词、6796 条语音后，卷积模型确实能从整张 log-mel 谱图里学到一部分局部模式。不过 epoch 消融也显示，dev macro-F1 最高的 30/40 epoch 设置并没有带来最高测试准确率，最终 25 epoch 更好，因此 CNN 的优势仍然带有训练方差和数据划分依赖。

因此，本文不能只按最高分排序。严格课内版最弱，但最贴近课程工具；AI 重做版不是最高分，却最能说明“改进频谱描述和检测结构”为什么有效；CNN 分数最高，但可解释性最弱。这个关系也提醒我们，label-wise accuracy 在一热四分类下会被大量真阴性抬高，真正应该主要看 exact-match、macro-F1 和分标签 F1。

这套方案仍有几个限制：

- 语音输入仍然是整词级音频，不是人工切好的 phone segment，所以严格课内版只能靠滑窗搜索。
- /g/、/b/、/d/ 的 burst 很短，对齐误差一大，模板证据就容易被后续元音吞掉。
- 当前 AI 重做版仍是模板法，没有做 phone-level alignment，也没有显式建模说话人和录音通道差异。
- 当前 CNN 只是轻量对照，没有加入数据增强、预训练语音模型或强制对齐，因此不能代表深度语音模型的上限。

9 结论

本文完成了 Topic 2 的重构，核心结论如下：

- 新数据集把任务收紧到了首浊辅音检测，当前主线使用每类 75 个词，共 300 个词、6796 条语音，标签边界比旧版清楚得多；
- 严格课内版可以只用短时 FFT 幅度谱和归一化相关完成完整检测链路；在当前数据集上，dev 选出 5 帧块，再用 train+dev 重估模板后，exact-match 为 0.265；
- AI 重做版 `course_filterbank_corr` 通过 log-mel 词首局部窗、正负模板差分和自相关线索把 exact-match 提升到 0.503；

- MLP 的 exact-match 为 0.485，CNN 为 0.559。扩大词表后 CNN 成为最高分方法，但模板法仍然提供了更清楚的声学解释；
- /z/ 最容易，这和持续摩擦能量更长、更稳定一致；/g/、/b/、/d/ 的短促爆破更依赖对齐，因此仍是主要错误来源。

A 算法结构与伪代码

本附录把正文中的四个实现整理成可复现的结构。所有方法都使用相同的输入设置：音频统一为 16 kHz、1 s 单声道 WAV，标签集合为 $C = \{g, b, d, z\}$，train/dev/test 分别只承担训练、调参和最终测试职责。

A.1 `strict_course_fft`

模型与假设：每个首浊辅音可以由一个短时 FFT 幅度谱原型表示；最大能量块近似包含词首辅音的主要局部证据；归一化相关可以削弱音量差异。

伪代码：

1. 对每条训练音频做 20 ms 分帧、10 ms 帧移和 512 点 FFT。
2. 对每个候选 M 帧块计算归一化幅度谱描述子 $P_i^{(r)}$。
3. 在正样本中选最大能量块，得到 $P_i^{(\star)}$。
4. 对每个类别 c，平均同类 $P_i^{(\star)}$ 并归一化，得到模板 T_c。
5. 在 dev 集上从 $M \in \{3, 4, 5, 6\}$ 选择 exact-match 最好的块长。
6. 用 train+dev 按选定块长重估模板。
7. 测试时滑动全部候选块，计算 $s_{i,c} = \max_r \cos(P_i^{(r)}, T_c)$。
8. 输出 $\hat{c}_i = \arg\max_c s_{i,c}$。

A.2 `course_filterbank_corr`

模型与假设：词首附近的 log-mel 局部窗比整词平均谱更可靠；正负模板差分能减少类别间共享能量的干扰；能量包络自相关能补充持续摩擦和短促爆破之间的时间结构差异。

伪代码：

1. 对音频做 25 ms 分帧、10 ms 帧移，计算 40 维 log-mel spectrogram。
2. 由帧能量的平滑曲线估计 onset o_i。
3. 取 $\Delta \in \{-2, 0, 2\}$ 三个候选偏移，得到 16 帧局部窗。
4. 对局部窗切成 3 段，拼接原始段均值和去基线后的段均值，得到 $\phi_i^{(\Delta)}$。
5. 对局部窗能量包络计算 24 阶归一化自相关，得到 $a_i^{(\Delta)}$。
6. 对每个类别 c，在 train 集上分别平均正样本和负样本，得到 P_c^+、P_c^-、A_c^+、A_c^-。
7. 对每个候选偏移计算 $0.65[\cos(\phi, P_c^+) - \cos(\phi, P_c^-)] + 0.35[\cos(a, A_c^+) - \cos(a, A_c^-)]$。
8. 对三个偏移取最大值作为 $s_{i,c}$，最后输出 $\arg\max_c s_{i,c}$。

A.3 `mlp_ai`

模型与假设： MFCC 均值、方差、一阶差分统计和粗频带能量已经能概括整词里的主要声学差异；两层非线性网络可以学习这些统计特征到四个标签的映射。

结构：

$$62 \to 128 \to 64 \to 4.$$

隐藏层激活函数为 ReLU，输出层用 sigmoid 概率。训练使用 Adam、early stopping 和 L_2 正则，dev 集用于阈值选择，测试时按 $\arg\max$ 解码。

伪代码：

1. 从每条音频提取 MFCC 统计、delta MFCC 统计和 10 维 band-energy。
2. 用 train 集均值和方差标准化特征。
3. 训练两层 MLP，优化四个标签的 binary cross entropy。
4. 在 dev 集上选择每个标签的阈值，同时保留 exclusive decoding。
5. 在 test 集输出四个标签概率，取最大概率类别作为预测。

A.4 `cnn_ai`

模型与假设： log-mel spectrogram 可以看成时间频率图像，卷积层可以从整词谱图中自动学习局部声学模式。这个假设不要求人工指定词首窗口，但需要足够数据让模型学会忽略无关位置。

结构：

$$\begin{aligned}
&\mathrm{Conv}_{24} \to \mathrm{BN} \to \mathrm{ReLU} \to \mathrm{Pool} \\
&\to \mathrm{Conv}_{48} \to \mathrm{BN} \to \mathrm{ReLU} \to \mathrm{Pool} \\
&\to \mathrm{Conv}_{96} \to \mathrm{BN} \to \mathrm{ReLU} \to \mathrm{GlobalAvgPool} \\
&\to \mathrm{FC}_{96} \to \mathrm{Dropout} \to \mathrm{FC}_{4}.
\end{aligned}$$

伪代码：

1. 提取整词 log-mel spectrogram，并用 train 集全局均值和方差标准化。
2. 将谱图作为单通道输入送入三层卷积网络。
3. 使用带正样本权重的 BCEWithLogitsLoss 训练，优化器为 AdamW。
4. 每个 epoch 后在 dev 集计算 macro-F1，并保留 dev macro-F1 最高的模型。
5. 在 test 集输出 sigmoid 概率，按 $\arg\max$ 得到最终类别。

参考文献

[1] S. Davis and P. Mermelstein, “Comparison of Parametric Representations for Monosyllabic Word Recognition in Continuously Spoken Sentences,” *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 1980. https://doi.org/10.1109/TASSP.1980.1163420.

[2] L. R. Rabiner, "A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition," *Proceedings of the IEEE*, 1989. https://doi.org/10.1109/5.18626.

[3] N. J. Wilkinson and M. J. Russell, "Improved Phone Recognition on TIMIT Using Formant Frequency Data and Confidence Measures," in *Proc. ICSLP 2002*. https://www.isca-archive.org/icslp_2002/wilkinson02_icslp.html.

[4] M. Mazumder *et al.*, "Multilingual Spoken Words Corpus," in *Proc. NeurIPS Datasets and Benchmarks*, 2021. https://datasets-benchmarks-proceedings.neurips.cc/paper/2021/hash/fe131d7f5a6b38b23cc967316c13dae2-Abstract-round2.html.

[5] G. Chen, C. Parada, and G. Heigold, "Small-Footprint Keyword Spotting using Deep Neural Networks," in *Proc. ICASSP 2014*. https://research.google/pubs/small-footprint-keyword-spotting-using-deep-neural-networks/.

[6] T. N. Sainath and C. Parada, "Convolutional Neural Networks for Small-Footprint Keyword Spotting," in *Proc. Interspeech 2015*. https://research.google/pubs/convolutional-neural-networks-for-small-footprint-keyword-spotting/.

[7] P. Warden, "Speech Commands: A Dataset for Limited-Vocabulary Speech Recognition," arXiv:1804.03209, 2018. https://doi.org/10.48550/arXiv.1804.03209.

[8] M. Berg *et al.*, "Keyword Transformer: A Self-Attention Model for Keyword Spotting," arXiv:2104.00769, 2021.

[9] A. Baevski *et al.*, "wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations," arXiv:2006.11477, 2020. https://doi.org/10.48550/arXiv.2006.11477.

[10] W.-N. Hsu *et al.*, "HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units," arXiv:2106.07447, 2021.

[11] S. Chen *et al.*, "WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing," *IEEE Journal of Selected Topics in Signal Processing*, 2022. https://arxiv.org/abs/2110.13900.

[12] C. Gao *et al.*, "Self-Supervised Speech Representation Learning for Keyword-Spotting with Light-Weight Transformers," arXiv:2303.04255, 2023. https://arxiv.org/abs/2303.04255.

[13] D. Kim and J. Hwang, "Fully End-to-end Streaming Open-vocabulary Keyword Spotting with W-CTC Forced Alignment," in *Proc. Interspeech 2025*. https://www.isca-archive.org/interspeech_2025/kim25d_interspeech.html.