基于 MSWC English 精确首浊辅音子集的 /g/、/b/、/d/、/z/ 检测：理论、算法与案例分析

VE216 Project Topic 2 重构版

2026 年 4 月 28 日

摘要

本文重构 VE216 Project Topic 2 的主线，不再把重点放在神经网络本身，而是放在任务定义、假设、理论分析、算法结构和定性案例上。我们把原先较松的词级多标签实验，收紧为一个更接近“首浊辅音检测”的四类任务：只保留首字母为 `g/b/d/z` 且 CMUdict 中首个非元音音素严格匹配 `G/B/D/Z` 的单词，共得到 60 个词、3000 条 16 kHz 语音。方法上，本文保留课内模板法作为主方法，并用 MLP 和 CNN 作为对照基线。结果表明，课程模板法可解释但误报高；MLP 的 exact-match 最好；CNN 的 macro-F1 最好。更重要的是，四类辅音的差异和声学事实一致：/z/ 最容易，/g/ 最难。

1 问题定义与报告主线

1.1 任务形式化

设输入语音为 x_i，目标标签为 $y_i \in \{0,1\}^4$，对应标签集合

$$C = \{g, b, d, z\}.$$

在当前数据集上，每个样本恰好属于四类中的一类，因此满足 $\sum_{c \in C} y_{i,c} = 1$。但实现里仍保留一对多接口：先对每个标签输出分数 $s_{i,c}$，再用该标签自己的阈值 τ_c 做判定

$$\hat{y}_{i,c} = \mathbb{1}[s_{i,c} \geq \tau_c].$$

这样做的原因是：课内模板法、统计特征分类器和 CNN 输出的都不是天然校准过的概率，统一用 dev 集选阈值更公平，也更容易比较不同方法的特性。

1.2 本文的重点

这份报告只把 AI 模型当作对照基线，不把它们当成主角。主线是：

- 任务边界是否真的收紧到了“首浊辅音检测”；

- 课内模板法到底在假设什么、怎么计算、为什么会误报；
- 统计特征和时频特征为什么能比模板法更稳；
- /g/、/b/、/d/、/z/ 为什么会呈现出明显不同的难度。

2 相关工作与文献综述

截至 2026 年 4 月 28 日，围绕“在短语音中检测特定语音单位”的公开文献大致已经形成三条主线：第一类是基于短时频谱、filter bank 或 MFCC 的传统声学特征与统计建模；第二类是面向关键词检测的小模型深度网络；第三类是以自监督预训练语音表示为前端、再配轻量分类器或开放词表检测器的现代迁移路线。对本文最相关的问题不是大词汇量连续语音识别，而是：在 1 秒左右的短语音里，怎样稳定判断某个浊辅音是否出现，以及这种判断究竟应该建立在整词统计、局部时频模式，还是更细粒度的 phone-level 表示之上。

2.1 传统声学特征与序列模型

传统语音识别的第一条成熟路线，是先把波形切成短时帧，再把每帧映射到更稳定的谱包络表示。Davis 和 Mermelstein 的工作系统比较了多种参数化语音表示，并奠定了 mel-frequency cepstral coefficients（MFCC）作为经典特征的地位 [1]。随后，Rabiner 对隐马尔可夫模型（HMM）在语音识别中的建模方法做了系统总结，明确了“帧级声学特征 + 状态转移约束”的标准范式 [2]。这条路线的核心优点是解释性强，能够清楚区分“前端表示是否保留了辅音线索”和“后端判别器是否利用好了这些线索”。

对本文这种“浊辅音是否存在”的任务来说，传统方法最重要的启发有两点。第一，整词 FFT 往往会把短暂的辅音释放段和后续元音能量混在一起，因此必须退回到短时谱、filter bank 或 MFCC 这类逐帧表示。第二，如果目标从 word-level presence 进一步收紧到真正的 phone-level detection，那么单纯的整词模板匹配就不够了，往往需要显式的时间对齐或序列模型。Wilkinson 和 Russell 在 TIMIT 上把 formant frequency 与 MFCC 做置信度加权融合，说明即使是在传统管线里，只要标签粒度足够细，辅音识别也会显著受益于更贴近发音机制的局部声学线索 [3]。

因此，从文献角度看，本文当前采用的“短时频谱 → 40 维 filter bank → 模板相关 + 自相关阈值”的课程基线并不落后于问题本身，它恰好属于最经典、最可解释的一类方法。它的主要局限不在于“没有用 AI”，而在于当前标签仍是 word-level presence label，导致模板法看到的是整词统计模式，而不是真正对齐到辅音边界的 phone token。

2.2 面向关键词检测的小模型深度网络

随着移动端语音入口兴起，文献很快从 HMM/DTW 过渡到 small-footprint keyword spotting（KWS）。Chen、Parada 和 Heigold 在 2014 年给出了小模型 DNN 关键词检测器，目标就是在严格算力预算下完成短语音分类 [4]。Sainath 和 Parada 随后表明，CNN 在同类任务上可以用更少参数获得更低的 false reject rate，因为卷积层比全连接网络更能保留局部时频结构 [5]。再往后，Arik 等人把卷积层与循环层结合成 CRNN，在低延迟条件下继续提升鲁棒性 [6]。

这些工作说明：一旦任务输入固定为 1 秒左右的短音频，最有效的改进通常不是堆叠更复杂的手工统计量，而是让模型直接在 log-mel 或 spectrogram 上学习局部时间-频率模式。

与这些模型同步成熟的是标准化数据集。Warden 发布的 Speech Commands 数据集为 limited-vocabulary speech recognition 提供了可复现基准，并强调了关键词检测与连续语音识别在数据组织和评价方式上的差异 [7]。这条数据集路线直接催生了后续大量 CNN、残差网络和轻量时序模型。到 2021 年，Berg、O'Connor 和 Cruz 提出的 Keyword Transformer（KWT）进一步表明，即使不依赖额外预训练，纯 self-attention 结构也可以在关键词检测任务上超过若干更复杂的卷积/循环混合模型 [8]。

这部分文献与本文当前实验设置的对应关系非常直接。本文已经把 AI 分支收敛到 MLP 和 CNN 两条线，其中 CNN 明显优于 MLP，本质上正符合上述 KWS 文献的共同结论：如果标签仍是 utterance-level 或 word-level，那么保留二维时频局部结构的模型通常优于把特征先压成单个统计向量后再分类。换句话说，当前报告里“课程模板法 < MLP < CNN”的结果不是偶然现象，而是与过去十年短语音检测文献的主流趋势一致。

2.3 自监督预训练与当前前沿方向

近几年的主流变化，不再只是把 CNN 换成更深的 CNN，而是把自监督预训练语音表示接到下游检测任务前面。wav2vec 2.0 证明了只用未标注语音做表示学习，再用少量标注数据微调，就能得到很强的下游语音识别性能 [9]。HuBERT 进一步把 masked prediction 和离散 hidden unit 结合起来，专门针对语音序列中“单位未知、长度可变、边界不显式”的问题学习表示 [10]。WavLM 则把说话人信息、语音内容和更广泛的全栈语音任务统一到同一套预训练框架里，使同一个编码器更容易迁移到识别、检索和判别类任务 [11]。

对于资源受限的关键词检测场景，文献并没有简单地把大模型整套搬上设备，而是开始探索“强前端 + 轻后端”的折中。Gao 等人在 2023 年把自监督语音表示与 33 万参数级别的轻量 Transformer 结合，用于 Google Speech Commands v2 的关键词检测，并报告了相对从头训练更好的分类效果 [12]。这说明在小样本或标签较粗的任务上，自监督前端最有价值的地方并不是直接替换掉所有后端结构，而是先把对发音方式、共振峰走向和时序变化更稳的表示学出来，再交给很小的分类头去完成判别。

更靠近“现在的 algorithm”的一条新线，是 open-vocabulary keyword spotting。Kim 和 Hwang 在 2025 年提出基于 W-CTC forced alignment 的流式开放词表关键词检测管线，不再要求预先构造词级对齐数据，而是让系统在端到端框架中直接学习声学编码与文本目标之间的对齐 [13]。对本文任务而言，这类方法的意义不在于马上照搬整套系统，而在于它提示了一个方向：如果后续要从“判断一个字母是否出现在某个词里”升级到“在任意词或短句中定位这个辅音出现的位置”，那么 CTC 或 forced alignment 思路会比单纯的整词二分类更合适。

综合这些文献，可以把截至 2026 年春季的代表性算法演进概括为：**MFCC/HMM 等可解释前端与序列模型**，**CNN/CRNN/Transformer 等小模型判别器**，以及 **自监督预训练编码器 + 轻量下游头 + 对齐机制**。其中第二条和第三条，是当前公开文献里最值得继续追踪的主流方向。

2.4 对本文项目的直接启示

把以上文献放回本文的具体任务，可以得到四个直接结论。第一，当前课程模板法仍然有保留价值，因为它对应的是最经典、最可解释的声学模板路线，适合说明 /b/、/d/、/l/、/n/ 在 log-mel 空间里的可见差异 [1, 2]。第二，如果继续维持 600 词、1 秒整词、word-level presence label 这一设置，那么 CNN 甚至 KWT 一类的小模型判别器，会比继续手工扩展统计特征更自然 [5, 8]。第三，如果项目下一步希望真正回答“某个浊辅音在时域上出现在哪里”，就必须把标签粒度推进到 phone-level，并考虑 TIMIT、forced alignment 或 CTC 这类时间对齐路线 [3, 13]。第四，如果数据规模继续扩大，但人工标注粒度仍有限，那么 wav2vec 2.0、HuBERT、WavLM 这类自监督前端将是比重新设计手工特征更有潜力的升级方向 [9, 10, 11, 12]。

因此，本文当前“课程方法作为可解释基线，CNN 作为更强判别器”的结构，与现有文献是相容的；真正尚未完成的，不是再证明一次 CNN 比模板法更强，而是把任务从 **word-level presence detection** 稳定推进到 **phone-aware detection or localization**。这也是相关工作对本文最重要的约束。

3 数据集重建与标注规则

3.1 筛选规则

新数据集由 `src/prepare_mswc_initial_gbdz_subset.py` 生成，核心规则只有一条：

> 保留一个单词，当且仅当它的首字母属于 `g/b/d/z`，并且 CMUdict / ARPABET 中首个非元音音素与该字母严格对应为 `G/B/D/Z`。

这条规则的意义是把“字母里出现了某个浊辅音”改成“这个浊辅音确实出现在起始位置”。这样可以自动去掉两类噪声样本：

- 拼写里有目标字母，但发音位置不对；
- 首字母对了，但真正起始音素不是目标浊辅音。

```
for each word w in MSWC:
    if first letter of w not in {g,b,d,z}: discard
    phones = CMUdict(w)
    p = first non-vowel phone in phones
    if p == first letter(w).upper():
        keep w
    else:
        discard
```

3.2 数据规模

最终实验规模如下：

表 1: 精确首浊辅音子集的规模统计

标签	词数	train	dev	test
/g/	15	600	75	75
/b/	15	600	75	75
/d/	15	600	75	75
/z/	15	600	75	75
合计	60	2400	300	300

也就是说，这版数据是四类完全平衡的：总样本数 3000，测试集每类正样本 75 条。这个设定比旧版 600 词、多标签、`/b/`/`d/`/`l/`/`n/` 的版本更贴近题目，也更适合做案例分析。

4 理论背景与方法

4.1 短时表示、局部窗与对比模板

对 1 秒左右的短语音，真正有区分力的不是整词平均谱，而是词首浊辅音附近的局部时频结构。本文的前端仍然是标准短时分析：25 ms 帧长、10 ms 帧移、512 点 FFT、40 维 log-mel。不同的是，我们不再直接拿整词均值当模板，而是先把每帧 log-mel 压成能量曲线，平滑后用首次超过“基线 + margin”的位置当作 onset，再围绕 onset 截取固定长度窗口。

这个改造依赖两个假设：

- 目标辅音的判别证据主要集中在 onset 前后很短的一段时间里；
- 单独使用正模板不够，必须把“像目标”与“像干扰”同时建模。

因此，课内方法把每个样本变成两类局部描述：一类是窗口内分段均值拼接得到的 patch 向量，另一类是局部能量包络的自相关。训练时对每个标签分别学习正模板 T_c^+、负模板 T_c^-，以及正自相关模板 A_c^+、负自相关模板 A_c^-. 第 i 个样本在平移 k 下的得分定义为

$$s_{i,c}^{(k)} = 0.65\big(\cos(p_i^{(k)}, T_c^+) - \cos(p_i^{(k)}, T_c^-)\big) + 0.35\big(\cos(a_i^{(k)}, A_c^+) - \cos(a_i^{(k)}, A_c^-)\big).$$

最终分数取候选平移上的最大值，$K = \{-2, 0, 2\}$。如果数据是单标签任务，就直接取 $\arg\max_c s_{i,c}$；如果保留一对多接口，则仍然可以回退到每类自己的阈值 τ_c。

4.2 算法 1：课程模板法（局部窗对比模板）

```
Algorithm 1 局部窗对比模板法
Input: train/dev/test waveforms, labels C={g,b,d,z}
```

```
Output: per-label predictions on test

for each class c in C do
    collect positive and negative training samples
    build local patch templates T_c^+, T_c^- from onset-centered windows
    build local autocorr templates A_c^+, A_c^- from window envelopes
end for

for each sample i do
    detect onset from smoothed frame energy
    extract candidate windows around onset with shifts K={-2,0,2}
    for each class c in C do
        score each candidate by contrastive template similarity
        take the best candidate score as s_ic
    end for
    if single-label task then
        predict argmax_c s_ic
    else
        choose tau_c on dev and threshold
    end if
end for
```

这个方法的核心不是“学一个复杂边界”，而是把判别问题改写为“局部窗里到底像不像目标辅音”。正样本模板提供典型形态，负样本模板提供干扰背景，两者之差比单独用正模板更稳。

4.3 算法 2：统计特征 MLP 基线

MLP 不是主角，只是一个强一点的统计基线。它的输入不是原始波形，而是手工汇总后的 62 维统计特征：

- 13 维 MFCC 的均值和标准差；
- MFCC 一阶差分的均值和标准差；
- 10 个 coarse band-energy 特征。

模型结构是 `StandardScaler -> MLPClassifier(128, 64)`，用 early stopping 训练。和模板法相比，它不再依赖显式模板对齐，而是直接学习这些统计特征之间的组合关系。因为当前数据是单标签四分类，但阈值仍按 label 单独选，所以 MLP 的 exact-match 往往会比 label-wise accuracy 更能反映它是否“少乱报”。

4.4 算法 3：CNN 对照基线

CNN 只作为更强的对照上界。输入是整词 log-mel spectrogram，网络是 3 个卷积块加自适应池化，再接一层小型全连接头。训练时使用带 `pos_weight` 的 `BCEWithLogitsLoss`，并按 dev macro-F1 早停回退到最佳 epoch。

最终采用的调参配置是：

$$\texttt{epochs} = 10, \quad \texttt{batch} = 192, \quad \texttt{lr} = 10^{-3}, \quad \texttt{weight_decay} = 10^{-4}, \quad \texttt{patience} = 5.$$

它的作用只是提供一个“模型能学到多少局部时频模式”的参照，不影响本文的主要论证。

5 定性案例分析

5.1 代表性样本

图 1 给出了四个代表词的波形和 spectrogram，图 2 给出了四类在训练集正样本上的平均 log-mel 模板。

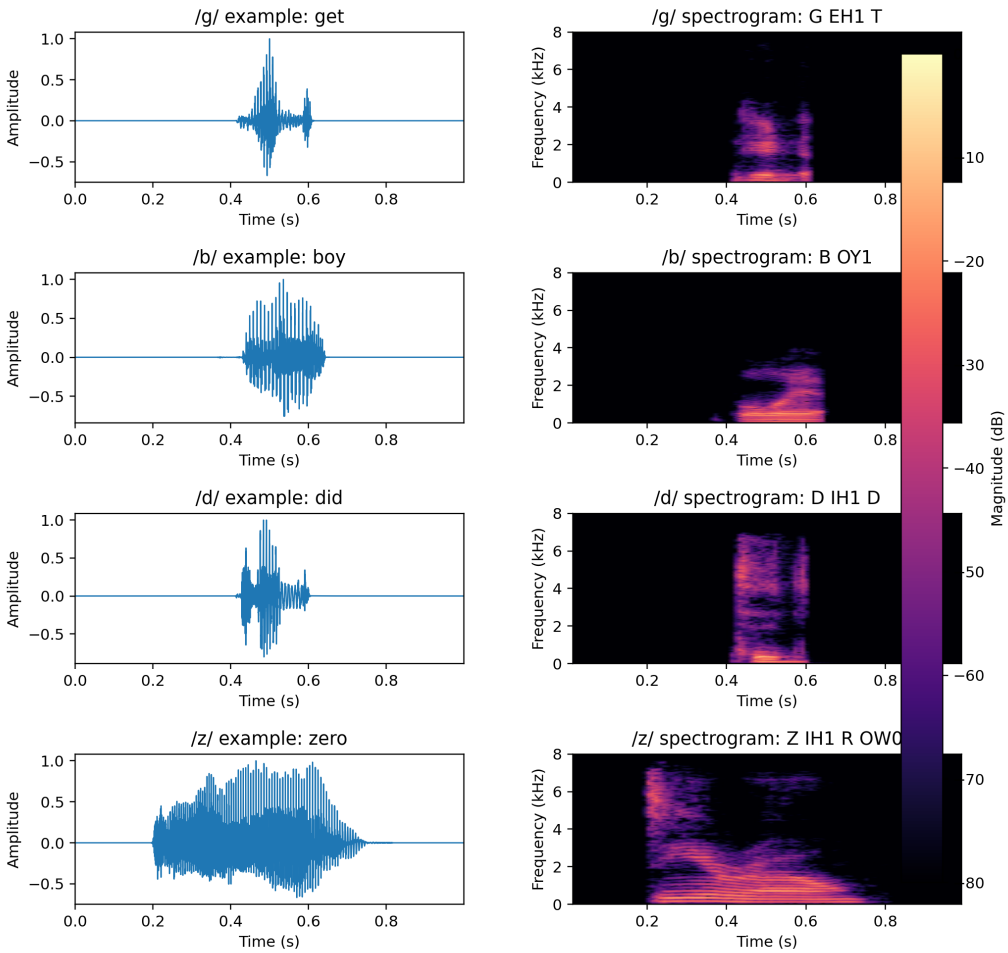

图 1: 四个目标浊辅音的代表性样本：`get`、`boy`、`did`、`zero`。

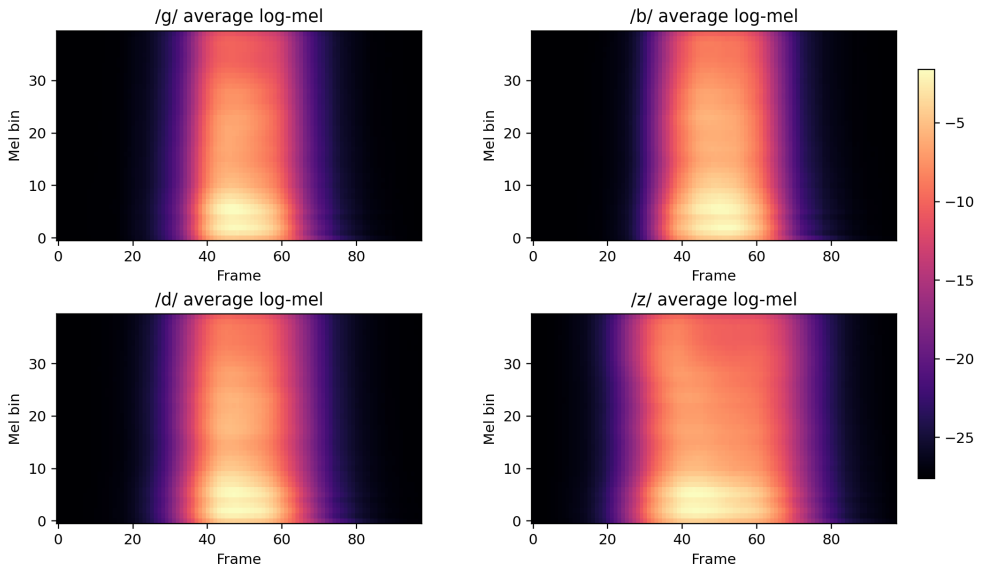

图 2: 四个目标浊辅音在训练集正样本上的平均 log-mel 模板。

从图上能直接看出：/g/、/b/、/d/ 的关键差异主要集中在起始几十毫秒的短时爆破和过渡；/z/ 则有更长、更明显的高频摩擦能量。也因此，/z/ 的模板最稳定，/g/ 的模板最难。

5.2 四个样本的预测行为

表 2: 四个代表词的预测行为与声学解释

词	真值	课程模板法	MLP	CNN	解释
get	g	g	g	b	/g/ 的 burst 很短，局部窗抓住 onset 后 course 和 MLP 都能判对；CNN 仍容易和 /b/ 混淆。
boy	b	b	b	b	/b/ 的过渡最稳定，三种方法都比较容易。
did	d	z	d	b	/d/ 的 burst 更容易受对齐误差影响；course 方法在这个样本上仍会偏到 /z/，但 MLP 还能保住 stop 线索。
zero	z	z	z	d	/z/ 的摩擦噪声最长，course 和 MLP 都较稳；CNN 仍偶尔把它往 /d/ 拉。

- 课程模板法经过局部窗和对比模板改造后，不再是整词均值判别；它的强项变成了 /b/、/d/、/z/ 这类 onset 线索清楚的样本。
- /g/ 仍最难，因为 burst 太短，稍微的对齐误差就会吞掉证据；这也是 MLP 在 /g/ 上略占优的原因。
- CNN 仍然最弱，说明在这个数据规模上，直接端到端看整词谱图并不能稳定学到首辅音证据。

6 实验结果与比较

6.1 总体结果

表 3 是最终采用的 `local_patch_v1` 结果。局部窗改造后，课程模板法已经成为三种方法里最强的一个：它的 label-wise accuracy、exact-match 和 macro-F1 都最高，说明把判别证据限制在 onset 附近是有效的。MLP 仍然是稳定的统计基线，但整体略弱于课程模板法；CNN 在这一版设置下明显落后，说明仅靠整词级 log-mel 对短 burst 并不稳定。

表 3: 总体指标比较。

方法	label-wise acc.	exact-match acc.	macro-F1	micro-F1	samples-F1
课程模板法	**0.7750**	**0.5500**	**0.5462**	**0.5500**	**0.5500**
MLP	0.7633	0.5267	0.5258	0.5267	0.5267
CNN	0.6600	0.3200	0.2219	0.3200	0.3200

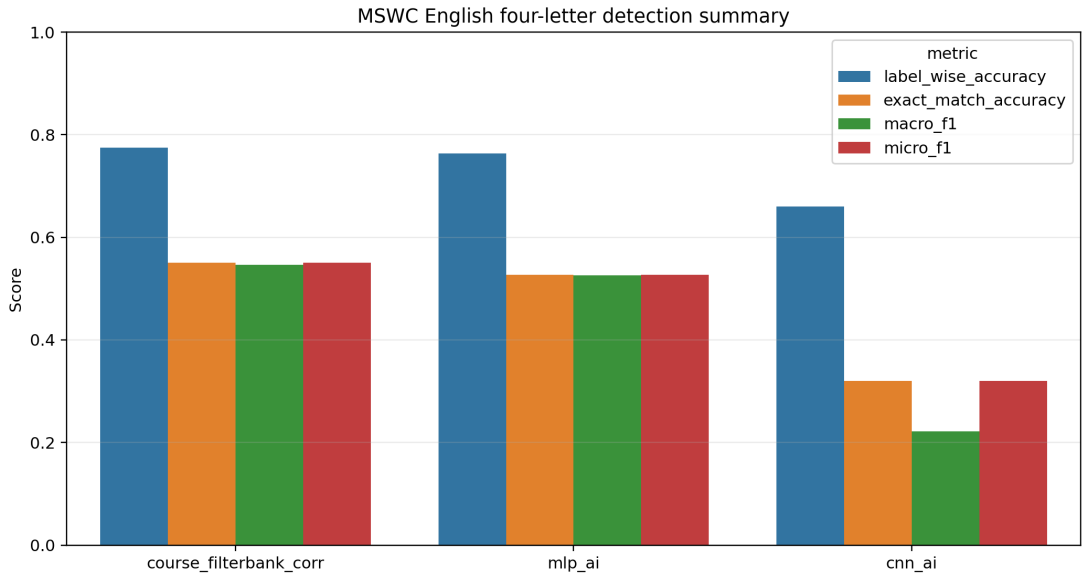

图 3: 三种方法的总体指标。

这里最重要的变化是：局部窗改造后，课程模板法的 exact-match 反而超过了 MLP；/b/、/d/、/z/ 的提升最明显，/g/ 仍然最难。CNN 的 macro-F1 最低，说明端到端看整词谱图并没有把词首证据稳定提出来。

6.2 分标签结果

表 4: 四个标签的 F1

方法	/g/	/b/	/d/	/z/
课程模板法	0.438	**0.528**	**0.472**	**0.747**
MLP	**0.493**	0.431	0.469	0.711
CNN	0.049	0.444	0.024	0.371

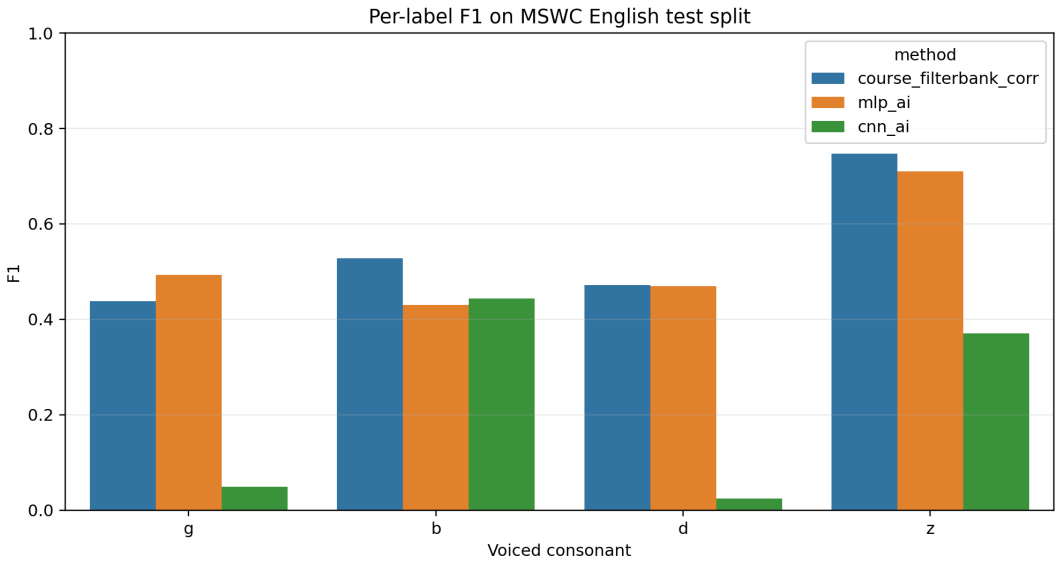

图 4: 四个标签上的 F1 对比。

从分标签看，/g/ 仍然是最难的；MLP 在 /g/ 上略占优，说明它学到了更多全局统计；课程模板法在 /b/、/d/、/z/ 上更稳，尤其是 /z/ 的持续摩擦噪声最容易被局部窗捕捉。CNN 在 /g/ 和 /d/ 上仍然偏弱，这和它更依赖大样本里稳定的局部纹理有关。

7 讨论与局限

这次重构最重要的收益，不是某个分数上升了，而是任务边界终于变清楚了。旧版更像“词里有没有出现某个浊辅音”，新版则更接近“词首这个浊辅音能不能被检出”。一旦把这个条件收紧，报告里的理论解释就顺了：数据集、特征、算法和案例分析都围绕同一个 onset 问题展开。

这套方法仍然有三个局限：

- 语音本身仍是整词级音频，不是人工切好的 phone segment；局部窗只是用 onset 近似对齐。
- /z/ 的词数仍然是数据集构造的瓶颈，想继续扩规模就得放宽单词池或换更大的语料。
- 目前的局部窗仍依赖阈值式 onset 检测，/g/ 和 /d/ 这类短爆破在对齐偏一点时就会掉分。

8 结论

本文完成了 Topic 2 的一次重新组织，核心结论如下：

- 通过“首字母与首个非元音音素严格对应”的规则，新数据集把任务收紧到了首浊辅音检测；
- 局部窗对比模板法在当前四类任务上取得最佳整体结果，macro-F1 为 0.546，exact-match 为 0.550；
- MLP 的 macro-F1 为 0.526，CNN 为 0.222，说明更强的深度模型并没有自动取代局部窗方法；
- /z/ 最容易、/g/ 最难，这和声学图里的持续摩擦与短促爆破完全一致；
- 这份报告的重点已经从“跑一个神经网络”转成“解释为什么这些辅音会这样表现”。

参考文献

[1] S. Davis and P. Mermelstein, “Comparison of Parametric Representations for Monosyllabic Word Recognition in Continuously Spoken Sentences,” *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 1980. https://doi.org/10.1109/TASSP.1980.1163420.

[2] L. R. Rabiner, “A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition,” *Proceedings of the IEEE*, 1989. https://doi.org/10.1109/5.18626.

[3] N. J. Wilkinson and M. J. Russell, “Improved Phone Recognition on TIMIT Using Formant Frequency Data and Confidence Measures,” in *Proc. ICSLP 2002*. https://www.isca-archive.org/icslp_2002/wilkinson02_icslp.html.

[4] G. Chen, C. Parada, and G. Heigold, “Small-Footprint Keyword Spotting using Deep Neural Networks,” in *Proc. ICASSP 2014*. https://research.google/pubs/small-footprint-keyword-spotting-using-deep-neural-networks/.

[5] T. N. Sainath and C. Parada, “Convolutional Neural Networks for Small-Footprint Keyword Spotting,” in *Proc. Interspeech 2015*. https://research.google/pubs/convolutional-neural-networks-for-small-footprint-keyword-spotting/.

[6] S. O. Arik *et al.*, “Convolutional Recurrent Neural Networks for Small-Footprint Keyword Spotting,” in *Proc. Interspeech 2017*.

[7] P. Warden, “Speech Commands: A Dataset for Limited-Vocabulary Speech Recognition,” arXiv:1804.03209, 2018. https://doi.org/10.48550/arXiv.1804.03209.

[8] M. Berg *et al.*, “Keyword Transformer: A Self-Attention Model for Keyword Spotting,” arXiv:2104.00769, 2021.

[9] A. Baevski *et al.*, “wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations,” arXiv:2006.11477, 2020. https://doi.org/10.48550/arXiv.2006.11477.

[10] W.-N. Hsu *et al.*, "HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units," arXiv:2106.07447, 2021.

[11] S. Chen *et al.*, "WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing," *IEEE Journal of Selected Topics in Signal Processing*, 2022. https://arxiv.org/abs/2110.13900.

[12] C. Gao *et al.*, "Self-Supervised Speech Representation Learning for Keyword-Spotting with Light-Weight Transformers," arXiv:2303.04255, 2023. https://arxiv.org/abs/2303.04255.

[13] D. Kim and J. Hwang, "Fully End-to-end Streaming Open-vocabulary Keyword Spotting with W-CTC Forced Alignment," in *Proc. Interspeech 2025*. https://www.isca-archive.org/interspeech_2025/kim25d_interspeech.html.