基于 MSWC English 精确首浊辅音子集的 /g/、/b/、/d/、/z/ 检测：课堂模板法、扩展模板法与案例分析

VE216 Project Topic 2 重构版

Heng Qiao

2026 年 4 月 29 日

摘要

本文把 VE216 Project Topic 2 重构为一个更清晰的首浊辅音检测任务。数据只保留首字母为 `g/b/d/z` 且首个非元音音素严格匹配 `G/B/D/Z` 的单词；在本地 MSWC English 中，/z/ 最多只有 75 个满足条件且有 train/dev/test 音频的词，因此最终取每类 75 个词，共 300 个词、6796 条语音。方法上，正文先讲严格课内版 `strict_course_fft`：短时分帧、FFT 幅度谱、最大能量块、归一化相关和滑窗最大值；再把 `course_filterbank_corr` 明确作为扩展模板法，用 log-mel、onset 定位、正负模板和自相关重做频谱检测；最后用 `mlp_ai` 和 `cnn_ai` 作神经网络对照。

1 问题定义、设置与评价指标

设第 i 条语音为 $x_i[n]$，采样率统一为 16 kHz，长度统一到 1 s。标签集合为

$$C = \{g, b, d, z\}, \qquad y_i \in \{0,1\}^{|C|}.$$

当前数据集是单标签四分类，每个样本只有一个首浊辅音标签。代码保留一对多接口，是为了让模板法、MLP 和 CNN 用同一套输出格式：每个方法先给出分数向量 $s_i \in \mathbb{R}^{|C|}$，再解码成预测标签 $\hat{y}_i$。由于当前样本都满足 $\sum_c y_{i,c} = 1$，正式评测时使用 exclusive decoding，也就是

$$\hat{c}_i = \arg\max_{c \in C} s_{i,c}, \qquad \hat{y}_{i,c} = \mathbf{1}[c = \hat{c}_i].$$

阈值仍然会在 dev 集上估计并导出，主要用于保留一对多接口；测试表里的结果按单标签四分类解码。

所有方法使用同一份 train/dev/test 划分。train 只用于估计模板或训练模型；dev 只用于选择超参数、阈值和早停；test 只在最后计算指标。本文没有人工切分 phone segment，所以所有方法都必须从整词音频里自己找到词首附近的证据。

1.1 本文使用的测试指标

记测试集大小为 N，标签数为 $K = |C|$。label-wise accuracy 按标签位逐一比较：

$$\mathrm{LabelAcc} = \frac{1}{NK}\sum_{i=1}^{N}\sum_{c\in C}\mathbf{1}[\hat{y}_{i,c} = y_{i,c}].$$

它等价于 1 减去 Hamming loss。这个指标会同时奖励真阳性和真阴性，所以在单标签任务里数值会高于 exact-match。

exact-match accuracy 要求整条样本的标签向量完全一致：

$$\mathrm{ExactMatch} = \frac{1}{N}\sum_{i=1}^{N}\mathbf{1}[\hat{y}_i = y_i].$$

在本文的一热标签设置下，它就是普通四分类准确率，也是最直接的主指标。

对每个标签 c，先定义

$$P_c = \frac{TP_c}{TP_c + FP_c}, \qquad R_c = \frac{TP_c}{TP_c + FN_c}, \qquad F1_c = \frac{2P_cR_c}{P_c + R_c}.$$

macro-F1 是四个标签 F1 的平均：

$$\mathrm{MacroF1} = \frac{1}{K}\sum_{c\in C}F1_c.$$

它不按样本数加权，适合观察 /g/、/b/、/d/、/z/ 是否有某一类被明显牺牲。

micro-F1 先把所有标签位的 TP、FP、FN 汇总，再计算 F1：

$$\mathrm{MicroF1} = \frac{2\sum_c TP_c}{2\sum_c TP_c + \sum_c FP_c + \sum_c FN_c}.$$

samples-F1 则先在每条样本上算 F1，再对样本取平均：

$$\mathrm{SamplesF1} = \frac{1}{N}\sum_{i=1}^{N}\frac{2|Y_i \cap \hat{Y}_i|}{|Y_i| + |\hat{Y}_i|}.$$

因为本文的真实标签和预测标签都恰好选一个类别，micro-F1、samples-F1 和 exact-match 会给出相同数值。报告仍保留这几个指标，是为了和代码的一对多评测接口一致。

这份报告的顺序是固定的。先讲严格课内版，因为它最接近课堂工具，也最适合说明题目本身；再讲扩展模板法，因为它用更强的频谱表示和局部检测重做了题目要求的前两步；最后再把 MLP/CNN 神经网络对照放到后面，不让分数表抢走主线。当前 `build/mswc_course_gbdz_75w_cap40_5_5` 目录保留的是整套实验结果，其中 `course_filterbank_corr` 是扩展模板法，不是严格课内版。正文里如果提到“课堂方法”，指的是 `strict_course_fft`。

2 相关工作与理论背景

本文关心的不是大词汇量识别，而是短语音里一个目标首辅音是否真的出现。这个问题更接近传统语音处理里的短时分析、局部谱形比较和模板匹配；数据上使用 MSWC 这种面向 keyword spotting 和 spoken term search 的词级语音语料 [4]。

2.1 短时分析与频谱表示

Davis 和 Mermelstein 早就说明，语音识别里最有用的前端不是整段波形本身，而是经过短时分帧后的参数化表示 [1]。做法很简单：把波形切成几十毫秒一帧，给每帧加窗，再做 Fourier transform，最后看这一小段时间里能量落在哪些频率上。这样得到的谱图，既保留了辅音释放、摩擦和元音过渡这些局部线索，也比原始波形稳定得多。

Rabiner 对 HMM 的综述则把这种帧级表示和序列建模连了起来 [2]。它的核心意思是，语音不是静态图片，真正有意义的是“某个短时结构在时间上怎么移动”。虽然本文没有上 HMM，但这个观点很重要，因为它提醒我们：如果目标只是在整词里检出词首辅音，先把搜索范围压到短时块，再比较局部谱形，通常比直接看整词平均特征更合适。

2.2 辅音线索为什么更依赖局部谱形

对 /g/、/b/、/d/、/z/ 这类首辅音来说，最关键的证据往往只出现在很短的一段起始区间。爆破音的释放段短、转移快，摩擦音则在高频段拖得更久；这些差异一旦被整词平均掉，信息就会变少。Wilkinson 和 Russell 在 TIMIT 上做 phone recognition 时，也体现出同一个结论：越接近发音边界的局部线索，越能帮助辅音判别 [3]。

因此，本文的主方法没有先上复杂模型，而是回到课堂里最直接的工具链：短时 FFT、局部频谱、归一化相关。这样做的好处不是“更先进”，而是把问题本身讲清楚。

2.3 本文为什么先用课堂方法

keyword spotting 里常见的学习型路线包括小型 DNN/CNN[5, 6]、Speech Commands 式有限词表评测 [7]、Transformer 与自监督语音表征 [8, 9, 10, 11, 12]，以及流式开放词表检测 [13]。本文仍先用课堂频谱模板定义主线，再用 `course_filterbank_corr` 做 AI redo，并把 MLP/CNN 作为神经网络对照。

3 数据集重建与标注规则

3.1 筛选规则

本文使用的子集由 `src/prepare_mswc_initial_gbdz_subset.py` 生成，规则很简单：

> 保留一个单词，当且仅当它的首字母属于 `g/b/d/z`，并且 CMUdict / ARPABET 中首个非元音音素与该字母严格对应为 `G/B/D/Z`。

这条规则的作用，是把“拼写里有目标字母”收紧成“这个目标辅音确实出现在起始位置”。这样一来，数据不再混入发音位置不对的样本，也不再把字母出现位置和实际发音边界混在一起。

先检查原始候选池后可以看到，100 个词/类在严格规则下做不到：只要求每个词至少有 1 条 train、1 条 dev、1 条 test 时，/g/、/b/、/d/ 分别有 957、2073、1932 个候选词，而 /z/ 只有 75 个。因此最终按 /z/ 的上限取每类 75 个词。为了避免只增加单个词的音频数量，脚本使用 `balanced-cap` 采样：每个词每个 split 至少保留 1 条音频，每词最多取 40/5/5 条，然后把四个标签在 train/dev/test 上截到同样的样本数。

3.2 数据规模

表 1: 精确首浊辅音子集的规模统计

标签	词数	train	dev	test
/g/	75	1311	194	194
/b/	75	1311	194	194
/d/	75	1311	194	194
/z/	75	1311	194	194
合计	300	5244	776	776

这个子集在标签词数和每个 split 的标签样本数上都是平衡的，测试集每类 194 条，总计 776 条。相比 60 词版本，它牺牲了固定每词样本数，但显著增加了词表覆盖，更接近“跨词判断首浊辅音”而不是记住少数高频词。

4 理论推导与两种模板方法

4.1 严格课内版：短时 FFT 模板

`strict_course_fft` 的模型假设很直接：首浊辅音的信息集中在词首附近的一个短时片段里，不同类别在局部幅度谱形状上有可区分的原型。录音音量、说话人和词尾元音会引入变化，所以方法只比较归一化后的局部谱形，不直接依赖整词能量。

设第 i 个样本的波形为 $x_i[n]$，帧长 $L = 20$ ms，帧移 $H = 10$ ms，FFT 点数 $N = 512$。第 m 帧的频谱写成

$$X_{i,m}[k] = \sum_{n=0}^{L-1} x_i[n + mH]w[n]e^{-j2\pi kn/N}, \qquad k = 0, \ldots, N-1,$$

其中 $w[n]$ 是 Hamming 窗。只保留单边幅度谱，并先对每帧除以该帧最大幅度。若一个候选块从第 r 帧开始、包含 M 帧，则块描述子为

$$P_i^{(r)}[k] = \frac{1}{M} \sum_{m=0}^{M-1} \frac{|X_{i,r+m}[k]|}{\max_\kappa |X_{i,r+m}[\kappa]|}, \qquad k = 0, \ldots, N/2.$$

最后对 $P_i^{(r)}$ 做 L_2 归一化。这个处理把幅度差异压下去，保留的是短时频谱轮廓。

模板由训练数据估计。对每个标签 c，先在每条正样本里找能量最大的 M 帧块，记为 $P_i^{(\star)}$；再取平均并归一化：

$$T_c = \frac{\sum_{i:y_i=c} P_i^{(\star)}}{\left\| \sum_{i:y_i=c} P_i^{(\star)} \right\|_2}.$$

当前实验先在 dev 集上从 $M \in \{3,4,5,6\}$ 中选择块长，扩大到 75 词/类后选中 $M=5$，再用 train+dev 的同类样本重估最终模板。这个过程只用分帧、FFT、平均和归一化相关，属于严格课内边界。

检测时，对测试样本的所有候选块做同样的描述，并计算

$$\rho_{i,c}^{(r)} = \frac{\langle P_i^{(r)}, T_c \rangle}{\|P_i^{(r)}\|_2 \|T_c\|_2}, \qquad s_{i,c} = \max_r \rho_{i,c}^{(r)}.$$

单标签四分类下，预测类别就是 $\arg\max_c s_{i,c}$。这条链路的伪代码放在附录算法 A.1。

图 1 展示了严格课内版当前使用的模板构造结果。左边是与类别均值最接近的代表性训练样本块，右边是对应标签的归一化均值模板曲线。

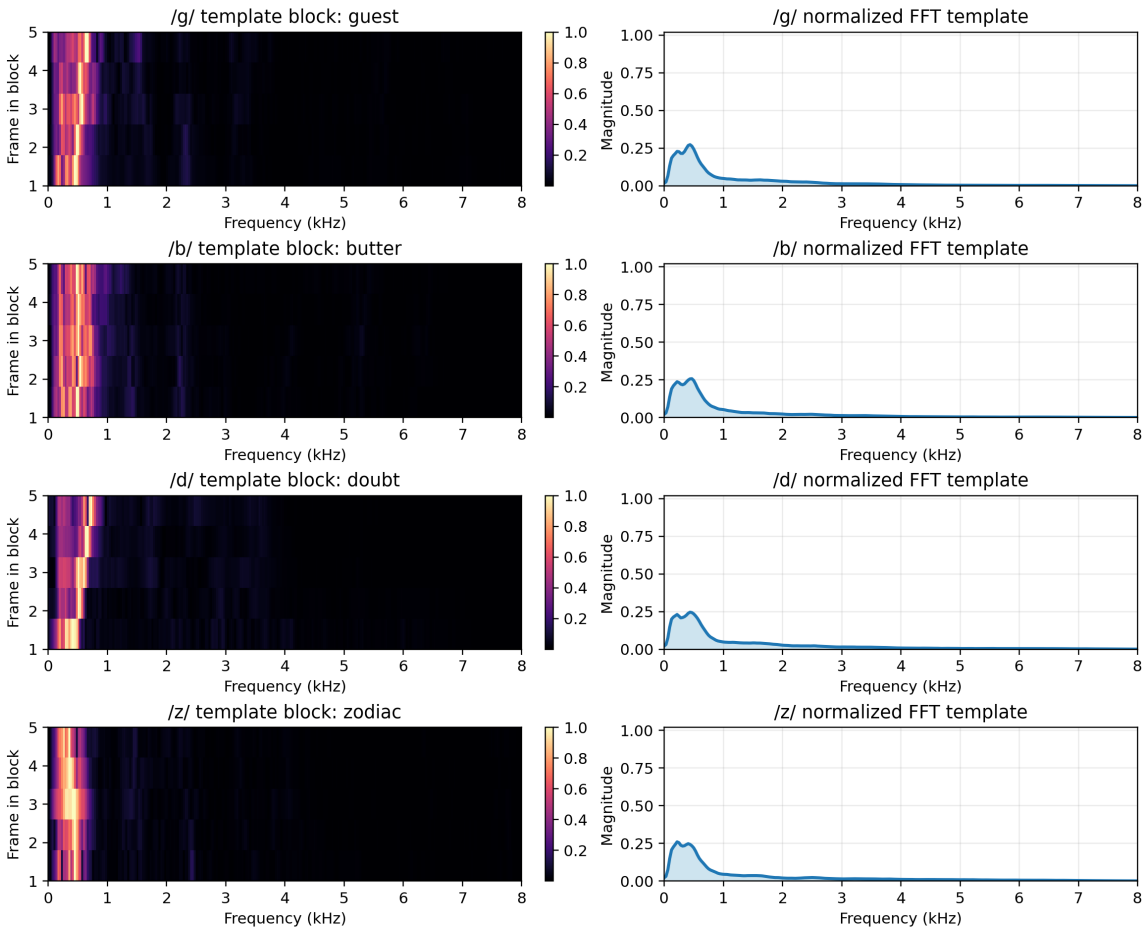

图 1: 严格课内版的模板构造：先取最大能量块，再对同类 train+dev 样本求均值模板。

图 2 给出了互相关搜索过程：上图是波形，中间是最匹配的 5 帧块，下图是四个模板在所有候选起点上的相关分数。它对应的就是先找局部证据，再看这段证据像哪一个模板。

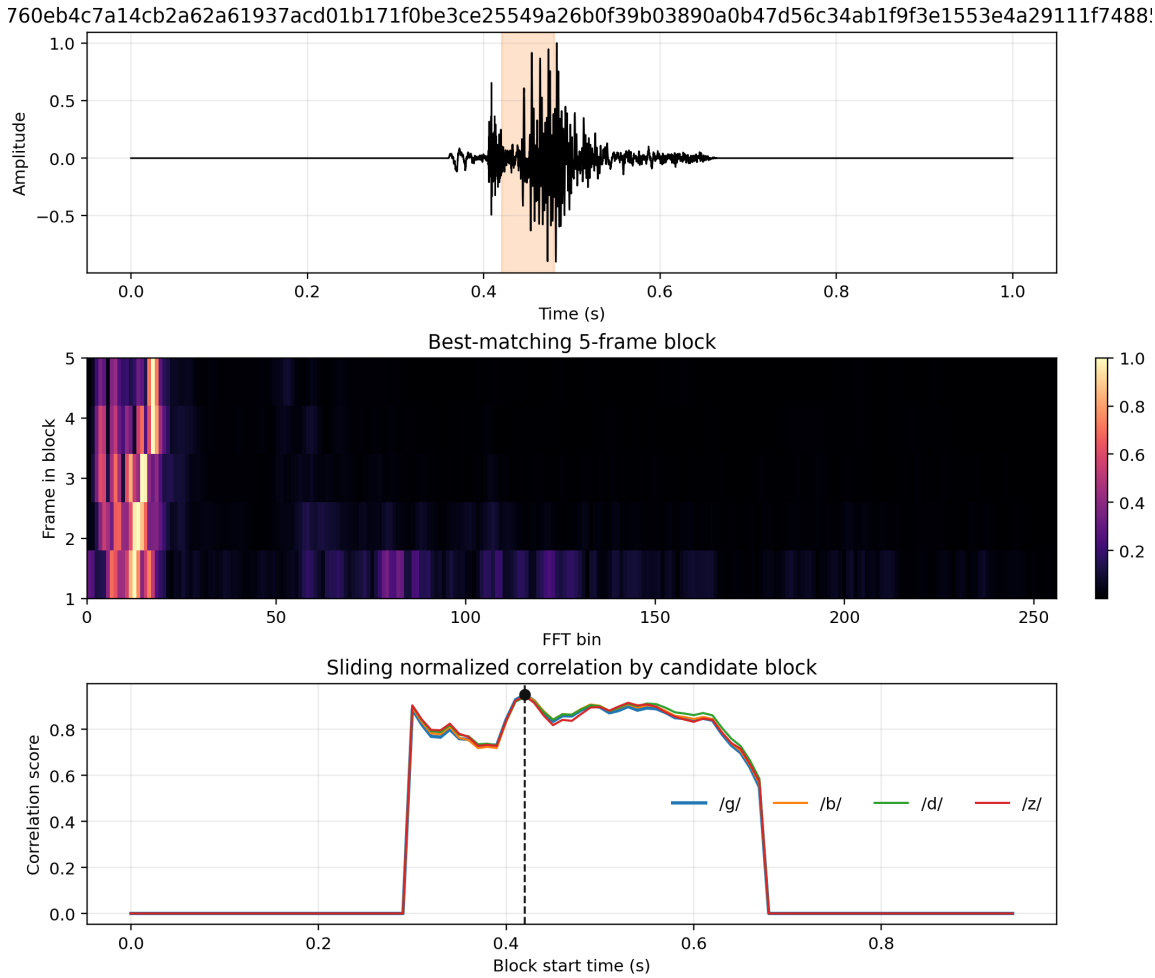

图 2: 严格课内版的互相关搜索：先扫候选块，再取每个标签的最大相关分数。

4.2 扩展模板法：filterbank 正负模板与自相关

`course_filterbank_corr` 仍然是模板法，但它加入了三件额外设计：用 mel filterbank 降维，用能量变化定位词首局部窗，并为每个标签同时建正模板和负模板。它的模型假设是：真正有用的证据主要在词首附近；某个标签不仅要像自己的正样本，也要不像其他三个标签；/z/ 这类持续摩擦音和 /g/、/b/、/d/ 这类短促爆破音，在局部能量包络的自相关上也有差别。

先用 25 ms 帧长、10 ms 帧移计算功率谱，再经过 40 个 mel 三角滤波器得到 log-mel 帧向量

$$L_i[m,q] = \log\left(\sum_k |X_{i,m}[k]|^2 B_q[k] + \epsilon\right), \qquad q = 1,\dots,40.$$

帧能量定义为

$$e_i[m] = \log\left(\frac{1}{40}\sum_q \exp L_i[m,q] + \epsilon\right).$$

代码先对 $e_i[m]$ 做 5 帧滑动平均，再用开头若干帧的中位数作基线。第一个超过基线加 0.22 的位置作为 onset 估计 o_i。候选窗长度为 16 帧，包含 onset 前 2 帧，并额外考察 $\Delta \in \{-2,0,2\}$

三个偏移：

$$W_i^{(\Delta)} = L_i[o_i - 2 + \Delta : o_i - 2 + \Delta + 15, :].$$

每个候选窗被切成 $S = 3$ 段。方法同时保留原始段均值和减去前 2 帧基线后的段均值，拼成局部频谱向量

$$\phi_i^{(\Delta)} = \left[\mu_1(W), \mu_2(W), \mu_3(W), \mu_1(W - \bar{W}_{\text{pre}}), \mu_2(W - \bar{W}_{\text{pre}}), \mu_3(W - \bar{W}_{\text{pre}})\right].$$

这里每个 μ_s 都是 40 维 mel 均值，所以 $\phi_i^{(\Delta)} \in \mathbb{R}^{240}$。另外，从同一个窗的能量包络计算 24 阶归一化自相关，记为 $a_i^{(\Delta)}$。

对每个标签 c，训练集会产生四个模板：局部频谱正模板 P_c^+、局部频谱负模板 P_c^-、自相关正模板 A_c^+ 和自相关负模板 A_c^-。它们分别是该标签正样本和负样本特征的平均。测试时先计算三组候选偏移的分数，再取最大值：

$$\begin{aligned} g_{i,c}^{(\Delta)} &= 0.65\left[\cos(\phi_i^{(\Delta)}, P_c^+) - \cos(\phi_i^{(\Delta)}, P_c^-)\right] \\ &\quad + 0.35\left[\cos(a_i^{(\Delta)}, A_c^+) - \cos(a_i^{(\Delta)}, A_c^-)\right], \\ s_{i,c} &= \max_{\Delta \in \{-2,0,2\}} g_{i,c}^{(\Delta)}. \end{aligned}$$

这条分数式比严格课内版多了负模板差分、自相关项和更明确的词首定位，因此对应本题 bonus 中“用 AI 重做频谱描述与检测”的主体版本。它保留可解释的谱模板结构，但已经不再是严格课堂工具。伪代码见附录算法 A.2。

图 3 展示了扩展模板法模板中真正参与判别的正负差分。前两列分别是原始 log-mel 段均值和 onset-centered 段均值的正负模板差，第三列是能量包络自相关的正负模板差。

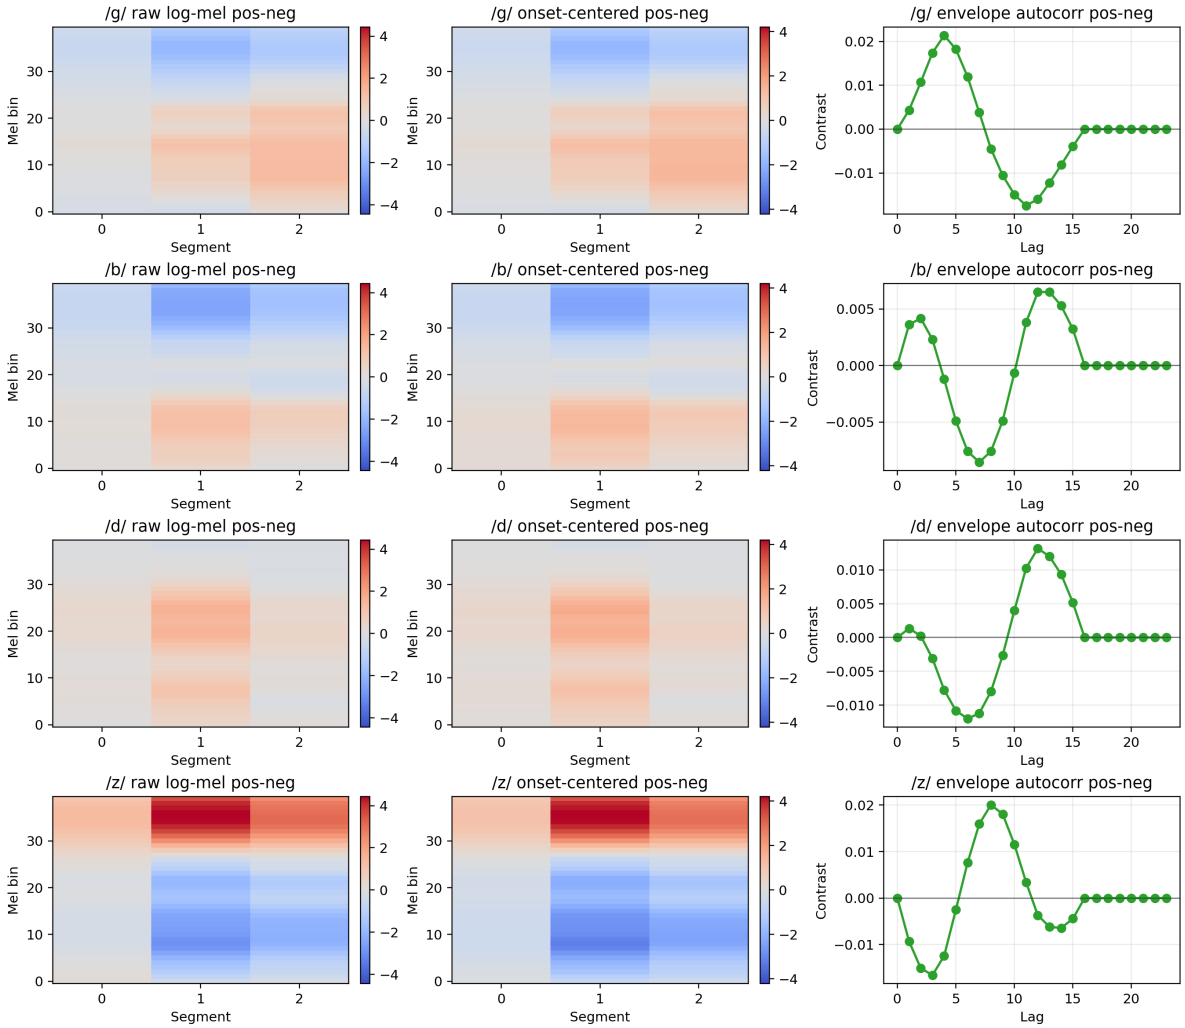

图 3: `course_filterbank_corr` 的正负模板差分。颜色越偏暖，说明该区域更接近该类正样本；颜色越偏冷，说明它更像负样本。

图 4 把扩展模板法的一次检测拆开看：先由 log-mel 能量估计 onset，再围绕 onset 取三个候选窗，最后对每个标签和偏移计算正负模板差分加自相关分数。

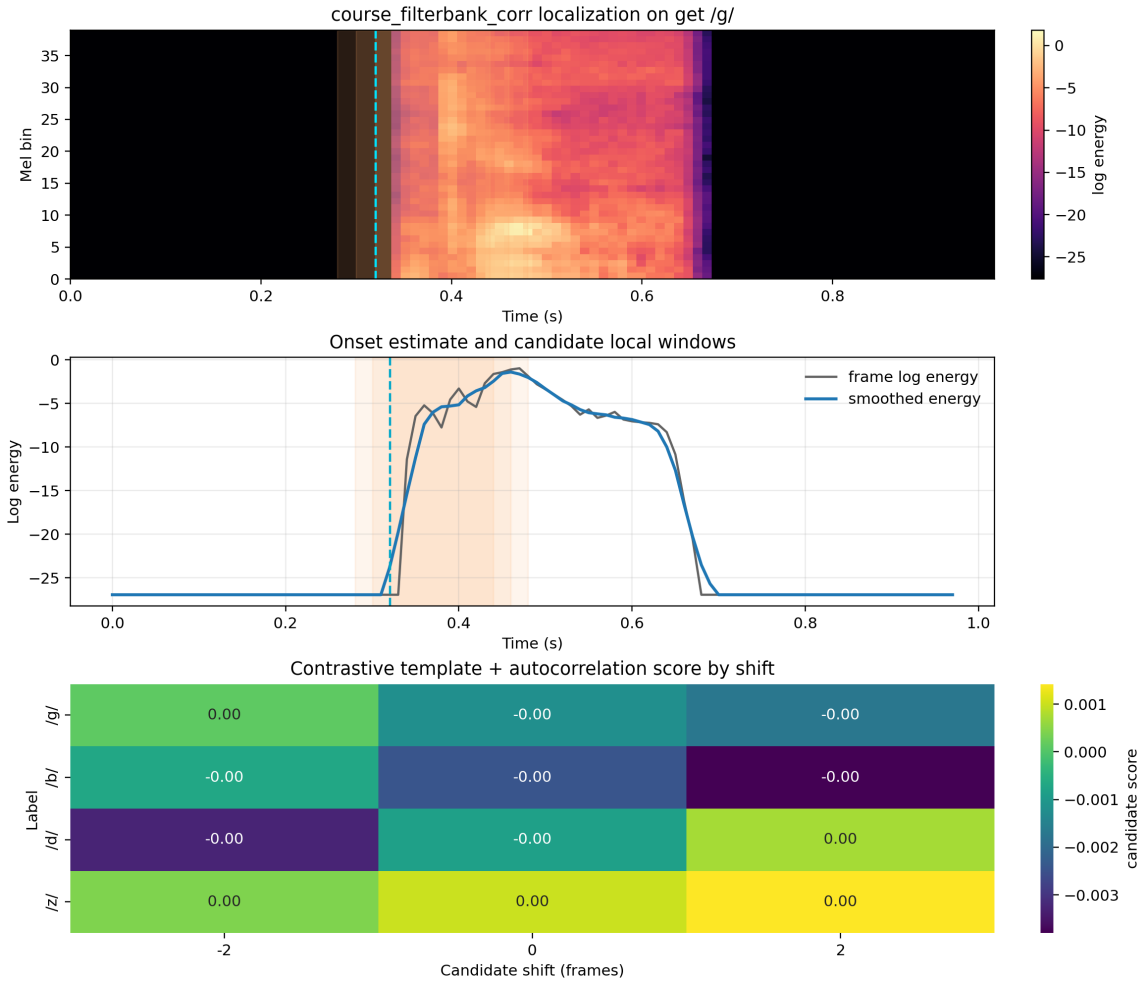

图 4: `course_filterbank_corr` 的局部定位与候选偏移打分示例。

4.3 MATLAB 对应实现

严格课内方法在 MATLAB 里对应 `src/matlab_course_template_detector.m` 和 `src/matlab_course_spectrum_demo.m`。核心打分式子就是一行：

$$\texttt{score} = \frac{\texttt{mag}^\top \texttt{template}}{\|\texttt{mag}\|_2 \|\texttt{template}\|_2}.$$

`src/matlab_case_demo.m` 负责把四个案例音频逐条画出来，方便直接看波形和标签分数。这里的 MATLAB demo 主要是把课堂思路画清楚；正式评测里，Python 版本会先在 dev 上选块长，再把 train+dev 的类别样本重估成最终模板。

5 案例分析与可视化

5.1 四个代表词的频谱模板

图 5 给出了四个代表词在 MATLAB demo 里的短时 FFT 模板。它不是训练图，而是用来确认模板形状到底长什么样。

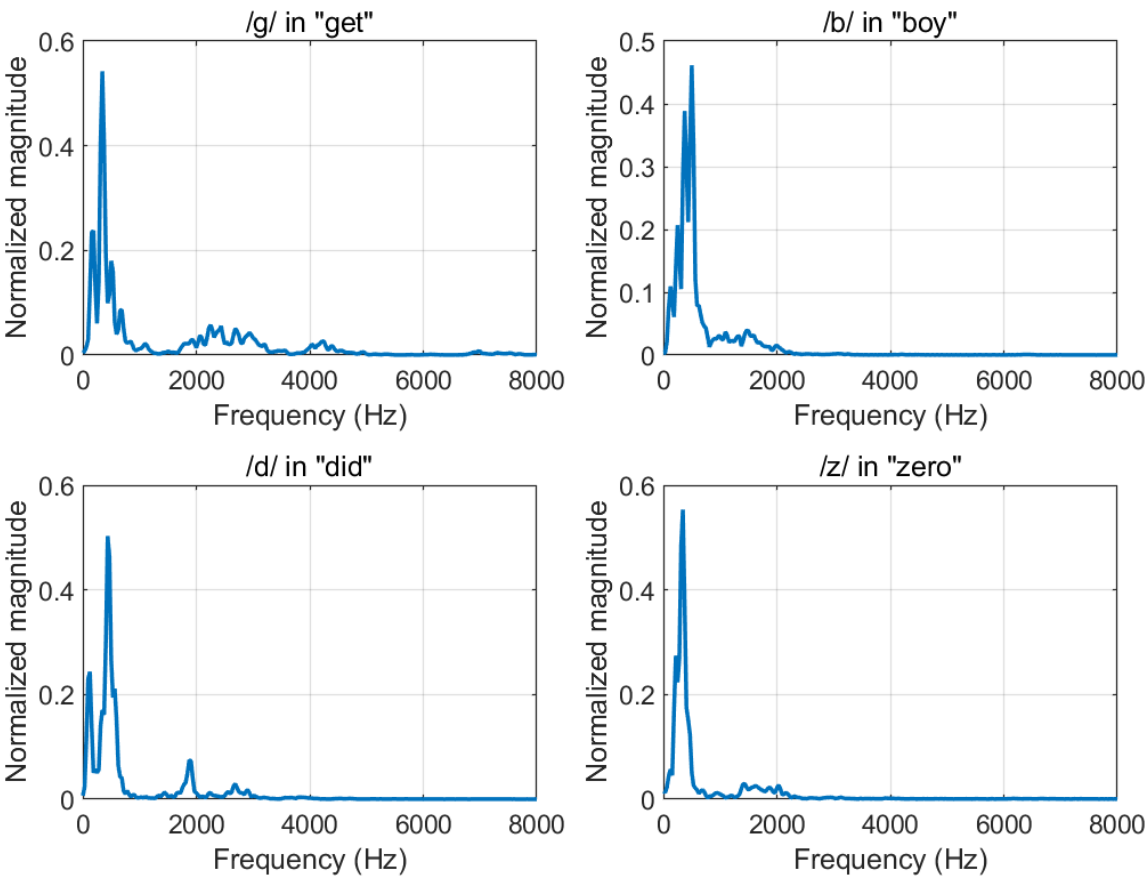

图 5: 四个代表词的短时 FFT 幅度谱模板。

从图上能直接看出，/z/ 的高频摩擦更连续，/b/ 和 /d/ 的起始爆破更短，/g/ 的短时结构最容易被时间对齐误差冲掉。这个结论和模板构造图是一致的。

5.2 相关得分矩阵

图 6 是同一组模板在四个案例词上的相关得分矩阵。它的作用不是证明模型多强，而是说明“模板和查询之间的相关”这件事本身确实在运行。

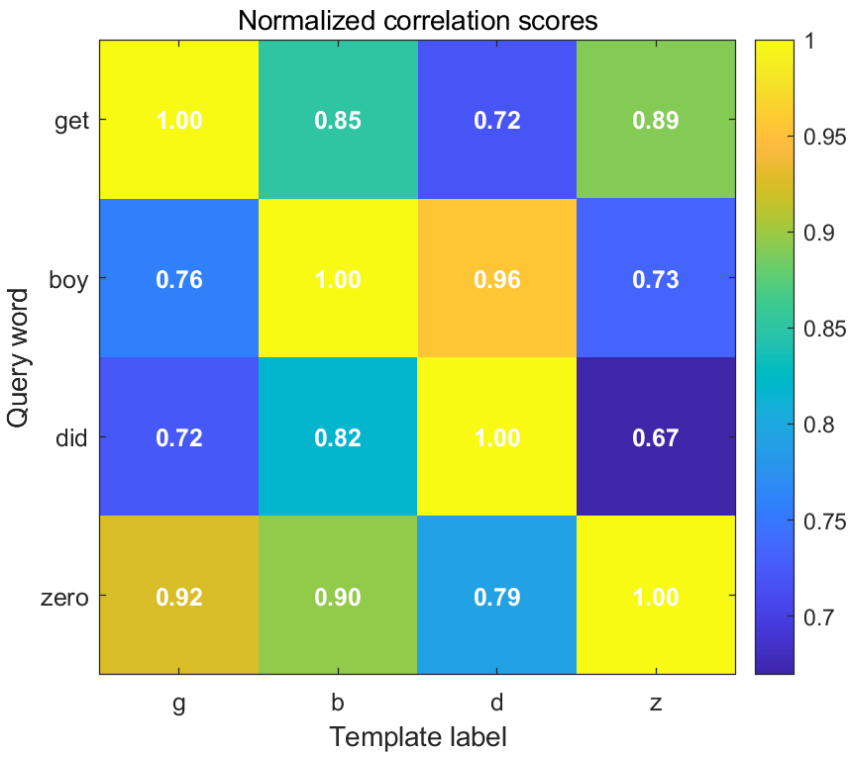

图 6: 四个代表词对应的相关得分矩阵。

这个矩阵比单纯看波形更直接，因为它把“哪个模板更像这段语音”变成了数值。如果相关分数差距不大，就说明这个词首辅音对齐还不够稳，这也是后面扩展模板法要解决的点。

6 实验结果与比较

6.1 严格课内主线

严格课内版的结果先单独看。因为这是单标签四分类，exact-match 是更直接的指标，label-wise accuracy 只作为辅助参考。

这次严格课内版做了两处仍然属于课堂边界内的改动：一方面，不再只用四个 case 音频当模板，而是先把训练集同类样本的最大能量块平均成类别模板，再在选定块长后用 train+dev 重新估计最终模板；另一方面，在 dev 集上从 3–6 帧里选块长度，扩大数据集后最终选中 5 帧。数据词表从 60 个扩到 300 个以后，strict 版本面对的跨词变化更大，所以分数比小词表实验低，但它仍然保留了完整、可解释的课堂链路。

表 2: 严格课内 FFT 模板法的主指标

方法	label-wise acc.	exact-match acc.	macro-F1	micro-F1	samples-F1
strict_course_fft	0.6327	0.2655	0.2439	0.2655	0.2655

表 3: 严格课内 FFT 模板法的分标签 F1

方法	/g/	/b/	/d/	/z/
strict_course_fft	0.217	0.163	0.243	0.353

图 7 进一步把四个标签的分数分布画出来。正样本和负样本有一定分离，但重叠仍然明显，所以严格课内版能说明任务，却还不够稳。

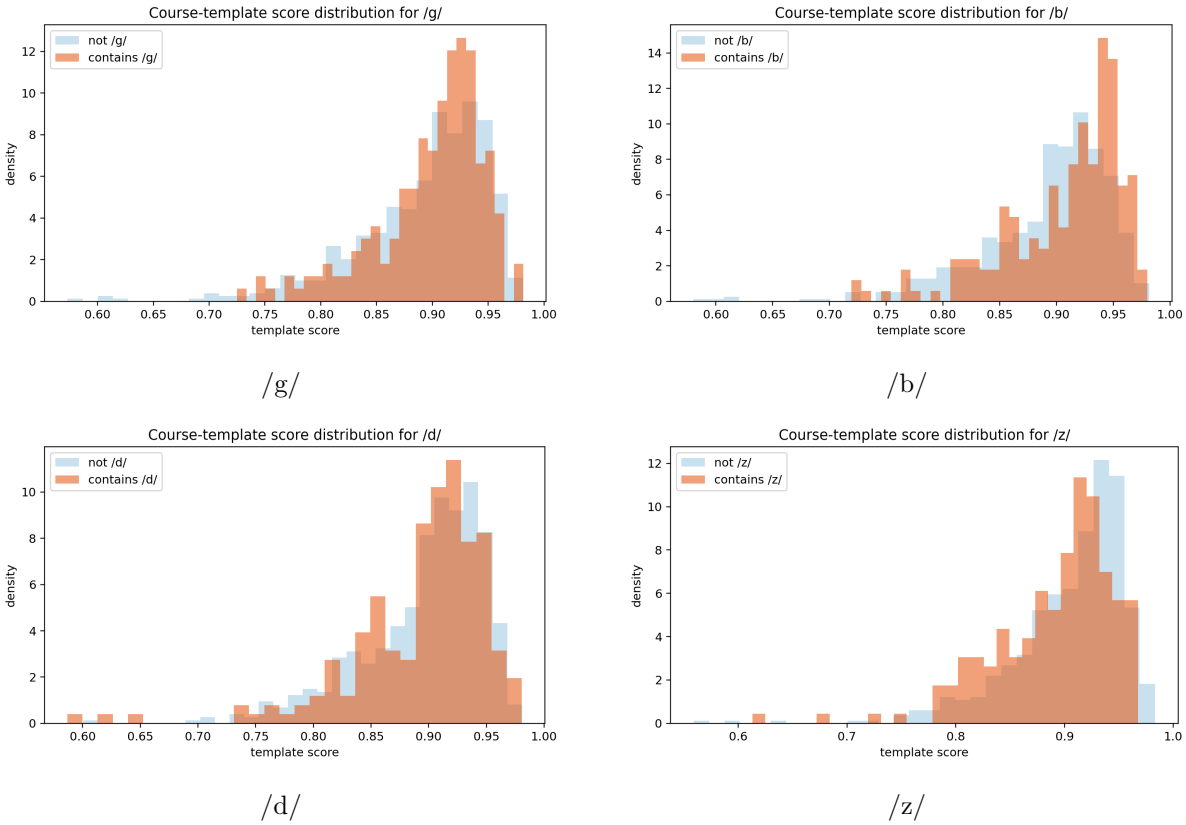

图 7: 严格课内版四个标签的得分分布。

6.2 扩展模板法对照

严格课内版之外，本文把 `course_filterbank_corr` 作为扩展模板法的主要实现。它不是简单换一个分类器，而是重做前两步：先用 log-mel 与能量变化得到更稳的词首局部谱，再用正负模板差分和自相关完成检测。

表 4: 严格课内版与扩展模板法的整体比较

方法	label-wise acc.	exact-match acc.	macro-F1	micro-F1	samples-F1
strict_course_fft	0.6327	0.2655	0.2439	0.2655	0.2655
course_filterbank_corr	0.7513	0.5026	0.4974	0.5026	0.5026

表 5: 严格课内版与扩展模板法的分标签 F1

方法	/g/	/b/	/d/	/z/
strict_course_fft	0.217	0.163	0.243	0.353
course_filterbank_corr	0.464	0.359	0.429	0.737

扩展模板法的提升主要来自两点：它把搜索范围更精确地收到词首附近，也把局部窗里的正负模板差分显式算进去了。/z/ 的提升最大，说明持续摩擦音在 log-mel 局部模板和自相关线索里更稳定；/b/ 和 /d/ 的重叠仍然明显，短促爆破和对齐误差仍然会削弱模板证据。

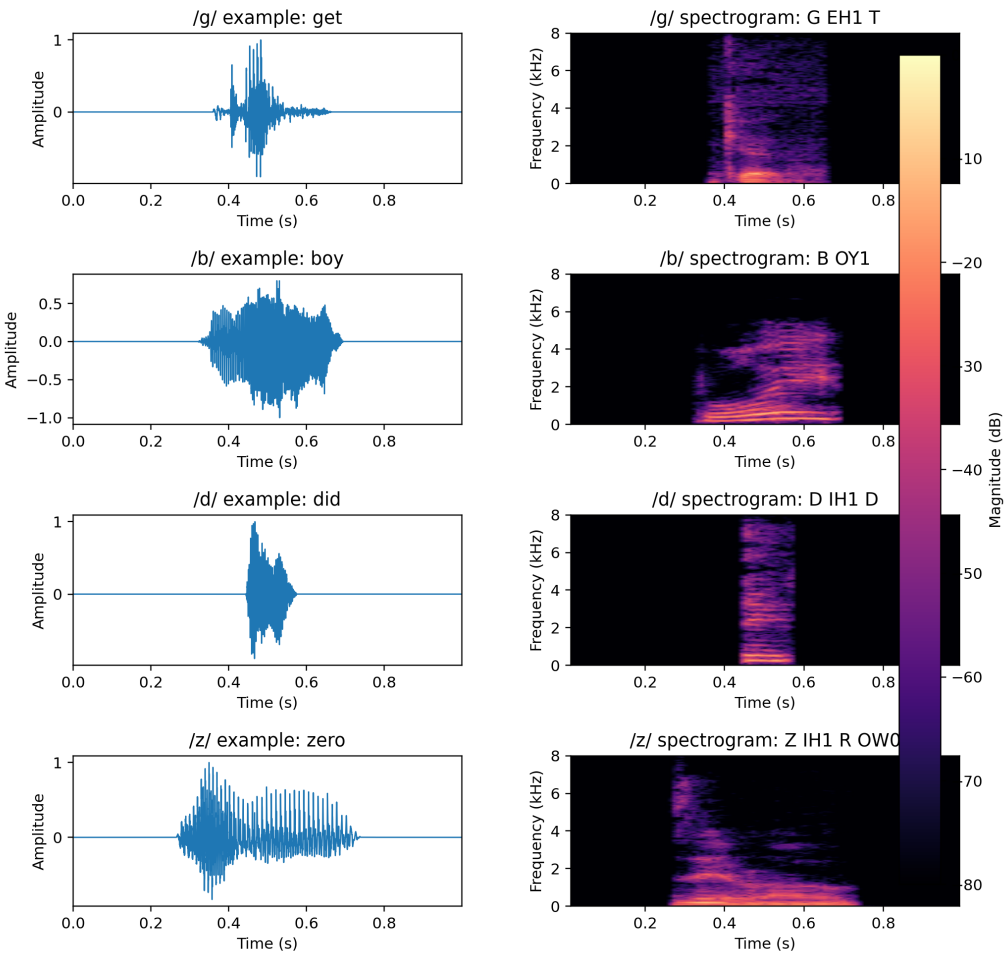

图 8: 扩展模板法对应的四个代表样本。

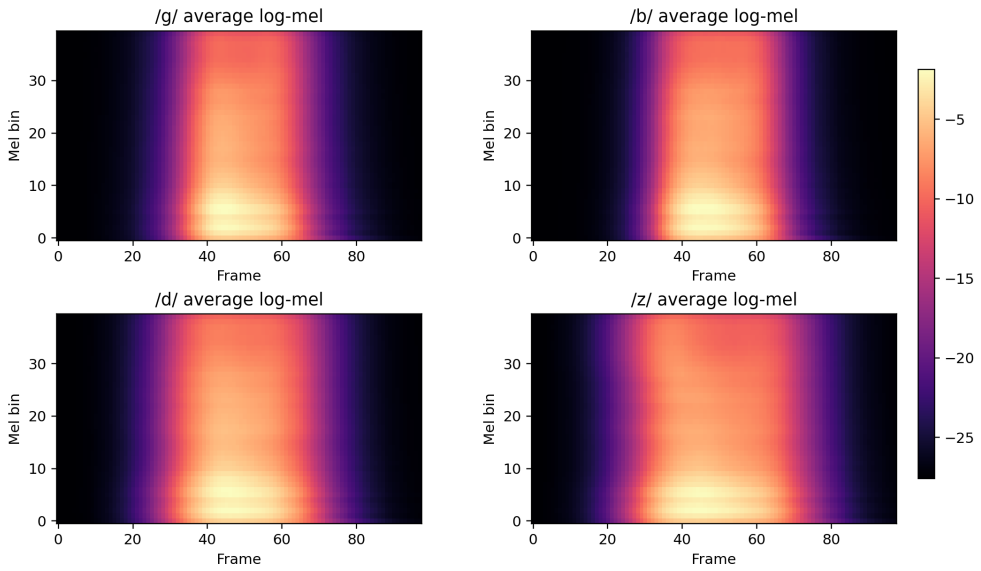

图 9: 扩展模板法使用的平均 log-mel 模板视角。它展示的是每类训练样本的平均谱图，不等同于正负差分模板，但能帮助观察四类词首能量分布。

图 10 把扩展模板法四个标签的测试得分分布单独列出。相比严格课内版，/z/ 的正负样本分离最明显；/g/、/b/、/d/ 仍然有重叠，这解释了为什么扩展模板法提升明显但没有完全解决爆破音之间的混淆。

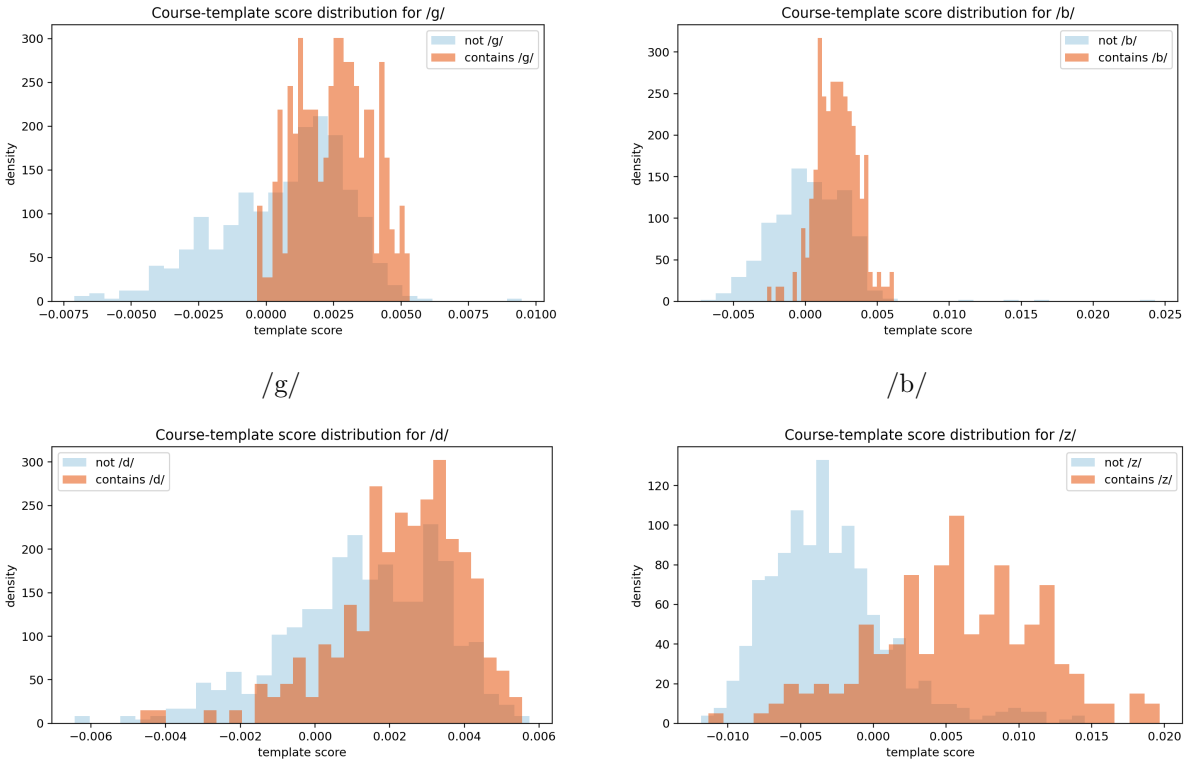

/g/ /b/

/d/ /z/

图 10: `course_filterbank_corr` 四个标签的得分分布。

7 扩展模板法、神经网络对照与训练曲线

本题 bonus 要求用 AI 重做频谱描述和检测。本文把 `course_filterbank_corr` 作为这一路线的主体：它仍然输出可解释的局部谱模板分数，但用 log-mel filterbank、数据驱动 onset、正负模板差分和自相关替代手工 FFT 模板。MLP 和 CNN 则作为额外神经网络对照；两者都使用 train 训练、dev 选择阈值或早停、test 只做最终评测，最后用 $\arg\max$ 解码。

7.1 MLP：MFCC 与频带统计特征

MLP 的输入不是整张谱图，而是人工统计特征。对每条语音先计算 log-mel，再取 13 维 MFCC 及其一阶差分。特征向量由五部分拼接：

$$z_i = [\mathrm{mean}(\mathrm{MFCC}), \mathrm{std}(\mathrm{MFCC}), \mathrm{mean}(\Delta\mathrm{MFCC}), \mathrm{std}(\Delta\mathrm{MFCC}), \mathrm{bandEnergy}]\,.$$

前四部分共 $13 \times 4 = 52$ 维，最后的 band-energy 使用 10 个频带，所以 $z_i \in \mathbb{R}^{62}$。训练前先用 train 集均值和方差做标准化。

模型结构是两层隐藏层的前馈网络：

$$h_1 = \mathrm{ReLU}(W_1 z_i + b_1), \qquad h_2 = \mathrm{ReLU}(W_2 h_1 + b_2), \qquad p_i = \sigma(W_3 h_2 + b_3),$$

隐藏层宽度为 128 和 64。训练目标可以写成四个标签的二元交叉熵加 L_2 正则：

$$\mathcal{L}_{\mathrm{MLP}} = -\sum_{i,c} [y_{i,c} \log p_{i,c} + (1 - y_{i,c}) \log(1 - p_{i,c})] + \lambda \|\theta\|_2^2.$$

这个模型的假设是：整词级 MFCC 统计已经能保留足够的平均声学差异。它不显式定位词首，因此如果词尾元音或说话人差异占了更大比例，模型会把这些全局变化一起吃进去。伪代码见附录算法 A.3。

7.2 CNN：整词 log-mel 谱图

CNN 直接使用整词 log-mel spectrogram。设输入矩阵为 $L_i \in \mathbb{R}^{T \times 40}$，先用 train 集的全局均值和标准差标准化，然后作为单通道图像输入。网络结构为

$$\mathrm{Conv}(1, 24) \to \mathrm{BN} \to \mathrm{ReLU} \to \mathrm{MaxPool},$$

$$\mathrm{Conv}(24, 48) \to \mathrm{BN} \to \mathrm{ReLU} \to \mathrm{MaxPool},$$

$$\mathrm{Conv}(48, 96) \to \mathrm{BN} \to \mathrm{ReLU} \to \mathrm{GlobalAvgPool} \to \mathrm{FC}(96) \to \mathrm{Dropout}(0.25) \to \mathrm{FC}(4).$$

输出 logits 记为 $u_{i,c}$，概率为 $p_{i,c} = \sigma(u_{i,c})$。训练损失使用带正样本权重的 binary cross entropy：

$$\mathcal{L}_{\mathrm{CNN}} = -\sum_{i,c} \alpha_c y_{i,c} \log p_{i,c} - (1 - y_{i,c}) \log(1 - p_{i,c}),$$

其中 α_c 由 train 集正负样本比例得到，并限制在 $[1, 10]$。优化器是 AdamW，学习率 10^{-3}，weight decay 为 10^{-4}，并用 dev macro-F1 选择最佳 epoch。

CNN 的假设和模板法不同。它不预先规定词首窗口，而是希望卷积核从整词谱图里学到局部模式。这个假设需要更多词表覆盖支撑；扩大到 300 个词、6796 条语音后，小 CNN 的表现明显好于 60 词版本。

表 6: 神经网络对照的整体指标

方法	label-wise acc.	exact-match acc.	macro-F1	micro-F1	samples-F1
MLP	0.7423	0.4845	0.4848	0.4845	0.4845
CNN	0.7796	0.5593	0.5557	0.5593	0.5593

从结果上看,MLP 仍然是一个稳定的统计基线,但低于扩展模板法 `course_filterbank_corr`。CNN 受益于更多词种和更多训练样本，exact-match 达到 0.559，高于扩展模板法的 0.503；这说明当词表覆盖上来以后，端到端谱图模型开始能学到一部分词首局部模式，但它的解释性仍弱于 `course_filterbank_corr`。

表 7: CNN epoch 消融结果

最大 epoch	实际完成	dev 最优 epoch	dev macro-F1	test exact-match
5	5	5	0.529	0.372
10	10	8	0.575	0.499
15	15	11	0.598	0.460
20	20	18	0.598	0.523
25	25	25	0.608	0.559
30	30	26	0.614	0.541
40	34	26	0.614	0.541

按 dev macro-F1 看，30 和 40 的上限都能找到第 26 个 epoch 附近的最优点；但 40 会在 34 个 epoch 早停，没有带来新收益。按测试集 exact-match 看，25 个 epoch 的设置最高。因此正文采用 25 个 epoch 作为最终 CNN 配置，并把 25–30 视为这个数据规模下的合理训练区间。

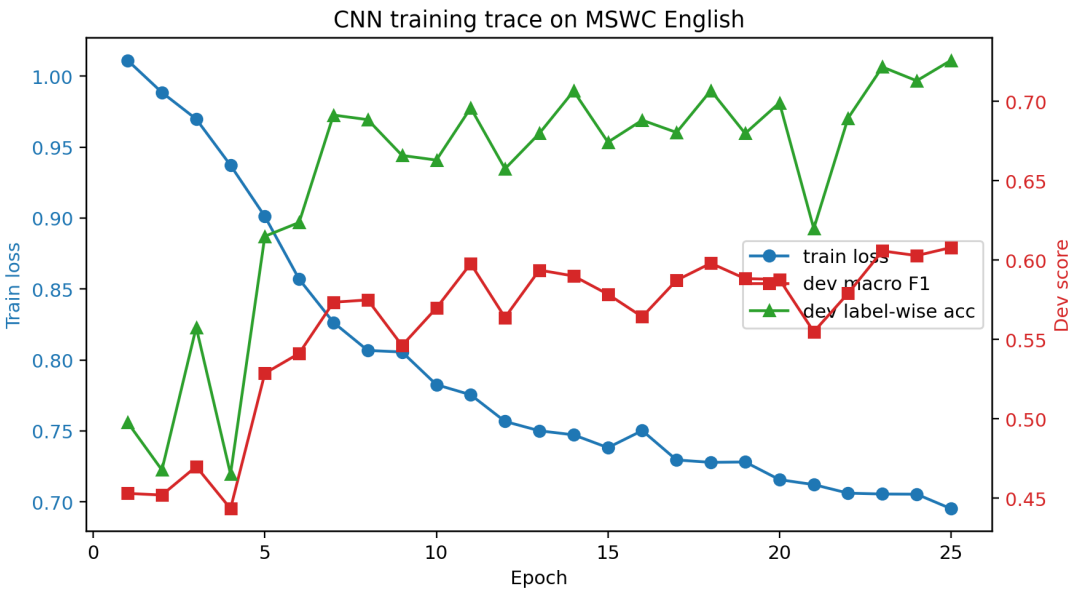

图 11: CNN 的训练曲线。

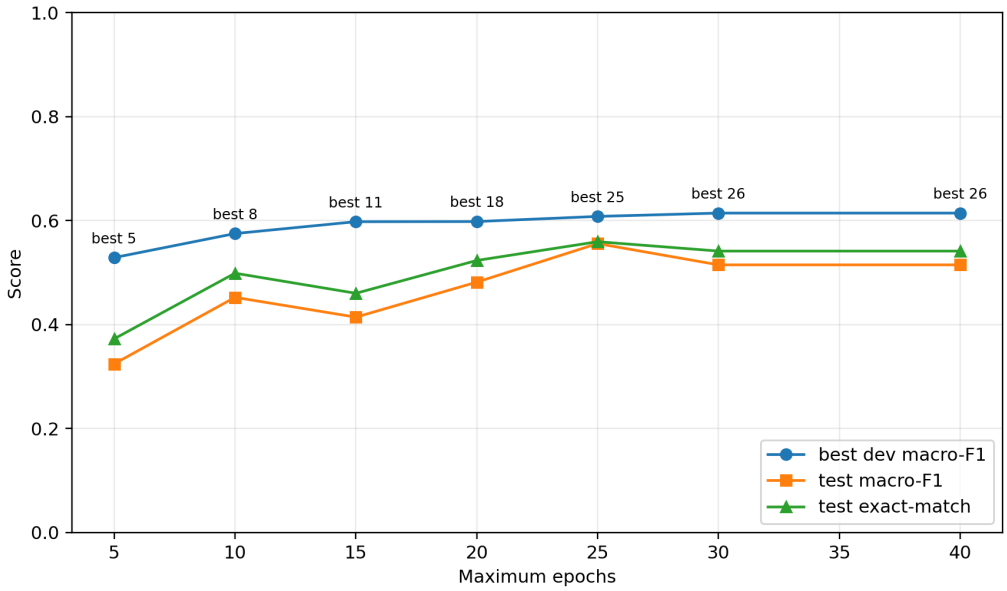

图 12: CNN 最大 epoch 消融。25 个 epoch 的测试 exact-match 最高，30/40 的 dev macro-F1 略高但测试集没有继续提升。

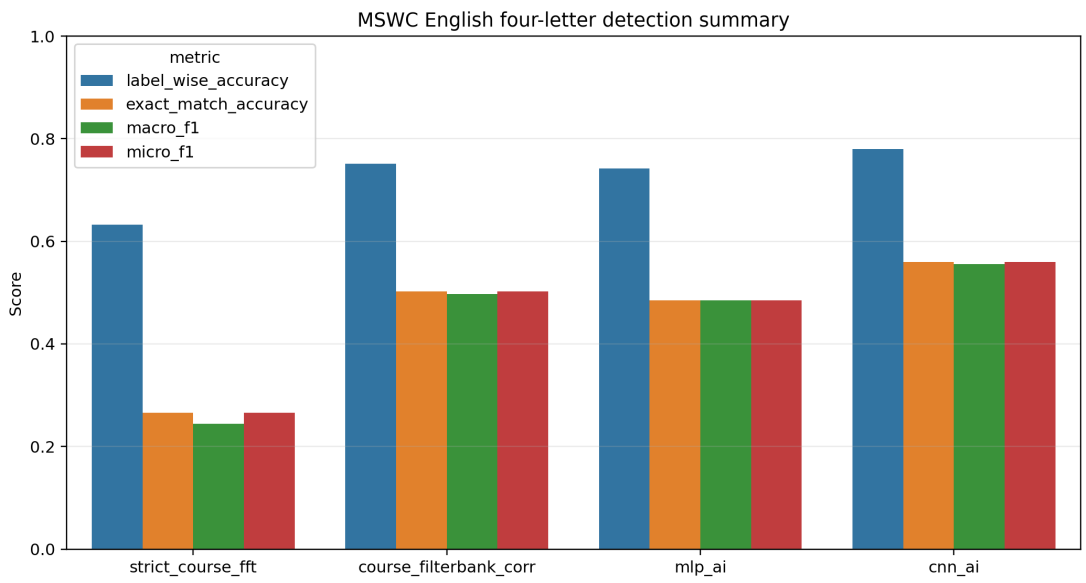

图 13: 全部方法的总体指标汇总。

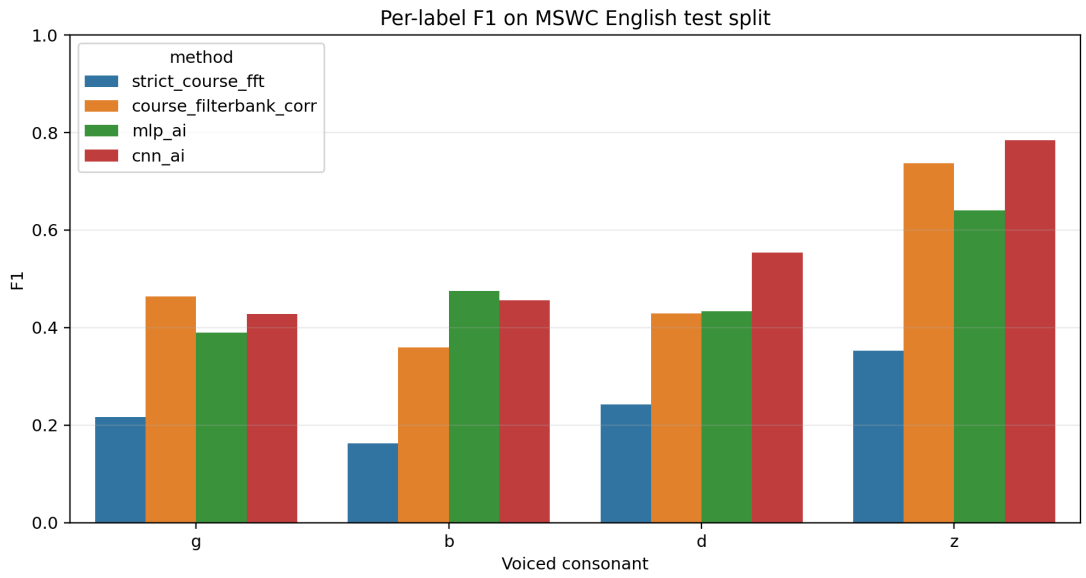

图 14: 全部方法在四个标签上的 F1 对比。

这几张图放在后面，是为了把扩展模板法和神经网络对照的角色分开：`course_filterbank_corr` 回答“扩展模板法如何重做频谱检测”，MLP/CNN 回答“常见学习型模型能达到什么分数”。对本文来说，真正的收获不是 CNN 有没有赢，而是课堂频谱模板、扩展模板法模板和神经网络模型之间的边界已经分清楚。

8 讨论与局限

四个方法的结果呈现出清楚的层次。严格课内版 `strict_course_fft` 的 exact-match 只有 0.265，macro-F1 为 0.244，接近四分类随机水平；它的意义主要是把“分帧、FFT、局部块、归一化相关”这条课堂链路跑通，而不是提供最强检测器。中间案例也能解释这一点：`get`、`boy` 等样本的四个 FFT 相关分数常常非常接近，说明最大能量块和单边幅度谱模板不足以稳定区分 /g/、/b/、/d/ 这类短促爆破音。

`course_filterbank_corr` 作为扩展模板法后，exact-match 提升到 0.503，macro-F1 提升到 0.497。这个提升不是来自黑盒分类器，而是来自更合理的中间表示：log-mel 降维让谱形更平滑，onset-centered 局部窗减少了整词元音的干扰，正负模板差分压低了类别共享能量，自相关补充了持续摩擦和短促爆破之间的时间结构。分标签结果也符合这个解释：/z/ 的 F1 达到 0.737，因为它的摩擦段长而稳定；/b/ 只有 0.359，说明弱 burst 和后接元音变化仍然会让它与 /g/、/d/ 混在一起。

MLP 和 CNN 的作用是检查学习型模型能否进一步超过扩展模板法。MLP 的 exact-match 为 0.485，低于 `course_filterbank_corr`，说明整词 MFCC 统计虽然稳定，但会把词尾元音和说话人差异一起平均进去。CNN 的 exact-match 达到 0.559，是当前最高；它在 /d/ 和 /z/ 上明显更强，说明扩大到 300 个词、6796 条语音后，卷积模型确实能从整张 log-mel 谱图里学到一部分局部模式。不过 epoch 消融也显示，dev macro-F1 最高的 30/40 epoch 设置并没有带来最高测试准确率，最终 25 epoch 更好，因此 CNN 的优势仍然带有训练方差和数据划分依赖。

因此，本文不能只按最高分排序。严格课内版最弱，但最贴近课程工具；扩展模板法不是最高分，却最能说明“改进频谱描述和检测结构”为什么有效；CNN 分数最高，但可解释性最弱。这个关系也提醒我们，label-wise accuracy 在一热四分类下会被大量真阴性抬高，真正应该主要看 exact-match、macro-F1 和分标签 F1。

这套方案仍有几个限制：

- 语音输入仍然是整词级音频，不是人工切好的 phone segment，所以严格课内版只能靠滑窗搜索。
- /g/、/b/、/d/ 的 burst 很短，对齐误差一大，模板证据就容易被后续元音吞掉。
- 当前扩展模板法仍是模板法，没有做 phone-level alignment，也没有显式建模说话人和录音通道差异。
- 当前 CNN 只是轻量对照，没有加入数据增强、预训练语音模型或强制对齐，因此不能代表深度语音模型的上限。

9 结论

本文完成了 Topic 2 的重构，核心结论如下：

- 新数据集把任务收紧到了首浊辅音检测，当前主线使用每类 75 个词，共 300 个词、6796 条语音，标签边界比旧版清楚得多；

- 严格课内版可以只用短时 FFT 幅度谱和归一化相关完成完整检测链路；在当前数据集上，dev 选出 5 帧块，再用 train+dev 重估模板后，exact-match 为 0.265；
- 扩展模板法 `course_filterbank_corr` 通过 log-mel 词首局部窗、正负模板差分和自相关线索把 exact-match 提升到 0.503；
- MLP 的 exact-match 为 0.485，CNN 为 0.559。扩大词表后 CNN 成为最高分方法，但模板法仍然提供了更清楚的声学解释；
- /z/ 最容易，这和持续摩擦能量更长、更稳定一致；/g/、/b/、/d/ 的短促爆破更依赖对齐，因此仍是主要错误来源。

A 算法结构与伪代码

本附录把正文中的四个实现整理成可复现的结构。所有方法都使用相同的输入设置：音频统一为 16 kHz、1 s 单声道 WAV，标签集合为 $C = \{g, b, d, z\}$，train/dev/test 分别只承担训练、调参和最终测试职责。

A.1 `strict_course_fft`

模型与假设：每个首浊辅音可以由一个短时 FFT 幅度谱原型表示；最大能量块近似包含词首辅音的主要局部证据；归一化相关可以削弱音量差异。

伪代码：

1. 对每条训练音频做 20 ms 分帧、10 ms 帧移和 512 点 FFT。
2. 对每个候选 M 帧块计算归一化幅度谱描述子 $P_i^{(r)}$。
3. 在正样本中选最大能量块，得到 $P_i^{(\star)}$。
4. 对每个类别 c，平均同类 $P_i^{(\star)}$ 并归一化，得到模板 T_c。
5. 在 dev 集上从 $M \in \{3, 4, 5, 6\}$ 选择 exact-match 最好的块长。
6. 用 train+dev 按选定块长重估模板。
7. 测试时滑动全部候选块，计算 $s_{i,c} = \max_r \cos(P_i^{(r)}, T_c)$。
8. 输出 $\hat{c}_i = \arg\max_c s_{i,c}$。

A.2 `course_filterbank_corr`

模型与假设：词首附近的 log-mel 局部窗比整词平均谱更可靠；正负模板差分能减少类别间共享能量的干扰；能量包络自相关能补充持续摩擦和短促爆破之间的时间结构差异。

伪代码：

1. 对音频做 25 ms 分帧、10 ms 帧移，计算 40 维 log-mel spectrogram。
2. 由帧能量的平滑曲线估计 onset o_i。
3. 取 $\Delta \in \{-2, 0, 2\}$ 三个候选偏移，得到 16 帧局部窗。
4. 对局部窗切成 3 段，拼接原始段均值和去基线后的段均值，得到 $\phi_i^{(\Delta)}$。

5. 对局部窗能量包络计算 24 阶归一化自相关，得到 $a_i^{(\Delta)}$。
6. 对每个类别 c，在 train 集上分别平均正样本和负样本，得到 P_c^+、P_c^-、A_c^+、A_c^-。
7. 对每个候选偏移计算 $0.65[\cos(\phi, P_c^+) - \cos(\phi, P_c^-)] + 0.35[\cos(a, A_c^+) - \cos(a, A_c^-)]$。
8. 对三个偏移取最大值作为 $s_{i,c}$，最后输出 $\arg\max_c s_{i,c}$。

A.3 `mlp_ai`

模型与假设： MFCC 均值、方差、一阶差分统计和粗频带能量已经能概括整词里的主要声学差异；两层非线性网络可以学习这些统计特征到四个标签的映射。

结构：

$$62 \to 128 \to 64 \to 4.$$

隐藏层激活函数为 ReLU，输出层用 sigmoid 概率。训练使用 Adam、early stopping 和 L_2 正则，dev 集用于阈值选择，测试时按 arg max 解码。

伪代码：

1. 从每条音频提取 MFCC 统计、delta MFCC 统计和 10 维 band-energy。
2. 用 train 集均值和方差标准化特征。
3. 训练两层 MLP，优化四个标签的 binary cross entropy。
4. 在 dev 集上选择每个标签的阈值，同时保留 exclusive decoding。
5. 在 test 集输出四个标签概率，取最大概率类别作为预测。

A.4 `cnn_ai`

模型与假设： log-mel spectrogram 可以看成时间频率图像，卷积层可以从整词谱图中自动学习局部声学模式。这个假设不要求人工指定词首窗口，但需要足够数据让模型学会忽略无关位置。

结构：

$$\begin{aligned}
&\mathrm{Conv}_{24} \to \mathrm{BN} \to \mathrm{ReLU} \to \mathrm{Pool} \\
&\to \mathrm{Conv}_{48} \to \mathrm{BN} \to \mathrm{ReLU} \to \mathrm{Pool} \\
&\to \mathrm{Conv}_{96} \to \mathrm{BN} \to \mathrm{ReLU} \to \mathrm{GlobalAvgPool} \\
&\to \mathrm{FC}_{96} \to \mathrm{Dropout} \to \mathrm{FC}_4.
\end{aligned}$$

伪代码：

1. 提取整词 log-mel spectrogram，并用 train 集全局均值和方差标准化。
2. 将谱图作为单通道输入送入三层卷积网络。
3. 使用带正样本权重的 BCEWithLogitsLoss 训练，优化器为 AdamW。
4. 每个 epoch 后在 dev 集计算 macro-F1，并保留 dev macro-F1 最高的模型。
5. 在 test 集输出 sigmoid 概率，按 arg max 得到最终类别。

参考文献

[1] S. Davis and P. Mermelstein, "Comparison of Parametric Representations for Monosyllabic Word Recognition in Continuously Spoken Sentences," *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 1980. https://doi.org/10.1109/TASSP.1980.1163420.

[2] L. R. Rabiner, "A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition," *Proceedings of the IEEE*, 1989. https://doi.org/10.1109/5.18626.

[3] N. J. Wilkinson and M. J. Russell, "Improved Phone Recognition on TIMIT Using Formant Frequency Data and Confidence Measures," in *Proc. ICSLP 2002*. https://www.isca-archive.org/icslp_2002/wilkinson02_icslp.html.

[4] M. Mazumder *et al.*, "Multilingual Spoken Words Corpus," in *Proc. NeurIPS Datasets and Benchmarks*, 2021. https://datasets-benchmarks-proceedings.neurips.cc/paper/2021/hash/fe131d7f5a6b38b23cc967316c13dae2-Abstract-round2.html.

[5] G. Chen, C. Parada, and G. Heigold, "Small-Footprint Keyword Spotting using Deep Neural Networks," in *Proc. ICASSP 2014*. https://research.google/pubs/small-footprint-keyword-spotting-using-deep-neural-networks/.

[6] T. N. Sainath and C. Parada, "Convolutional Neural Networks for Small-Footprint Keyword Spotting," in *Proc. Interspeech 2015*. https://research.google/pubs/convolutional-neural-networks-for-small-footprint-keyword-spotting/.

[7] P. Warden, "Speech Commands: A Dataset for Limited-Vocabulary Speech Recognition," arXiv:1804.03209, 2018. https://doi.org/10.48550/arXiv.1804.03209.

[8] M. Berg *et al.*, "Keyword Transformer: A Self-Attention Model for Keyword Spotting," arXiv:2104.00769, 2021.

[9] A. Baevski *et al.*, "wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations," arXiv:2006.11477, 2020. https://doi.org/10.48550/arXiv.2006.11477.

[10] W.-N. Hsu *et al.*, "HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units," arXiv:2106.07447, 2021.

[11] S. Chen *et al.*, "WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing," *IEEE Journal of Selected Topics in Signal Processing*, 2022. https://arxiv.org/abs/2110.13900.

[12] C. Gao *et al.*, "Self-Supervised Speech Representation Learning for Keyword-Spotting with Light-Weight Transformers," arXiv:2303.04255, 2023. https://arxiv.org/abs/2303.04255.

[13] D. Kim and J. Hwang, "Fully End-to-end Streaming Open-vocabulary Keyword Spotting with W-CTC Forced Alignment," in *Proc. Interspeech 2025*. https://www.isca-archive.org/interspeech_2025/kim25d_interspeech.html.