基于 MSWC English 精确首浊辅音子集的 /g/、/b/、/d/、/z/ 检测：理论、算法与案例分析

VE216 Project Topic 2 重构版

2026 年 4 月 28 日

摘要

本文重构 VE216 Project Topic 2 的主线，不再把重点放在神经网络本身，而是放在任务定义、假设、理论分析、算法结构和定性案例上。我们把原先较松的词级多标签实验，收紧为一个更接近“首浊辅音检测”的四类任务：只保留首字母为 `g/b/d/z` 且 CMUdict 中首个非元音音素严格匹配 `G/B/D/Z` 的单词，共得到 60 个词、3000 条 16 kHz 语音。方法上，本文保留课内模板法作为主方法，并用 MLP 和 CNN 作为对照基线。结果表明，课程模板法可解释但误报高；MLP 的 exact-match 最好；CNN 的 macro-F1 最好。更重要的是，四类辅音的差异和声学事实一致：/z/ 最容易，/g/ 最难。

1 问题定义与报告主线

1.1 任务形式化

设输入语音为 x_i，目标标签为 $y_i \in \{0,1\}^4$，对应标签集合

$$C = \{g, b, d, z\}.$$

在当前数据集上，每个样本恰好属于四类中的一类，因此满足 $\sum_{c \in C} y_{i,c} = 1$。但实现里仍保留一对多接口：先对每个标签输出分数 $s_{i,c}$，再用该标签自己的阈值 τ_c 做判定

$$\hat{y}_{i,c} = \mathbb{1}[s_{i,c} \geq \tau_c].$$

这样做的原因是：课内模板法、统计特征分类器和 CNN 输出的都不是天然校准过的概率，统一用 dev 集选阈值更公平，也更容易比较不同方法的特性。

1.2 本文的重点

这份报告只把 AI 模型当作对照基线，不把它们当成主角。主线是：

- 任务边界是否真的收紧到了“首浊辅音检测”；

- 课内模板法到底在假设什么、怎么计算、为什么会误报；
- 统计特征和时频特征为什么能比模板法更稳；
- /g/、/b/、/d/、/z/ 为什么会呈现出明显不同的难度。

2 相关工作与文献综述

截至 2026 年 4 月 28 日，围绕“在短语音中检测特定语音单位”的公开文献大致已经形成三条主线：第一类是基于短时频谱、filter bank 或 MFCC 的传统声学特征与统计建模；第二类是面向关键词检测的小模型深度网络；第三类是以自监督预训练语音表示为前端、再配轻量分类器或开放词表检测器的现代迁移路线。对本文最相关的问题不是大词汇量连续语音识别，而是：在 1 秒左右的短语音里，怎样稳定判断某个浊辅音是否出现，以及这种判断究竟应该建立在整词统计、局部时频模式，还是更细粒度的 phone-level 表示之上。

2.1 传统声学特征与序列模型

传统语音识别的第一条成熟路线，是先把波形切成短时帧，再把每帧映射到更稳定的谱包络表示。Davis 和 Mermelstein 的工作系统比较了多种参数化语音表示，并奠定了 mel-frequency cepstral coefficients（MFCC）作为经典特征的地位 [1]。随后，Rabiner 对隐马尔可夫模型（HMM）在语音识别中的建模方法做了系统总结，明确了“帧级声学特征 + 状态转移约束”的标准范式 [2]。这条路线的核心优点是解释性强，能够清楚区分“前端表示是否保留了辅音线索”和“后端判别器是否利用好了这些线索”。

对本文这种“浊辅音是否存在”的任务来说，传统方法最重要的启发有两点。第一，整词 FFT 往往会把短暂的辅音释放段和后续元音能量混在一起，因此必须退回到短时谱、filter bank 或 MFCC 这类逐帧表示。第二，如果目标从 word-level presence 进一步收紧到真正的 phone-level detection，那么单纯的整词模板匹配就不够了，往往需要显式的时间对齐或序列模型。Wilkinson 和 Russell 在 TIMIT 上把 formant frequency 与 MFCC 做置信度加权融合，说明即使是在传统管线里，只要标签粒度足够细，辅音识别也会显著受益于更贴近发音机制的局部声学线索 [3]。

因此，从文献角度看，本文当前采用的“短时频谱 → 40 维 filter bank → 模板相关 + 自相关阈值”的课程基线并不落后于问题本身，它恰好属于最经典、最可解释的一类方法。它的主要局限不在于“没有用 AI”，而在于当前标签仍是 word-level presence label，导致模板法看到的是整词统计模式，而不是真正对齐到辅音边界的 phone token。

2.2 面向关键词检测的小模型深度网络

随着移动端语音入口兴起，文献很快从 HMM/DTW 过渡到 small-footprint keyword spotting（KWS）。Chen、Parada 和 Heigold 在 2014 年给出了小模型 DNN 关键词检测器，目标就是在严格算力预算下完成短语音分类 [4]。Sainath 和 Parada 随后表明，CNN 在同类任务上可以用更少参数获得更低的 false reject rate，因为卷积层比全连接网络更能保留局部时频结构 [5]。再往后，Arik 等人把卷积层与循环层结合成 CRNN，在低延迟条件下继续提升鲁棒性 [6]。

这些工作说明：一旦任务输入固定为 1 秒左右的短音频，最有效的改进通常不是堆叠更复杂的手工统计量，而是让模型直接在 log-mel 或 spectrogram 上学习局部时间-频率模式。

与这些模型同步成熟的是标准化数据集。Warden 发布的 Speech Commands 数据集为 limited-vocabulary speech recognition 提供了可复现基准，并强调了关键词检测与连续语音识别在数据组织和评价方式上的差异 [7]。这条数据集路线直接催生了后续大量 CNN、残差网络和轻量时序模型。到 2021 年，Berg、O'Connor 和 Cruz 提出的 Keyword Transformer（KWT）进一步表明，即使不依赖额外预训练，纯 self-attention 结构也可以在关键词检测任务上超过若干更复杂的卷积/循环混合模型 [8]。

这部分文献与本文当前实验设置的对应关系非常直接。本文已经把 AI 分支收敛到 MLP 和 CNN 两条线，其中 CNN 明显优于 MLP，本质上正符合上述 KWS 文献的共同结论：如果标签仍是 utterance-level 或 word-level，那么保留二维时频局部结构的模型通常优于把特征先压成单个统计向量后再分类。换句话说，当前报告里“课程模板法 < MLP < CNN”的结果不是偶然现象，而是与过去十年短语音检测文献的主流趋势一致。

2.3 自监督预训练与当前前沿方向

近几年的主流变化，不再只是把 CNN 换成更深的 CNN，而是把自监督预训练语音表示接到下游检测任务前面。wav2vec 2.0 证明了只用未标注语音做表示学习，再用少量标注数据微调，就能得到很强的下游语音识别性能 [9]。HuBERT 进一步把 masked prediction 和离散 hidden unit 结合起来，专门针对语音序列中“单位未知、长度可变、边界不显式”的问题学习表示 [10]。WavLM 则把说话人信息、语音内容和更广泛的全栈语音任务统一到同一套预训练框架里，使同一个编码器更容易迁移到识别、检索和判别类任务 [11]。

对于资源受限的关键词检测场景，文献并没有简单地把大模型整套搬上设备，而是开始探索“强前端 + 轻后端”的折中。Gao 等人在 2023 年把自监督语音表示与 33 万参数级别的轻量 Transformer 结合，用于 Google Speech Commands v2 的关键词检测，并报告了相对从头训练更好的分类效果 [12]。这说明在小样本或标签较粗的任务上，自监督前端最有价值的地方并不是直接替换掉所有后端结构，而是先把对发音方式、共振峰走向和时序变化更稳的表示学出来，再交给很小的分类头去完成判别。

更靠近“现在的 algorithm”的一条新线，是 open-vocabulary keyword spotting。Kim 和 Hwang 在 2025 年提出基于 W-CTC forced alignment 的流式开放词表关键词检测管线，不再要求预先构造词级对齐数据，而是让系统在端到端框架中直接学习声学编码与文本目标之间的对齐 [13]。对本文任务而言，这类方法的意义不在于马上照搬整套系统，而在于它提示了一个方向：如果后续要从“判断一个字母是否出现在某个词里”升级到“在任意词或短句中定位这个辅音出现的位置”，那么 CTC 或 forced alignment 思路会比单纯的整词二分类更合适。

综合这些文献，可以把截至 2026 年春季的代表性算法演进概括为：**MFCC/HMM 等可解释前端与序列模型**，**CNN/CRNN/Transformer 等小模型判别器**，以及 **自监督预训练编码器 + 轻量下游头 + 对齐机制**。其中第二条和第三条，是当前公开文献里最值得继续追踪的主流方向。

2.4 对本文项目的直接启示

把以上文献放回本文的具体任务，可以得到四个直接结论。第一，当前课程模板法仍然有保留价值，因为它对应的是最经典、最可解释的声学模板路线，适合说明 /b/、/d/、/l/、/n/ 在 log-mel 空间里的可见差异 [1, 2]。第二，如果继续维持 600 词、1 秒整词、word-level presence label 这一设置，那么 CNN 甚至 KWT 一类的小模型判别器，会比继续手工扩展统计特征更自然 [5, 8]。第三，如果项目下一步希望真正回答“某个浊辅音在时域上出现在哪里”，就必须把标签粒度推进到 phone-level，并考虑 TIMIT、forced alignment 或 CTC 这类时间对齐路线 [3, 13]。第四，如果数据规模继续扩大，但人工标注粒度仍有限，那么 wav2vec 2.0、HuBERT、WavLM 这类自监督前端将是比重新设计手工特征更有潜力的升级方向 [9, 10, 11, 12]。

因此，本文当前“课程方法作为可解释基线，CNN 作为更强判别器”的结构，与现有文献是相容的；真正尚未完成的，不是再证明一次 CNN 比模板法更强，而是把任务从 **word-level presence detection** 稳定推进到 **phone-aware detection or localization**。这也是相关工作对本文最重要的约束。

3 数据集重建与标注规则

3.1 筛选规则

新数据集由 `src/prepare_mswc_initial_gbdz_subset.py` 生成，核心规则只有一条：

> 保留一个单词，当且仅当它的首字母属于 `g/b/d/z`，并且 CMUdict / ARPABET 中首个非元音音素与该字母严格对应为 `G/B/D/Z`。

这条规则的意义是把“字母里出现了某个浊辅音”改成“这个浊辅音确实出现在起始位置”。这样可以自动去掉两类噪声样本：

- 拼写里有目标字母，但发音位置不对；
- 首字母对了，但真正起始音素不是目标浊辅音。

```
for each word w in MSWC:
    if first letter of w not in {g,b,d,z}: discard
    phones = CMUdict(w)
    p = first non-vowel phone in phones
    if p == first letter(w).upper():
        keep w
    else:
        discard
```

3.2 数据规模

最终实验规模如下：

表 1: 精确首浊辅音子集的规模统计

标签	词数	train	dev	test
/g/	15	600	75	75
/b/	15	600	75	75
/d/	15	600	75	75
/z/	15	600	75	75
合计	60	2400	300	300

也就是说，这版数据是四类完全平衡的：总样本数 3000，测试集每类正样本 75 条。这个设定比旧版 600 词、多标签、`/b/` `/d/` `/l/` `/n/` 的版本更贴近题目，也更适合做案例分析。

4 理论背景与方法

4.1 短时表示、filter bank 与模板相似度

对 1 秒左右的短语音，最重要的不是绝对波形，而是局部时频能量结构。本文采用的前端是标准短时分析：

- 采样率统一到 16 kHz；
- 帧长 25 ms，帧移 10 ms；
- FFT 长度 512；
- 40 维 log-mel filter bank 作为主表示。

记某个样本的 log-mel 图为 $S_i \in \mathbb{R}^{T\times M}$，其中 $M = 40$。再定义时间包络

$$a_i(t) = \frac{1}{M}\sum_{m=1}^{M} S_i(t,m),$$

以及某个类别 c 的训练集正样本均值模板

$$T_c = \frac{1}{N_c}\sum_{i:y_{i,c}=1} S_i, \qquad A_c = \frac{1}{N_c}\sum_{i:y_{i,c}=1} a_i.$$

课内模板法的分数由两部分组成：

$$s_{i,c}^{\text{spec}} = \max_{\tau} \rho(S_i, T_c; \tau)\,, \qquad s_{i,c}^{\text{auto}} = \frac{\langle a_i, A_c\rangle}{\|a_i\|_2\,\|A_c\|_2},$$

其中 $\rho(\cdot)$ 表示归一化互相关，τ 是时间平移。最终总分是

$$s_{i,c} = 0.65\, s_{i,c}^{\text{spec}} + 0.35\, s_{i,c}^{\text{auto}}.$$

这套设计的假设很明确：同一类词在首辅音附近会共享相似的时频模板，而时间包络的周期性和持续性也有类别信息。它的优点是解释性强；缺点是只要模板在多个类之间都相似，就很容易一起抬高，导致误报。

4.2 算法 1：课程模板法

```
Algorithm 1 课程模板法
Input: train/dev/test waveforms, labels C={g,b,d,z}
Output: per-label predictions on test

for each class c in C do
    build mean log-mel template T_c from train positives
    build mean envelope autocorr template A_c from train positives
end for

for each dev sample i do
    for each class c in C do
        s_ic = 0.65 * max_correlation(S_i, T_c)
             + 0.35 * cosine(a_i, A_c)
    end for
    choose tau_c that maximizes F1 on dev
end for

for each test sample i do
    predict y_ic = 1[s_ic >= tau_c]
end for
```

这个方法本质上是“均值模板 + 阈值判别”。它不是学习一个复杂边界，而是在问：当前样本和某个类别的典型声学形态像不像。正因为如此，它适合作为主方法的可解释基线。

4.3 算法 2：统计特征 MLP 基线

MLP 不是主角，只是一个强一点的统计基线。它的输入不是原始波形，而是手工汇总后的 62 维统计特征：

- 13 维 MFCC 的均值和标准差；
- MFCC 一阶差分的均值和标准差；
- 10 个 coarse band-energy 特征。

模型结构是 `StandardScaler -> MLPClassifier(128, 64)`，用 early stopping 训练。和模板法相比，它不再依赖显式模板对齐，而是直接学习这些统计特征之间的组合关系。因为当前

数据是单标签四分类，但阈值仍按 label 单独选，所以 MLP 的 exact-match 往往会比 label-wise accuracy 更能反映它是否“少乱报”。

4.4 算法 3：CNN 对照基线

CNN 只作为更强的对照上界。输入是整词 log-mel spectrogram，网络是 3 个卷积块加自适应池化，再接一层小型全连接头。训练时使用带 `pos_weight` 的 `BCEWithLogitsLoss`，并按 dev macro-F1 早停回退到最佳 epoch。

最终采用的调参配置是：

$$\texttt{epochs} = 35, \quad \texttt{batch} = 96, \quad \texttt{lr} = 6 \times 10^{-4}, \quad \texttt{weight_decay} = 10^{-4}, \quad \texttt{patience} = 8.$$

它的作用只是提供一个“模型能学到多少局部时频模式”的参照，不影响本文的主要论证。

5 定性案例分析

5.1 代表性样本

图 1 给出了四个代表词的波形和 spectrogram，图 2 给出了四类在训练集正样本上的平均 log-mel 模板。

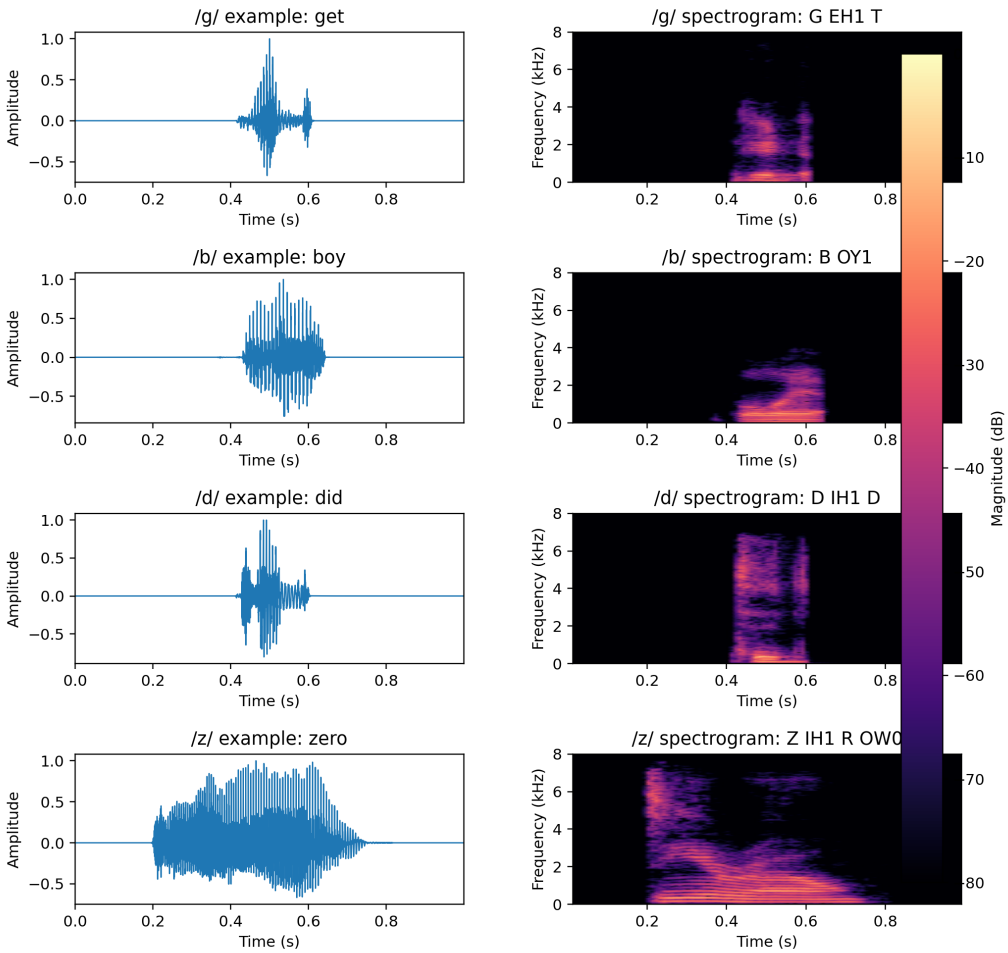

图 1: 四个目标浊辅音的代表性样本：`get`、`boy`、`did`、`zero`。

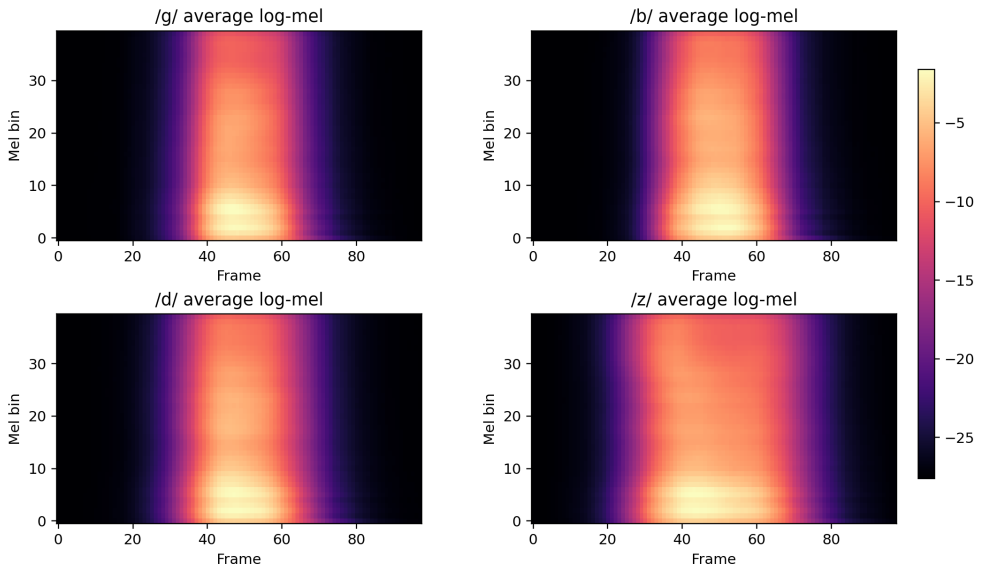

图 2: 四个目标浊辅音在训练集正样本上的平均 log-mel 模板。

从图上能直接看出：/g/、/b/、/d/ 的关键差异主要集中在起始几十毫秒的短时爆破和过渡；/z/ 则有更长、更明显的高频摩擦能量。也因此，/z/ 的模板最稳定，/g/ 的模板最难。

5.2 四个样本的预测行为

表 2: 四个代表词的预测行为与声学解释

词	真值	课程模板法	MLP	CNN	解释
get	g	g b d z	g	b	/g/ 爆破短，模板法容易把其它 stop 一起抬高；CNN 仍会和 /b/ 混淆。
boy	b	g b d z	b	b	/b/ 的低频起始和元音过渡更清楚，统计特征和 CNN 都能抓住。
did	d	b d z	d	g b	/d/ 有可见过渡，但阈值校准仍会让 CNN 多报。
zero	z	g b d z	z	z	/z/ 的持续摩擦最稳定，三种方法都最容易。

这个表最关键的结论不是“谁赢了”，而是错误模式很一致：

- 课程模板法偏召回，容易把多个标签同时判正，所以 exact-match 很差；
- MLP 的统计特征最稳，通常能给出更干净的单标签输出；
- CNN 的逐标签区分更强，但在短促 stop 上仍会出现阈值边界偏松的问题。

6 实验结果与比较

6.1 总体结果

表 3 是最终采用的 `tuned_b` 结果。这里最重要的结构是：课程模板法明显落后；MLP 和 CNN 明显更强；CNN 的 macro-F1 最好，但 MLP 的 exact-match 仍然更高。

表 3: 最终结果对比

方法	label-wise acc.	exact-match acc.	macro-F1	micro-F1	samples-F1
课程模板法	0.3525	0.0000	0.3916	0.3925	0.3856
MLP	**0.7558**	**0.4100**	0.5658	0.5646	0.5589
CNN	0.7567	0.3567	**0.5823**	**0.5718**	0.5483

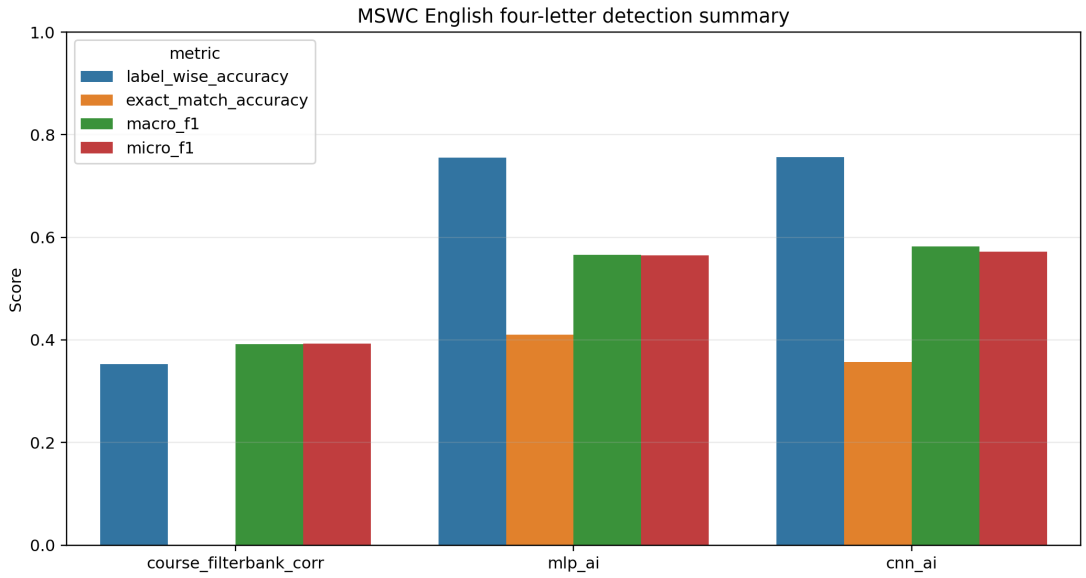

图 3: 总体指标比较。

这里的一个关键现象是：MLP 的 exact-match 更高，但 CNN 的 macro-F1 更高。这个差异说明 CNN 更敢把局部声学线索判出来，MLP 则更保守、更少同时报多个标签。对于当前这种“单词级四分类”设置，exact-match 比 label-wise accuracy 更能暴露阈值校准问题。

6.2 分标签结果

表 4: 四个标签的 F1

方法	/g/	/b/	/d/	/z/
课程模板法	0.403	0.403	0.400	0.360
MLP	0.490	0.533	0.524	0.717
CNN	0.443	**0.610**	0.532	**0.745**

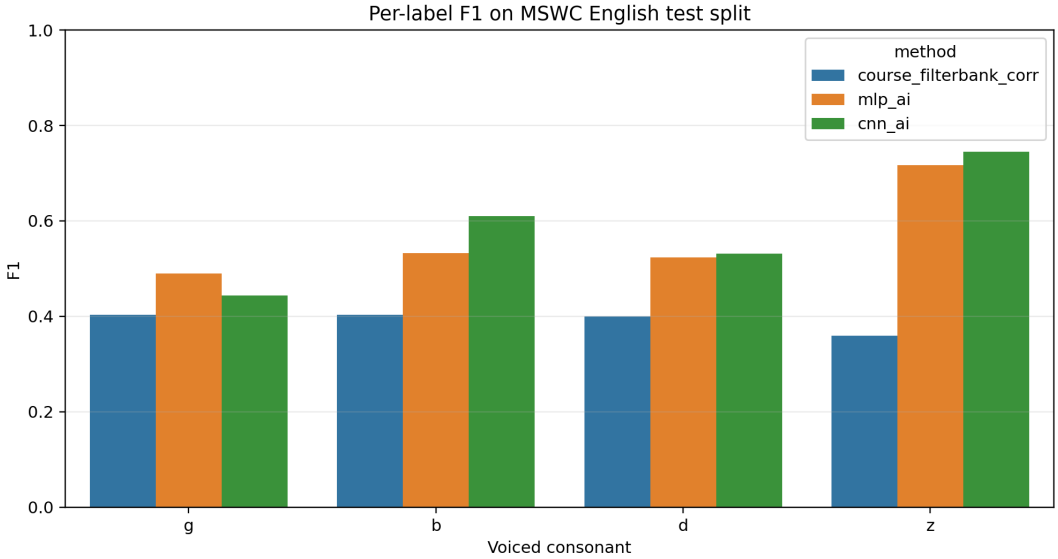

图 4: 分标签 F1 对比。

这个表对应的解释也很清楚：

- **/g/ 最难**。它的释放短、局部、容易被 25 ms 窗口抹平，因此三种方法都不占便宜。
- **/b/ 改善最明显**。低频起始和过渡对 CNN 很友好，所以 CNN 在 /b/ 上涨得最明显。
- **/d/ 居中**。它有可见过渡，但不如 /z/ 那么长，也不如 /g/ 那么短得极端。
- **/z/ 最容易**。持续摩擦噪声提供了最稳定的时频证据，因此 MLP 和 CNN 都能把它分得很好。

7 讨论与局限

这次重构最重要的收益，不是某个分数上升了，而是任务边界终于变清楚了。旧版更像“词里有没有出现某个浊辅音”，新版则更接近“词首这个浊辅音能不能被检出”。一旦把这个条件收紧，报告里的理论解释就顺了：

- 课内模板法是可解释的，但它更像召回器，容易把相似的 stop 一起判正；
- MLP 的统计特征压缩了整词声学形态，因此 exact-match 最稳；

- CNN 直接看局部时频图，所以在 /b/ 和 /z/ 上更强，但对 /g/ 这种极短 cue 仍不稳定。

不过这份报告仍然有三个局限需要明确写出：

1. 它仍然是整词级特征，不是人工切出来的 phone segment；
2. /z/ 的词数比较紧，整个平衡子集的规模被它卡住了；
3. 调参只做了轻量 sweep，AI 模型只是对照基线，不是全文核心。

如果后续继续推进，最合理的方向不是再加更大的网络，而是做真正的 phone-level 对齐，或者在现有 MSWC 上做更精细的首辅音裁剪。

8 结论

本文完成了 Topic 2 的一次重新组织，核心结论如下：

- 通过“首字母与首个非元音音素严格对应”的规则，新数据集把任务收紧到了首浊辅音检测；
- 课内模板法、MLP、CNN 的 macro-F1 分别为 0.392、0.566、0.582，说明手工模板仍有解释价值，但性能明显弱于更强的统计和卷积基线；
- CNN 在逐标签判别上最好，MLP 在 exact-match 上最好；
- /z/ 最容易、/g/ 最难，这和声学图里的持续摩擦与短促爆破完全一致；
- 这份报告的重点已经从“跑一个神经网络”转成“解释为什么这些辅音会这样表现”。

参考文献

[1] S. Davis and P. Mermelstein, “Comparison of Parametric Representations for Monosyllabic Word Recognition in Continuously Spoken Sentences,” *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 1980. https://doi.org/10.1109/TASSP.1980.1163420.

[2] L. R. Rabiner, “A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition,” *Proceedings of the IEEE*, 1989. https://doi.org/10.1109/5.18626.

[3] N. J. Wilkinson and M. J. Russell, “Improved Phone Recognition on TIMIT Using Formant Frequency Data and Confidence Measures,” in *Proc. ICSLP 2002*. https://www.isca-archive.org/icslp_2002/wilkinson02_icslp.html.

[4] G. Chen, C. Parada, and G. Heigold, “Small-Footprint Keyword Spotting using Deep Neural Networks,” in *Proc. ICASSP 2014*. https://research.google/pubs/small-footprint-keyword-spotting-using-deep-neural-networks/.

[5] T. N. Sainath and C. Parada, “Convolutional Neural Networks for Small-Footprint Keyword Spotting,” in *Proc. Interspeech 2015*. https://research.google/pubs/convolutional-neural-networks-for-small-footprint-keyword-spotting/.

[6] S. O. Arik *et al.*, "Convolutional Recurrent Neural Networks for Small-Footprint Keyword Spotting," in *Proc. Interspeech 2017*.

[7] P. Warden, "Speech Commands: A Dataset for Limited-Vocabulary Speech Recognition," arXiv:1804.03209, 2018. https://doi.org/10.48550/arXiv.1804.03209.

[8] M. Berg *et al.*, "Keyword Transformer: A Self-Attention Model for Keyword Spotting," arXiv:2104.00769, 2021.

[9] A. Baevski *et al.*, "wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations," arXiv:2006.11477, 2020. https://doi.org/10.48550/arXiv.2006.11477.

[10] W.-N. Hsu *et al.*, "HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units," arXiv:2106.07447, 2021.

[11] S. Chen *et al.*, "WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing," *IEEE Journal of Selected Topics in Signal Processing*, 2022. https://arxiv.org/abs/2110.13900.

[12] C. Gao *et al.*, "Self-Supervised Speech Representation Learning for Keyword-Spotting with Light-Weight Transformers," arXiv:2303.04255, 2023. https://arxiv.org/abs/2303.04255.

[13] D. Kim and J. Hwang, "Fully End-to-end Streaming Open-vocabulary Keyword Spotting with W-CTC Forced Alignment," in *Proc. Interspeech 2025*. https://www.isca-archive.org/interspeech_2025/kim25d_interspeech.html.