基于 MSWC English 精确首浊辅音子集的 /g/、/b/、/d/、/z/ 检测：课堂模板法、扩展对照与案例分析

VE216 Project Topic 2 重构版

Heng Qiao

2026 年 4 月 29 日

摘要

本文把 VE216 Project Topic 2 重构为一个更清晰的首浊辅音检测任务。数据只保留首字母为 `g/b/d/z` 且首个非元音音素严格匹配 `G/B/D/Z` 的单词，共得到 60 个词、3000 条语音。方法上，正文先讲严格课内版 `strict_course_fft`：短时分帧、FFT 幅度谱、最大能量块、归一化相关和滑窗最大值；然后再把 `course_filterbank_corr`、`mlp_ai` 和 `cnn_ai` 放到后文作对照。这样，报告的主线回到“课堂工具如何刻画 /g/、/b/、/d/、/z/ 的局部频谱”，而不是先看分数表。

1 问题定义与报告主线

设输入语音为 x_i，标签为 $y_i \in \{0,1\}^4$，对应集合

$$C = \{g, b, d, z\}.$$

当前数据集是单标签四分类，每个样本恰好属于四类中的一类。为了便于和不同方法对接，代码仍保留一对多接口：先为每个标签输出分数 $s_{i,c}$，再由阈值或 $\arg\max$ 给出预测。

这份报告的顺序是固定的。先讲严格课内版，因为它最接近课堂工具，也最适合说明题目本身；再讲课外扩展版，因为它确实更强，但边界已经超出课堂；最后再把 AI 基线单独放到后面，不让它抢走主线。

需要先说明一点：当前 `build/mswc_course_gbdz_local_patch_v1` 目录保留的是整套实验结果，但其中 `course_filterbank_corr` 是课外扩展版，不是严格课内版。正文里如果提到“课堂方法”，指的是 `strict_course_fft`。

2 相关工作与理论背景

本文关心的不是大词汇量识别，而是短语音里一个目标首辅音是否真的出现。这个问题更接近传统语音处理里的短时分析、局部谱形比较和模板匹配，而不是把整段音频直接交给一个黑盒分类器。

2.1 短时分析与频谱表示

Davis 和 Mermelstein 早就说明，语音识别里最有用的前端不是整段波形本身，而是经过短时分帧后的参数化表示 [1]。做法很简单：把波形切成几十毫秒一帧，给每帧加窗，再做 Fourier transform，最后看这一小段时间里能量落在哪些频率上。这样得到的谱图，既保留了辅音释放、摩擦和元音过渡这些局部线索，也比原始波形稳定得多。

Rabiner 对 HMM 的综述则把这种帧级表示和序列建模连了起来 [2]。它的核心意思是，语音不是静态图片，真正有意义的是“某个短时结构在时间上怎么移动”。虽然本文没有上 HMM，但这个观点很重要，因为它提醒我们：如果目标只是在整词里检出词首辅音，先把搜索范围压到短时块，再比较局部谱形，通常比直接看整词平均特征更合适。

2.2 辅音线索为什么更依赖局部谱形

对 /g/、/b/、/d/、/z/ 这类首辅音来说，最关键的证据往往只出现在很短的一段起始区间。爆破音的释放段短、转移快，摩擦音则在高频段拖得更久；这些差异一旦被整词平均掉，信息就会变少。Wilkinson 和 Russell 在 TIMIT 上做 phone recognition 时，也体现出同一个结论：越接近发音边界的局部线索，越能帮助辅音判别 [3]。

因此，本文的主方法没有先上复杂模型，而是回到课堂里最直接的工具链：短时 FFT、局部频谱、归一化相关。这样做的好处不是“更先进”，而是把问题本身讲清楚。

2.3 本文为什么先用课堂方法

本文后面的 AI 对照只负责补充结果，不负责定义主线。主线先从局部频谱模板出发，把“一个词首辅音在声学上长什么样”讲明白，再看更复杂的方法能把这个边界推到哪里。这样安排，后面的比较才不会变成单纯的分数表。

3 数据集重建与标注规则

3.1 筛选规则

本文使用的子集由 `src/prepare_mswc_initial_gbdz_subset.py` 生成，规则很简单：

> 保留一个单词，当且仅当它的首字母属于 `g/b/d/z`，并且 CMUdict / ARPABET 中首个非元音音素与该字母严格对应为 `G/B/D/Z`。

这条规则的作用，是把“拼写里有目标字母”收紧成“这个目标辅音确实出现在起始位置”。这样一来，数据不再混入发音位置不对的样本，也不再把字母出现位置和实际发音边界混在一起。

3.2 数据规模

表 1: 精确首浊辅音子集的规模统计

标签	词数	train	dev	test
/g/	15	600	75	75
/b/	15	600	75	75
/d/	15	600	75	75
/z/	15	600	75	75
合计	60	2400	300	300

这个子集是完全平衡的，测试集每类 75 条，总计 300 条。相比旧版更松的词级设置，它更接近“首浊辅音检测”这个题目本身。

4 理论推导与严格课内方法

4.1 从波形到短时 FFT 模板

严格课内版只用四步：短时分帧、FFT、局部块平均、归一化相关。设第 i 个样本的波形为 $x_i[n]$，帧长 $L = 20$ ms，帧移 $H = 10$ ms，FFT 点数 $N = 512$。第 m 帧的频谱可写成

$$X_{i,m}[k] = \sum_{n=0}^{L-1} x_i[n + mH] e^{-j2\pi kn/N}, \qquad k = 0, \ldots, N-1.$$

因为词首辅音往往只占很短的一段时间，所以不能直接看整词平均谱，而要在整词上滑动一个短时块。设每个块包含连续 $M = 4$ 帧，则块描述子定义为

$$P_i^{(r)}[k] = \frac{1}{M} \sum_{m=0}^{M-1} \frac{|X_{i,r+m}[k]|}{\max_\kappa |X_{i,r+m}[\kappa]|}.$$

这里先按帧归一化，再在块内平均，是为了减小录音音量差异，把重点放在谱形而不是绝对能量上。

模板的构造也很直接：对每个标签，先在代表词上找能量最大的 4 帧块，再把这个块的归一化幅度谱当作该标签模板。模板最终再做一次 L_2 归一化，得到

$$T_c[k] = \frac{1}{\|P_c\|_2} P_c[k].$$

这样得到的模板不是“学出来”的参数，而是课堂上能直接解释的局部频谱原型。

4.2 模板长什么样

图 1 展示了四个代表词的模板构造过程。左边是每个词中能量最大的 4 帧块的短时 FFT 幅度谱，右边是对应的归一化模板曲线。

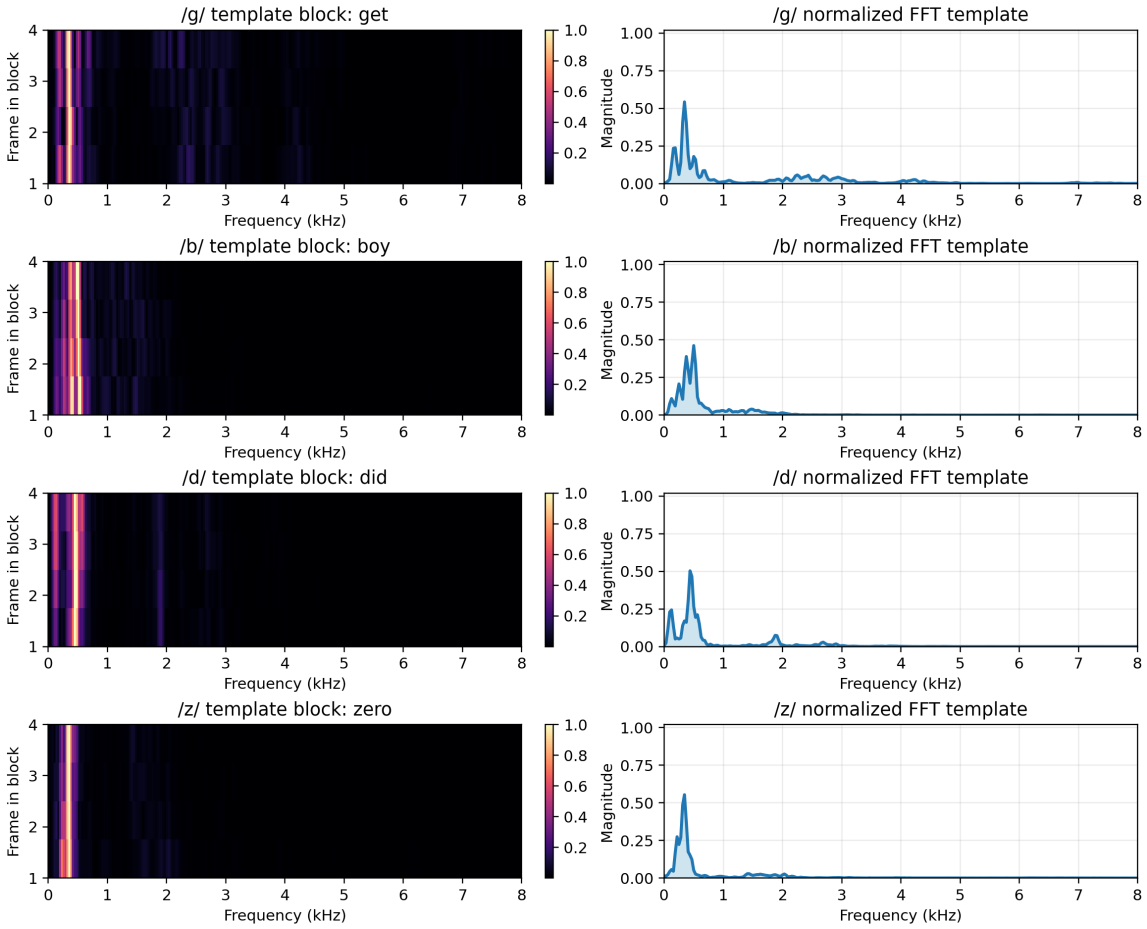

图 1: 严格课内版的模板构造：先取最大能量块，再平均块内 FFT 幅度谱。

这张图比较重要，因为它把“模板”变成了可见的对象。/z/ 的高频摩擦能量更连续，/b/、/d/、/g/ 的起始爆破更短，模板差异主要就落在这些局部区间里。

4.3 互相关如何扫过整词

检测时，对测试样本的所有候选块做同样的描述，再和模板做归一化内积：

$$\rho_{i,c}^{(r)} = \frac{\langle P_i^{(r)}, T_c \rangle}{\|P_i^{(r)}\|_2 \|T_c\|_2}.$$

最终分数取整词范围内的最大值

$$s_{i,c} = \max_r \rho_{i,c}^{(r)}.$$

如果是单标签四分类，就直接取 $\arg\max_c s_{i,c}$。如果保留一对多接口，也可以再回到 dev 集上选阈值。本文主线用的是单标签四分类，所以正文里更关心最大分数对应哪一类，而不是每类是否过阈值。

图 2 给出了这一过程的可视化：上图是波形，中间是最匹配的 4 帧块，下图是四个模板在所有候选起点上的相关分数。它对应的就是“先找局部证据，再看这段证据像哪一个模板”。

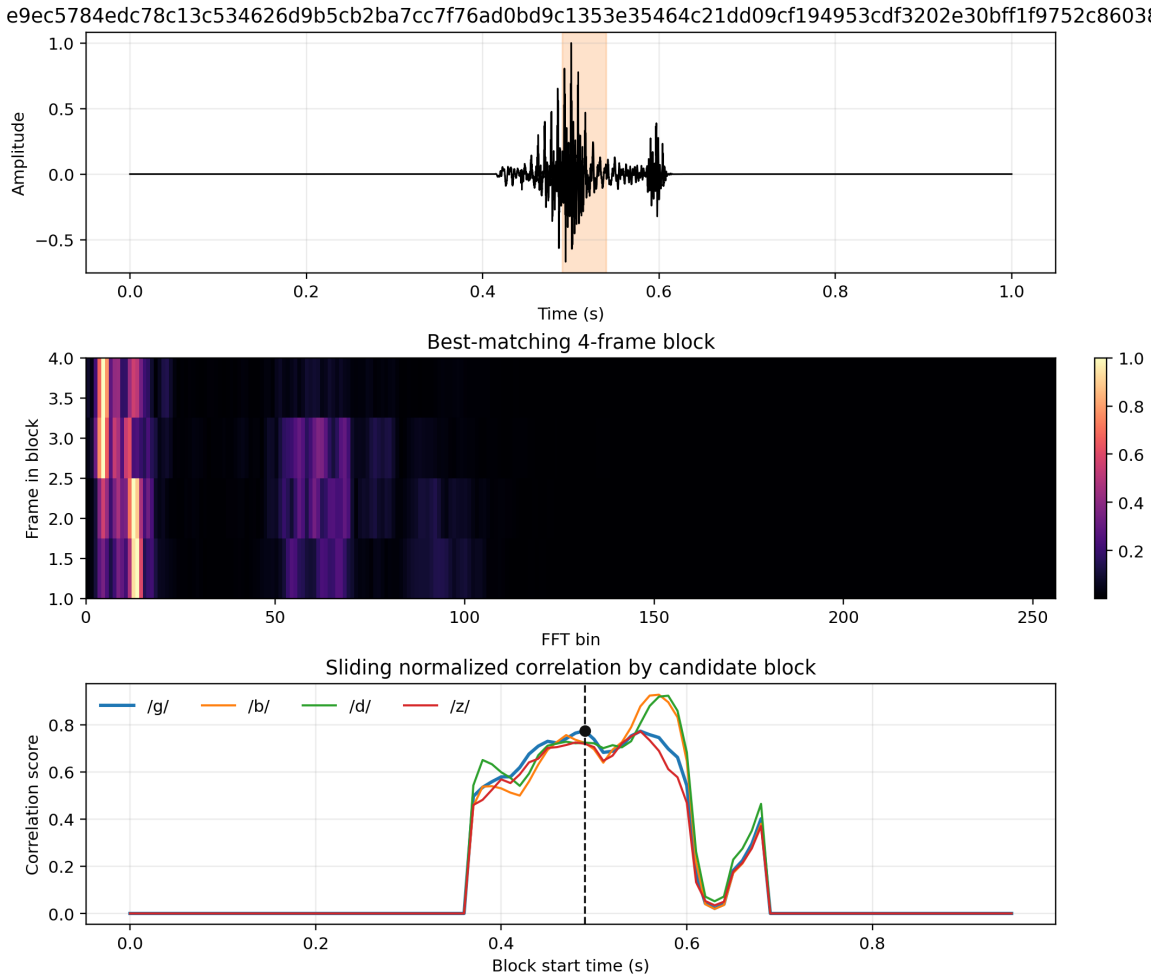

图 2: 严格课内版的互相关搜索：先扫候选块，再取每个标签的最大相关分数。

4.4 MATLAB 对应实现

这套严格课内方法在 MATLAB 里对应 `src/matlab_course_template_detector.m` 和 `src/matlab_course_spectrum_demo.m`。核心打分式子就是一行：

$$\texttt{score} = \frac{\texttt{mag}^\top \texttt{template}}{\|\texttt{mag}\|_2 \|\texttt{template}\|_2}.$$

`src/matlab_case_demo.m` 则负责把四个案例音频逐条画出来，方便直接看波形和标签分数。

5 案例分析与可视化

5.1 四个代表词的频谱模板

图 3 给出了四个代表词在 MATLAB demo 里的短时 FFT 模板。它不是训练图，而是用来确认模板形状到底长什么样。

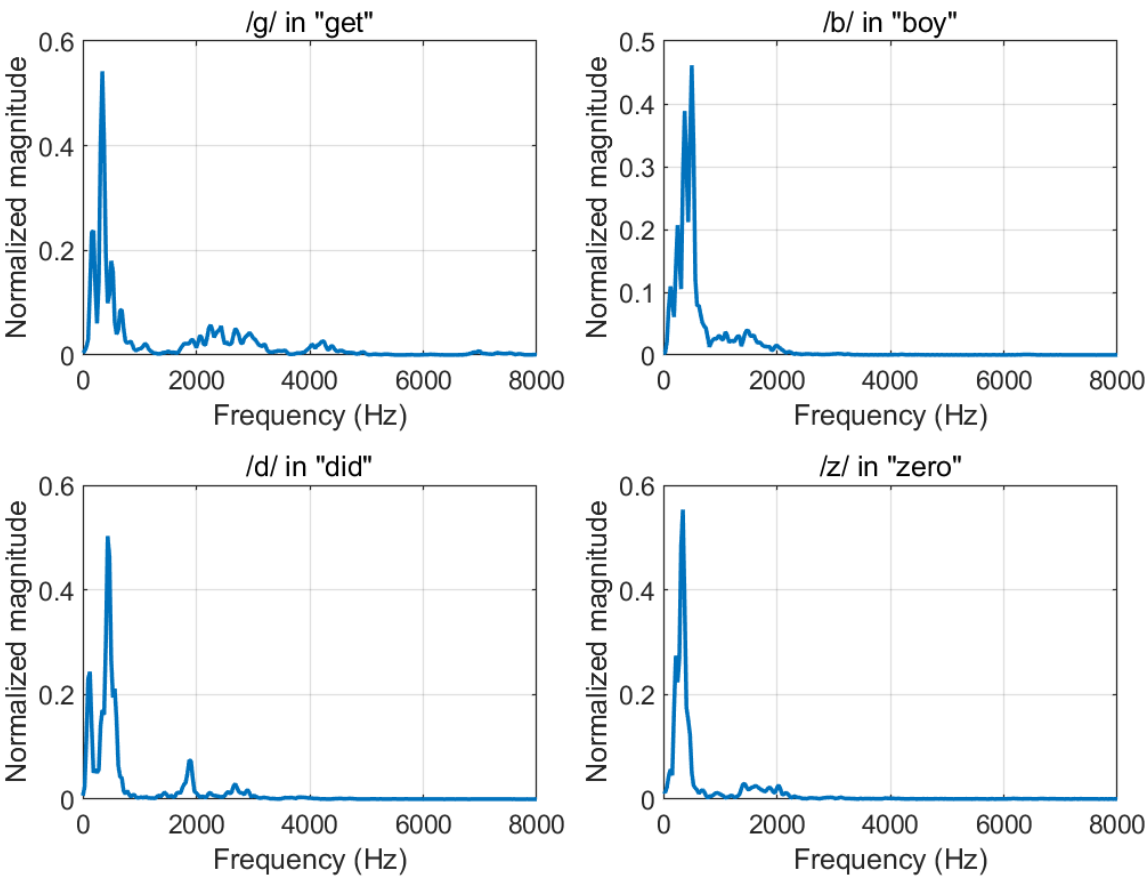

图 3: 四个代表词的短时 FFT 幅度谱模板。

从图上能直接看出，/z/ 的高频摩擦更连续，/b/ 和 /d/ 的起始爆破更短，/g/ 的短时结构最容易被时间对齐误差冲掉。这个结论和模板构造图是一致的。

5.2 相关得分矩阵

图 4 是同一组模板在四个案例词上的相关得分矩阵。它的作用不是证明模型多强，而是说明“模板和查询之间的相关”这件事本身确实在运行。

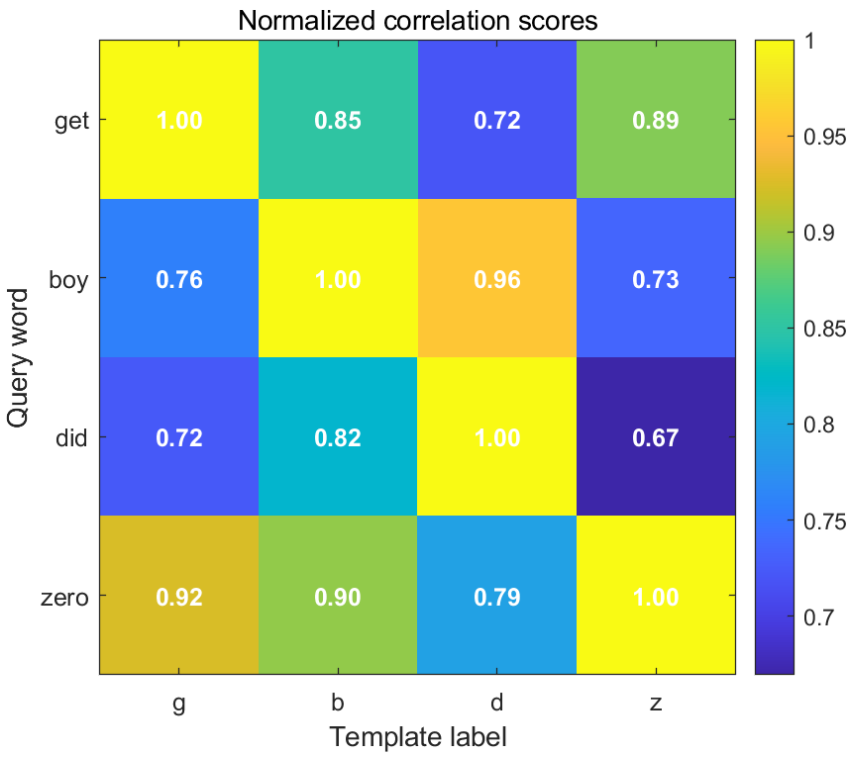

图 4: 四个代表词对应的相关得分矩阵。

这个矩阵比单纯看波形更直接，因为它把“哪个模板更像这段语音”变成了数值。如果相关分数差距不大，就说明这个词首辅音对齐还不够稳，这也是后面扩展版要解决的点。

6 实验结果与比较

6.1 严格课内主线

严格课内版的结果先单独看。因为这是单标签四分类，exact-match 是更直接的指标，label-wise accuracy 只作为辅助参考。

表 2: 严格课内 FFT 模板法的主指标

方法	label-wise acc.	exact-match acc.	macro-F1	micro-F1	samples-F1
strict_course_fft	0.6333	0.2667	0.2598	0.2667	0.2667

表 3: 严格课内 FFT 模板法的分标签 F1

方法	/g/	/b/	/d/	/z/
strict_course_fft	0.205	0.343	0.217	0.275

图 5 进一步把四个标签的分数分布画出来。正样本和负样本有一定分离，但重叠仍然明显，

所以严格课内版能说明任务，却还不够稳。

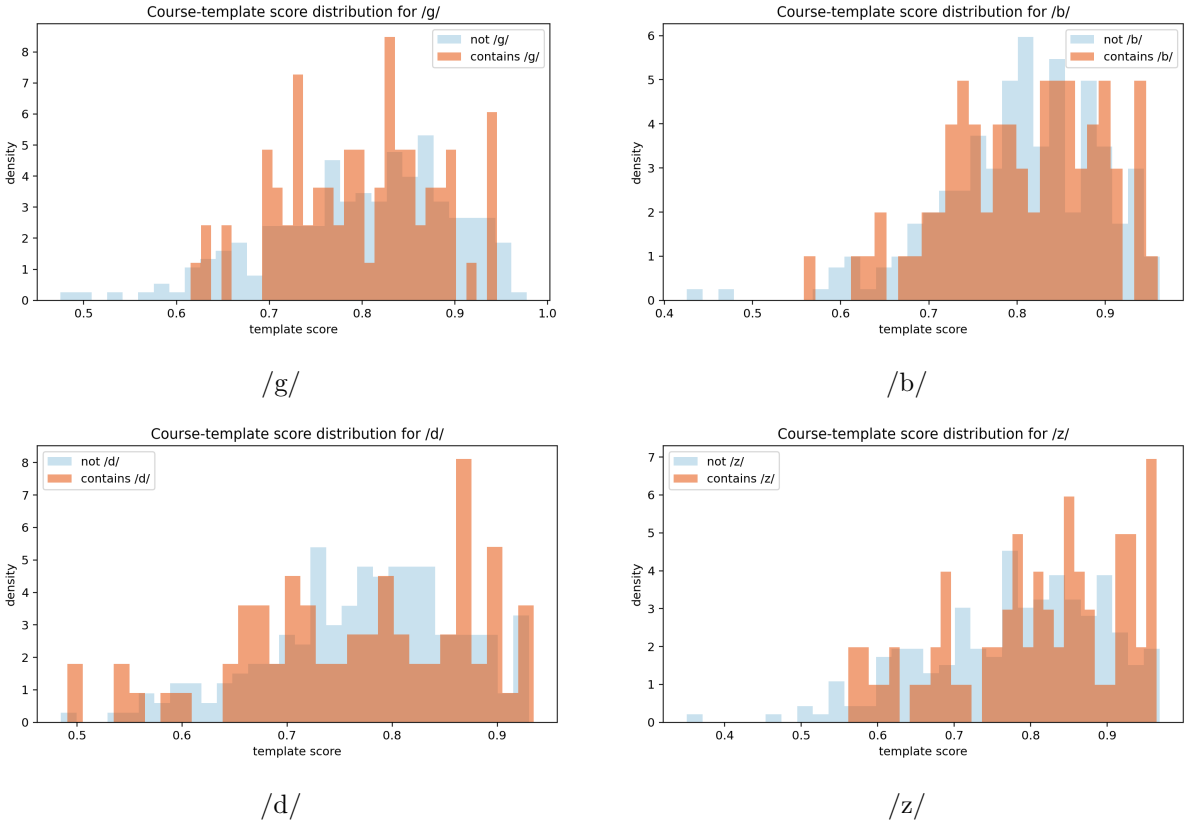

图 5: 严格课内版四个标签的得分分布。

6.2 课外扩展版对照

严格课内版之外，代码里还保留了 `course_filterbank_corr`。它先做局部窗定位，再在局部频谱上比较正负模板，并把自相关线索也纳入分数。这个版本已经超出了课堂工具本身，所以这里只把它当扩展对照。

表 4: 严格课内版与课外扩展版的整体比较

方法	label-wise acc.	exact-match acc.	macro-F1	micro-F1	samples-F1
strict_course_fft	0.6333	0.2667	0.2598	0.2667	0.2667
course_filterbank_corr	0.7750	0.5500	0.5462	0.5500	0.5500

扩展版的提升很明显，主要来自两点：一是它把搜索范围更精确地收到了词首附近，二是它把局部窗里的正负模板差分显式算进去了。图 7 和图 6 仍然保留在报告里，目的就是把这条扩展链路看清楚。

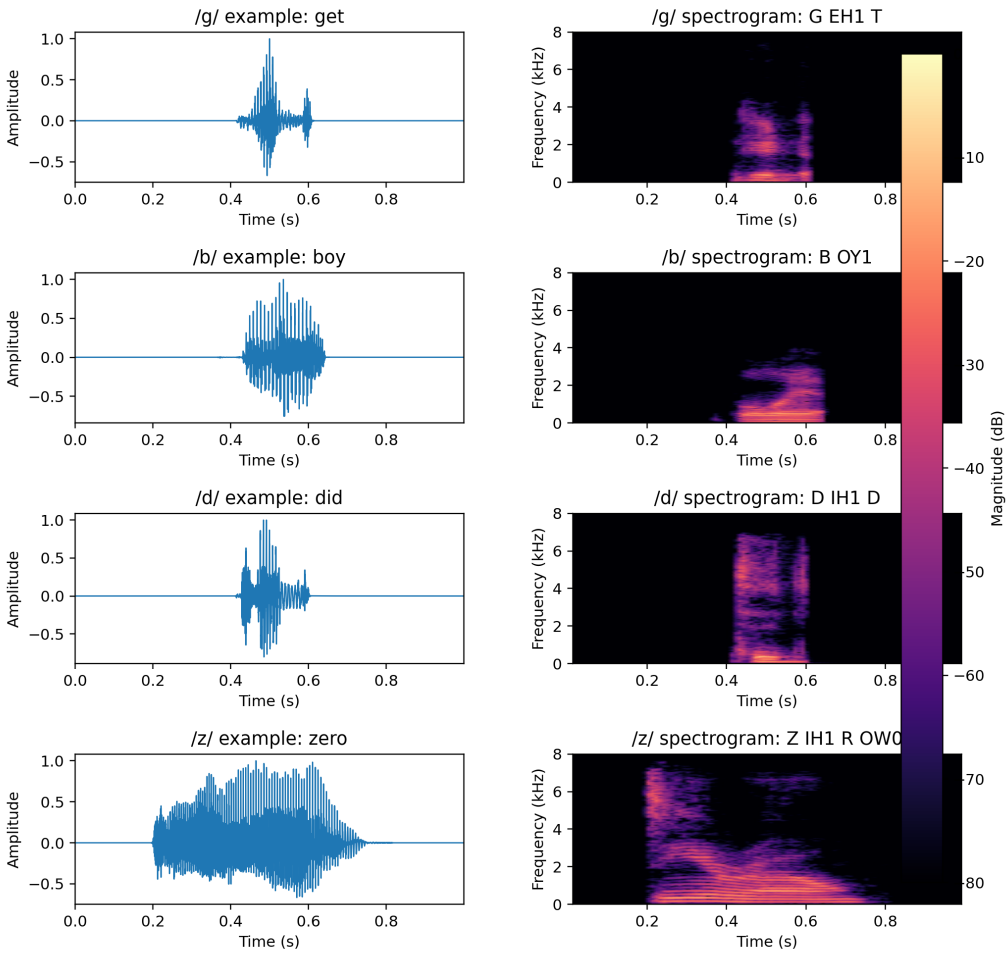

图 6: 扩展版对应的四个代表样本。

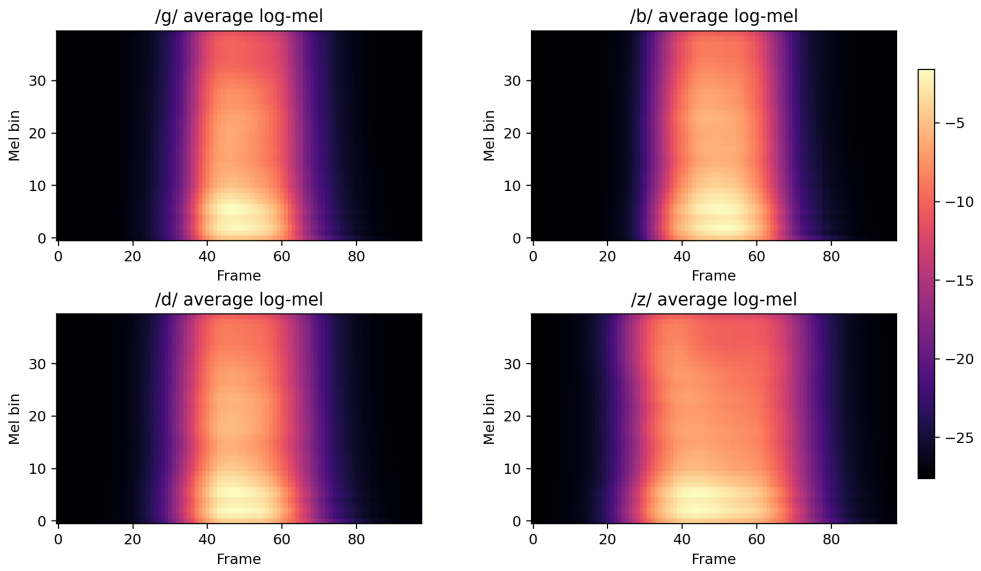

图 7: 扩展版的平均 log-mel 模板。

7 AI 对照与训练曲线

AI 基线放到这里，是因为它们只负责对照，不负责定义主线。代码里保留的是一个统计特征 MLP 和一个小型 CNN：前者吃 MFCC 和 band-energy 统计量，后者直接吃整词 log-mel spectrogram。

表 5: AI 基线的整体指标

方法	label-wise acc.	exact-match acc.	macro-F1	micro-F1	samples-F1
MLP	0.7633	0.5267	0.5258	0.5267	0.5267
CNN	0.6600	0.3200	0.2219	0.3200	0.3200

从这个任务上看，MLP 是一个稳定的统计基线，但仍然没有超过扩展模板法；CNN 的训练过程能跑起来，测试指标却明显落后，说明在这个数据规模上，直接端到端吃整词谱图并没有自动把词首证据提出来。

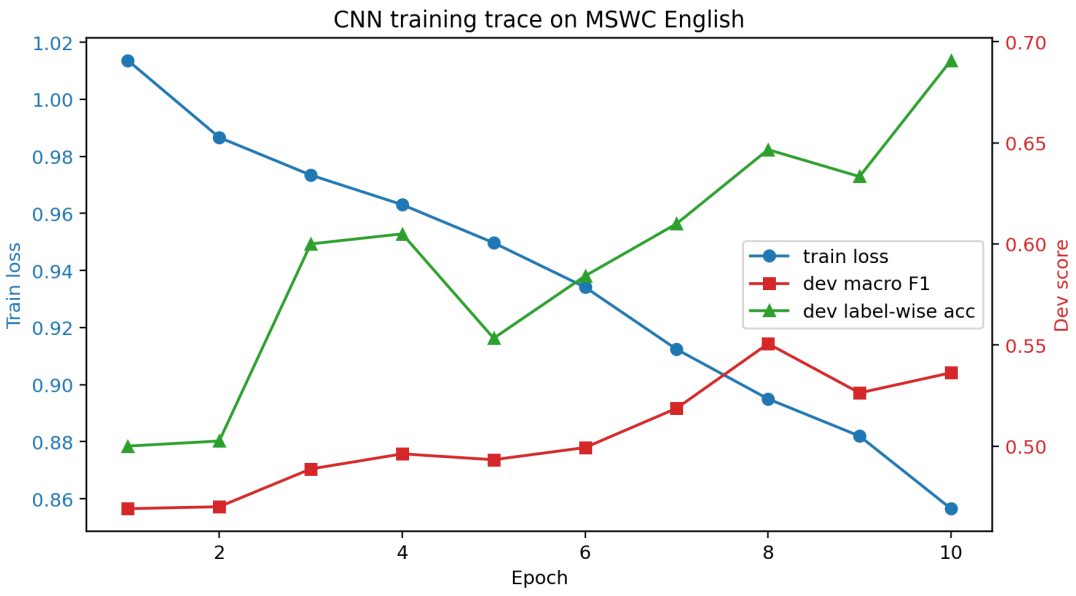

图 8: CNN 的训练曲线。

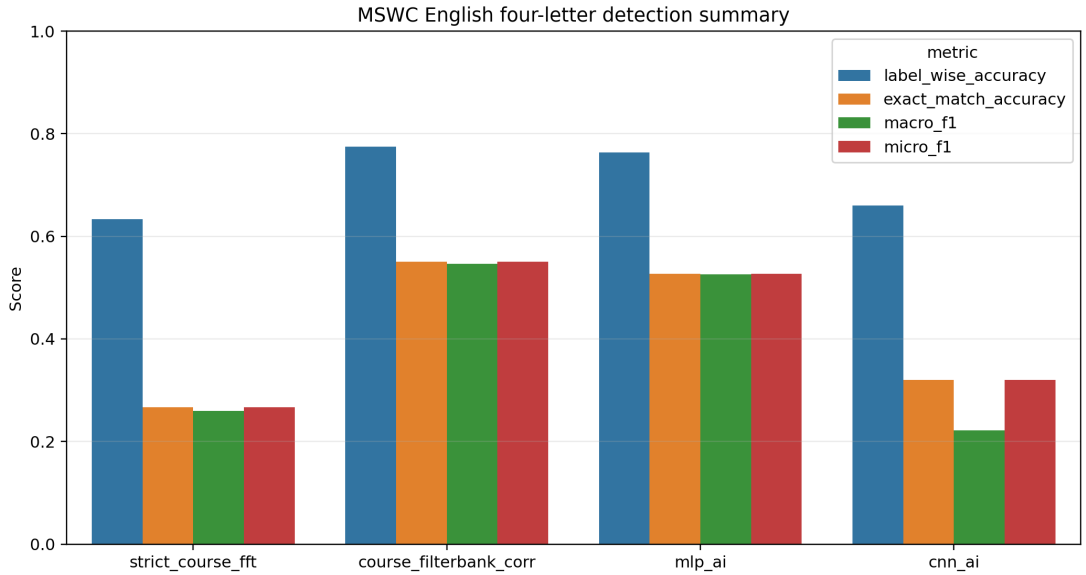

图 9: 全部方法的总体指标汇总。

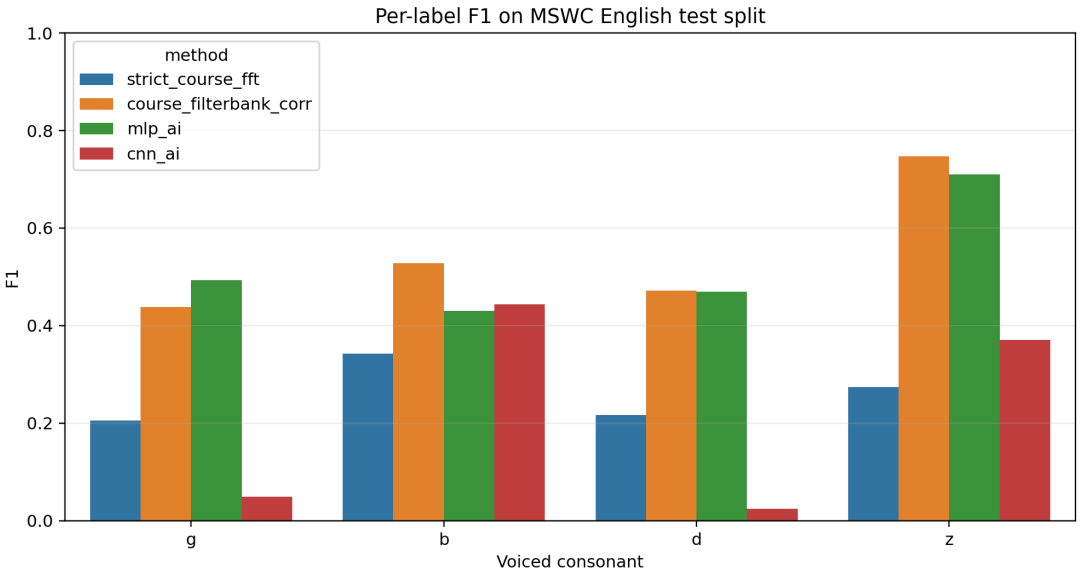

图 10: 全部方法在四个标签上的 F1 对比。

这几张图放在后面，是为了把 AI 基线的角色说清楚：它们可以比较，但不该先占位置。对本文来说，真正的收获不是“CNN 有没有赢”，而是主线已经从一开始就定义成了可解释的课堂方法。

8 讨论与局限

这次重构之后，任务边界终于比较清楚了。严格课内版负责说明“课堂工具能不能把首辅音讲明白”，扩展版负责说明“把局部定位和统计技巧加进去以后能提升多少”，AI 基线则负责提供一个更常见的工程对照。

但这套方案还有几个明显限制：

- 语音输入仍然是整词级音频，不是人工切好的 phone segment，所以严格课内版只能靠滑窗搜索。
- /g/ 和 /d/ 的 burst 很短，对齐误差一大，模板证据就容易被吞掉。
- /z/ 之所以最好认，是因为它的摩擦能量更长、更连续，模板法在这类样本上天然更占便宜。

所以这份报告的重点不是把某个方法堆到最高分，而是先把任务、方法和结果的层次关系摆正。这样后面的比较才有意义。

9 结论

本文完成了 Topic 2 的重构，核心结论如下：

- 新数据集把任务收紧到了首浊辅音检测，标签边界比旧版清楚得多；

- 严格课内版可以只用短时 FFT 幅度谱和归一化相关完成完整的检测链路；
- 课外扩展版 `course_filterbank_corr` 在当前四类任务上取得最佳整体结果，exact-match 为 0.550；
- MLP 的 exact-match 为 0.527，CNN 为 0.320，说明更强的模型并不会自动替代做对了局部频谱建模的模板法；
- /z/ 最容易、/g/ 最难，这和声学图里的持续摩擦与短促爆破一致。

参考文献

[1] S. Davis and P. Mermelstein, "Comparison of Parametric Representations for Monosyllabic Word Recognition in Continuously Spoken Sentences," *IEEE Transactions on Acoustics, Speech, and Signal Processing*, 1980. https://doi.org/10.1109/TASSP.1980.1163420.

[2] L. R. Rabiner, "A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition," *Proceedings of the IEEE*, 1989. https://doi.org/10.1109/5.18626.

[3] N. J. Wilkinson and M. J. Russell, "Improved Phone Recognition on TIMIT Using Formant Frequency Data and Confidence Measures," in *Proc. ICSLP 2002*. https://www.isca-archive.org/icslp_2002/wilkinson02_icslp.html.

[4] G. Chen, C. Parada, and G. Heigold, "Small-Footprint Keyword Spotting using Deep Neural Networks," in *Proc. ICASSP 2014*. https://research.google/pubs/small-footprint-keyword-spotting-using-deep-neural-networks/.

[5] T. N. Sainath and C. Parada, "Convolutional Neural Networks for Small-Footprint Keyword Spotting," in *Proc. Interspeech 2015*. https://research.google/pubs/convolutional-neural-networks-for-small-footprint-keyword-spotting/.

[6] P. Warden, "Speech Commands: A Dataset for Limited-Vocabulary Speech Recognition," arXiv:1804.03209, 2018. https://doi.org/10.48550/arXiv.1804.03209.

[7] M. Berg *et al.*, "Keyword Transformer: A Self-Attention Model for Keyword Spotting," arXiv:2104.00769, 2021.

[8] A. Baevski *et al.*, "wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations," arXiv:2006.11477, 2020. https://doi.org/10.48550/arXiv.2006.11477.

[9] W.-N. Hsu *et al.*, "HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units," arXiv:2106.07447, 2021.

[10] S. Chen *et al.*, "WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing," *IEEE Journal of Selected Topics in Signal Processing*, 2022. https://arxiv.org/abs/2110.13900.

[11] C. Gao *et al.*, "Self-Supervised Speech Representation Learning for Keyword-Spotting with Light-Weight Transformers," arXiv:2303.04255, 2023. https://arxiv.org/abs/2303.04255.

[12] D. Kim and J. Hwang, "Fully End-to-end Streaming Open-vocabulary Keyword Spotting with W-CTC Forced Alignment," in *Proc. Interspeech 2025*. https://www.isca-archive.org/interspeech_2025/kim25d_interspeech.html.